



Wydział Informatyki

Katedra Systemów Inteligentnych i Data Science
Data Science

Magdalena Sokolowska
S32924

**Dane, które ratują życie: Analiza i wizualizacja
czynników wpływających na adopcję psów i
kotów w Austin Animal Center z
wykorzystaniem metod uczenia maszynowego**

Praca dyplomowa magisterska

Promotor: prof. dr hab. Grzegorz Wójcik

Warszawa, styczeń 2026 r.

Streszczenie

Tutaj znajdzie się streszczenie całej pracy.

Słowa kluczowe: data science, koty, psy

Abstract

Life-Saving Data: Analyzing Factors Affecting Adoptions at the Austin Animal Center via Machine Learning and Visualization

Keywords: programming, bluetooth, horse riding

Spis treści

1	Wstęp	1
1.1	Kontekst problemu i znaczenie badań	1
1.2	Cel, hipotezy i pytania badawcze	2
1.3	Zakres i struktura pracy - możliwe zmiany w trakcie pisania pracy	4
2	Podstawy teoretyczne i przegląd literatury	7
2.1	Problem bezdomności zwierząt i filozofia No-Kill	7
2.2	Predykcyjne modelowanie adopcji	8
2.3	Reprodukowalność i inżynieria danych (MLOps) - in progress	9
3	Dane i przygotowanie zbioru badawczego	10
3.1	Źródło danych i zakres analizy	10
3.2	Charakterystyka zbiorów wejściowych	11
3.3	Standaryzacja i czyszczenie danych	11
3.4	Konstrukcja epizodów i dopasowanie rekordów	12
3.5	Zmienne docelowe	12
3.6	Konstrukcja cech wejściowych	12
3.7	Charakterystyka opisowa zbioru	13
3.8	Ograniczenia danych	14
3.9	Podsumowanie przygotowania danych	14
4	Metodyka modelowania i oceny modeli	16
4.1	Cel modelowania	17
4.2	Formalne sformułowanie problemu	17
4.3	Przygotowanie danych i podział chronologiczny	17
4.4	Algorytmy predykcyjne	18
4.5	Metryki oceny	19
4.6	Interpretowalność (SHAP)	20

4.7	Protokół eksperymentu	21
4.8	Ograniczenia	21
5	Wyniki badań i interpretacja modeli	23
5.1	Ramy interpretacyjne rozdziału	23
5.2	Porównanie jakości modeli	24
5.3	Weryfikacja hipotez badawczych	26
5.4	Interpretacja i wiarygodność modelu	29
6	Architektura systemu i reprodukowalność eksperymentów	31
6.1	Środowisko wdrożeniowe i konteneryzacja (Docker)	31
6.1.1	Uzasadnienie złożoności systemu (Dlaczego MLOps?)	31
6.1.2	Architektura serwisów (Docker Compose)	32
6.2	Architektura <i>Artifact-First</i> i separacja warstw	33
6.3	Organizacja kodu i modułowość	33
6.4	Automatyzacja potoku (Pipeline) a notatniki Jupyter	34
6.4.1	Fazy zautomatyzowanego potoku i Data Provenance	34
6.5	Rygor testowy i audyty danych	35
7	Aplikacja demonstracyjna i sposób prezentacji wyników	37
7.1	Cel i środowisko aplikacji	37
7.2	Główne moduły funkcjonalne (widoki)	38
7.2.1	Single Animal Predictor (symulator pojedynczego przyjęcia)	38
7.2.2	Wyjaśnialność decyzji (Interactive SHAP)	39
7.2.3	Przegląd historycznych grup zwierząt	40
7.3	Scenariusze użycia w pracy schroniska (triaging)	40
8	Podsumowanie i wnioski końcowe	42
8.1	Odpowiedzi na pytania badawcze (hipotezy)	42
8.2	Ograniczenia badawcze i metodologiczne	42
8.3	Kierunki dalszych badań (future work)	44
8.4	Podsumowanie końcowe i reprodukowalność	44
	Bibliografia	46
	Lista figur	49

Rozdział 1

Wstęp

1.1 Kontekst problemu i znaczenie badań

Każdego roku do schronisk dla zwierząt na całym świecie trafiają miliony bezdomnych psów i kotów, co stanowi ogromne wyzwanie organizacyjne i logistyczne. W samych Stanach Zjednoczonych szacuje się, że rocznie do schronisk trafia około 6 milionów psów i kotów [1]. Efektywne zarządzanie taką liczbą podopiecznych wymaga zapewnienia odpowiedniej opieki, zasobów i przestrzeni każdemu zwierzęciu, przy jednoczesnym dążeniu do jak najszybszego znalezienia mu nowego domu. Jednym z kluczowych wskaźników skuteczności pracy schroniska jest czas pobytu zwierzęcia pod jego opieką (ang. *Length of Stay*, LOS). Im krótszy jest LOS, tym mniejsze obciążenie dla zwierzęcia (ograniczenie stresu, ryzyka chorób i zgonu) oraz dla placówki (niższe koszty utrzymania i więcej wolnego miejsca dla kolejnych potrzebujących).

Coraz więcej schronisk przyjmuje filozofię „*No-Kill*”, która zakłada unikanie eutanazji zdrowych zwierząt poprzez osiągnięcie bardzo wysokiego odsetka adopcji i uratowań. Przykładem spektakularnego sukcesu podejścia *No-Kill* jest *Austin Animal Center* (AAC) w Teksasie. Od 2011 roku miasto Austin może poszczycić się mianem największego miasta w USA o statusie *No-Kill*, utrzymując współczynnik uratowań (ang. *live-release rate*) powyżej 90% [2]. Schronisko AAC przyjmuje ponad 18 tysięcy zwierząt rocznie [2], co czyni je jedną z największych tego typu placówek komunalnych w kraju i jednocześnie stawia przed nim ogromne wymagania w zakresie efektywnego wykorzystania danych i zasobów. Dążenie do utrzymania wysokiego odsetka adopcji przy tak dużej skali działalności wymaga ciągłego usprawniania procesów i podejmowania trafnych decyzji operacyjnych.

W ostatnich latach zauważalny jest istotny zwrot od podejmowania decyzji w oparciu o doświadczenie i intuicję personelu ku podejściu opartemu na danych (*data-driven*). Większość dużych schronisk gromadzi szczegółowe informacje o każdym przyjęciu i opuszczeniu zwierzęcia (*intake & outcome*), jednak w wielu przypadkach dane te nie są w żadnym stopniu wykorzystywane do wyciągania praktycznych wniosków. Zastosowanie nowoczesnych metod analizy danych i uczenia maszynowego otwiera możliwość lepszego zrozumienia, jakie czynniki sprzyjają szybkim adopcjom, a jakie wiążą się z dłuższym pobytem zwierząt w schronisku/jego śmiercią. Modele predykcyjne mogą pomóc przewidywać prawdopodobieństwo adopcji konkretnego zwierzęcia oraz zidentyfikować obszary wymagające interwencji (np. grupy zwierząt o podwyższonym ryzyku długotrwałego pobytu). Tym samym, badania łączące dane schronisk z metodami *machine learning* mają istotne znaczenie praktyczne: mogą przyczynić się do optymalizacji pracy schronisk, lepszego alokowania zasobów oraz, co najważniejsze, ratowania większej liczby zwierząt poprzez skracanie czasu oczekiwania na nowy dom i uniknięcie śmierci.

1.2 Cel, hipotezy i pytania badawcze

Celem niniejszej pracy jest opracowanie kompleksowego, zaawansowanego systemu analitycznego wykorzystującego metody uczenia maszynowego do prognozowania adopcji zwierząt na podstawie danych historycznych ze schroniska oraz identyfikacji najważniejszych czynników wpływających na przebieg tych adopcji. W szczególności praca skupia się na oszacowaniu prawdopodobieństwa adopcji oraz czasu oczekiwania na adopcję dla psów i kotów przyjętych do *Austin Animal Center* w latach 2013–2025. Osiągnięcie celu naukowego wymaga zbudowania dokładnego modelu predykcyjnego, ale wyzwaniem może być również zadbanie o jego interpretowalność oraz użyteczność praktyczną dla nietechnicznych użytkowników. Dlatego też celem wdrożeniowym jest implementacja systemu, który integruje powstały model w formie interaktywnej aplikacji (*dashboard*) przeznaczonej dla personelu i wolontariuszy schroniska. System ten ma umożliwiać eksplorację wyników predykcji (np. przewidywanego czasu adopcji danego zwierzęcia) oraz przeprowadzanie analiz typu „co-jeśli” w celu wsparcia decyzji dotyczących działań ukierunkowanych na zwierzęta o obniżonych szansach adopcyjnych.

Równolegle, celem analitycznym niniejszej pracy jest pogłębiona identyfikacja tych cech zwierząt oraz czynników zewnętrznych, które istotnie wpływają na zmniejszenie prawdopodobieństwa adopcji, co może stanowić podstawę do dalszych interwencji, zmian

w działaniach operacyjnych lub kampanii adopcyjnych ukierunkowanych na najbardziej narażone grupy.

Aby zrealizować powyższe cele, sformułowano następujące kluczowe pytania badawcze:

1. **Które zmienne opisujące zwierzę oraz okoliczności jego przyjęcia do schroniska najsilniej wpływają na prawdopodobieństwo szybkiej adopcji?** Jakie cechy (np. wiek, rasa, umaszczenie, płeć, stan zdrowia, typ przyjęcia) wykazują największą moc predykcyjną w kontekście skrócenia lub wydłużenia czasu pobytu zwierzęcia w schronisku?
2. **Jak złożone modele uczenia maszynowego wypadają na tle prostszych metod w zadaniu przewidywania adopcji zwierząt?** Innymi słowy, czy zastosowanie algorytmów klasy *ensemble* (np. gradient boosting w modelach XGBoost/CatBoost) zapewnia wyraźnie lepszą trafność prognoz niż podstawowe podejścia bazowe (takie jak proste modele regresyjne lub losowe strategie decyzji)?
3. **Czy istnieją istotne różnice w wzorcach adopcji między psami a kotami oraz jak te wzorce zmieniały się w czasie?** Pytanie to dotyczy zarówno ewentualnych odmiennych czynników wpływających na adopcje w zależności od gatunku, jak i trendów czasowych (np. czy w kolejnych latach obserwuje się poprawę skuteczności adopcji, zmiany sezonowe itp.).

Mając na uwadze powyższe pytania oraz przegląd literatury przedmiotu, przyjęto również kilka hipotez badawczych, które zostaną zweryfikowane w toku analizy:

- H1:** Sposób, w jaki zwierzę trafia do schroniska (np. jako bezdomna znajda przywieziona przez służby miejskie, czy jako zwierzę oddane bezpośrednio przez właściciela), ma istotniejszy wpływ na prawdopodobieństwo i tempo jego adopcji niż cechy wyglądu. Innymi słowy, zakłada się, że typ przyjęcia (ang. *intake type*) stanowi silniejszy prognostyk sukcesu adopcyjnego niż przynależność do konkretnej rasy.
- H2:** Występuje wyraźny efekt sezonowości w przebiegu adopcji. Pewne okresy w roku (np. miesiące letnie lub okolice przerw świątecznych) sprzyjają szybszym adopcjom, skracając średni czas pobytu zwierząt w schronisku, podczas gdy w innych okresach tempo adopcji spada. Hipoteza ta opiera się na założeniu, że czynniki zewnętrzne (takie jak wakacje, kampanie społeczne czy warunki pogodowe) wpływają na popyt na adopcje.

- H3:** Wiek zwierzęcia ma istotny wpływ na jego szanse adopcyjne – młodsze zwierzęta są adoptowane szybciej niż starsze. Zgodnie z obserwacjami z praktyki schroniskowej, szczenięta i kocięta cieszą się większym zainteresowaniem niż osobniki dorosłe lub starsze.
- H4:** Umaszczenie zwierzęcia wpływa na prawdopodobieństwo adopcji – zwierzęta o ciemnym umaszczeniu (np. czarne psy i koty) są adoptowane rzadziej. Zjawisko to, znane jako *black dog syndrome*, jest często przytaczane w mediach, choć literatura naukowa nie jest w tej kwestii jednogłośna [3]. W ramach pracy zweryfikowane zostanie, czy w danych z AAC zjawisko to jest rzeczywiście obserwowalne.
- H5:** Pandemia COVID-19 miała istotny wpływ na dynamikę adopcji zwierząt – zarówno pod względem liczby adopcji, jak i długości pobytu. Zakłada się, że w okresie pandemicznym (2020–2021) nastąpiły zmiany w wzorcach adopcyjnych, związane m.in. z pracą zdalną, ograniczeniami mobilności oraz kampaniami medialnymi promującymi adopcje.

Powyższe hipotezy zostaną poddane weryfikacji w dalszych rozdziałach pracy. Analiza ich trafności pozwoli nie tylko odpowiedzieć na postawione pytania badawcze, lecz także lepiej zrozumieć dynamikę procesów adopcyjnych. Warto podkreślić, że niniejsza praca ma charakter zarówno badawczy, jak i inżynierski: obejmuje cały cykl projektowy od zrozumienia problemu i postawienia hipotez, poprzez eksplorację i modelowanie danych, aż po implementację działającego prototypu rozwiązania. Dzięki temu możliwe będzie nie tylko wykazanie pewnych zależności teoretycznych, ale również stworzenie narzędzia, które potencjalnie może zostać wykorzystane w praktyce funkcjonowania schroniska.

1.3 Zakres i struktura pracy - możliwe zmiany w trakcie pisania pracy

Zakres analizy obejmuje dane historyczne pochodzące z *Austin Animal Center* z lat 2013–2025, które zawierają informacje zarówno o przyjęciach zwierząt do schroniska (*intake*), jak i o ich dalszych losach (*outcome*, w szczególności adopcjach). Dane te pozwalają prześledzić pełny cykl pobytu zwierzęcia w schronisku – od momentu znalezienia lub oddania, aż do chwili adopcji bądź innego zakończenia opieki. W pracy skoncentrowano się na dwóch dominujących w schronisku gatunkach, tj. psach i kotach, z pominięciem mniej licznych gatunków egzotycznych. Analizy zostały przeprowadzone

oddzielnie dla psów i kotów wszędzie tam, gdzie było to zasadne, aby uchwycić ewentualne różnice między tymi grupami. Pod względem merytorycznym praca łączy zagadnienia z obszaru nauk o danych (data science), uczenia maszynowego oraz inżynierii oprogramowania, co znajduje odzwierciedlenie w strukturze pracy.

Rozdziały niniejszej pracy zostały ułożone w taki sposób, aby stopniowo wprowadzać czytelnika w temat i następnie przejść do szczegółów implementacyjnych rozwiązania. Rozdział 2 przedstawia przegląd literatury oraz teoretyczne podstawy związane z problematyką bezdomności zwierząt i adopcji w kontekście zarządzania schroniskami. Omówiono w nim kluczowe pojęcia (takie jak zasada *No-Kill* czy metryki w pracy schronisk), a także metody analizy danych i algorytmy uczenia maszynowego wykorzystywane dotychczas do rozwiązywania podobnych problemów. Rozdział 3 zawiera opis danych wykorzystanych w badaniu – źródła i charakterystykę zbioru danych z AAC, sposób ich wstępnego przetworzenia oraz analizę eksploracyjną (EDA). Celem tej części jest zrozumienie struktury danych, wstępna identyfikacja trendów i potencjalnych zależności (np. typowe przedziały wiekowe zwierząt, sezonowość przyjęć i adopcji, itp.) oraz przygotowanie odpowiedniego zestawu cech do modelowania.

W Rozdziale 4 przedstawiono metodologię budowy modeli predykcyjnych. Opisano proces doboru cech (*feature engineering*) istotnych z punktu widzenia przewidywania adopcji, a także wybrane algorytmy uczenia maszynowego. Szczególną uwagę poświęcono modelom typu *gradient boosting*, takim jak XGBoost i CatBoost, ze względu na ich wysoką skuteczność w zadaniach z danymi tabelarycznymi. Omówiono też konfigurację tych modeli, strategie walidacji krzyżowej oraz metryki oceny, które posłużą do porównania ich z prostszymi modelami bazowymi. Rozdział 5 prezentuje uzyskane wyniki eksperymentów. Przedstawiono w nim porównanie jakości predykcji różnych modeli (m.in. porównanie modeli gradient boosting z modelami liniowymi) oraz analizę interpretowalności najlepszego modelu. Wykorzystano do tego techniki objaśniania decyzji czarnej skrzynki, w szczególności wartości SHAP (*Shapley Additive Explanations*), które pozwalają określić wpływ poszczególnych cech (np. wieku, rasy, typu intaku) na przewidywane prawdopodobieństwo adopcji. Taka analiza dostarcza cennych informacji, czy model podejmuje decyzje w sposób zgodny z intuicją i wiedzą dziedzinową (np. czy potwierdza, że młode zwierzęta adoptowane są szybciej), a także może ujawnić nieoczywiste zależności w danych.

Rozdział 6 koncentruje się na aspekcie inżynierskim rozwiązania, opisując zastosowane podejście *MLOps* do zapewnienia powtarzalności i niezawodności procesu analitycznego. W rozdziale tym omówiono, w jaki sposób stworzony model i towarzyszący

mu kod zostały zintegrowane w ramach tzw. potoku przetwarzania (*pipeline*) obejmującego: wersjonowanie danych i eksperymentów z użyciem narzędzia DVC (*Data Version Control*), konteneryzację środowiska i zależności za pomocą Dockera, oraz automatyzację trenowania i wdrażania modelu z wykorzystaniem ciągłej integracji i dostarczania (CI/CD, np. na platformie GitHub Actions). Rozdział 7 przedstawia zaprojektowaną aplikację internetową (dashboard) służącą jako interfejs użytkownika dla opracowanego modelu. Opisano funkcjonalności prototypowej aplikacji stworzonej w technologii *Streamlit* – m.in. możliwość sprawdzania prognoz dla wybranego zwierzęcia, symulacji scenariuszy (np. jak zmiana pewnych cech wpływa na przewidywane szanse adopcji), czy przegląd globalnych statystyk i trendów. Rozdział ten ukazuje, jak wyniki zaawansowanej analizy danych mogą zostać opakowane w przystępne narzędzie wspierające codzienną pracę schroniska. Wreszcie, Rozdział 8 to podsumowanie uzyskanych wyników oraz wnioski. Zawarto w nim omówienie stopnia realizacji celu pracy, weryfikację hipotez w świetle przeprowadzonych analiz oraz rekomendacje dotyczące wdrożenia wypracowanych rozwiązań w praktyce. Przedstawiono także propozycje dalszych kierunków rozwoju – zarówno jeśli chodzi o ulepszenia modelu (np. uwzględnienie dodatkowych danych lub zastosowanie alternatywnych technik uczenia), jak i rozszerzenie funkcjonalności systemu dla schroniska.

Niniejsza praca stanowi zatem połączenie badań nad danymi schroniska z praktycznym wdrożeniem rozwiązania informatycznego. Wkład własny autora istnieje w warstwie analitycznej, jak i inżynierskiej. Od strony analitycznej obejmuje on przygotowanie i oczyszczenie zbioru danych, przeprowadzenie eksploracji w celu sformułowania hipotez, a następnie zaprojektowanie i wytrenowanie modeli predykcyjnych dostosowanych do specyfiki danych AAC. Od strony inżynierskiej, istotnym elementem pracy jest zaprojektowanie i zaimplementowanie kompletnego procesu MLOps. Obejmuje to m.in.: zautomatyzowanie procesu trenowania modelu i aktualizacji prognoz, wprowadzenie kontroli wersji dla danych i modeli (co zapewnia odtwarzalność wyników), konteneryzację aplikacji dla ułatwienia jej uruchomienia na dowolnej platformie, oraz integrację tych komponentów w ramach ciągłej integracji/dostarczania. Dodatkowo, autor stworzył aplikację webową, która udostępnia wyniki modeli szerszemu gronu odbiorców w intuicyjnej formie. Dzięki temu podejściu, praca nie tylko odpowiada na postawione pytania badawcze, ale również dostarcza narzędzia mogącego znaleźć praktyczne zastosowanie w poprawie efektywności działania schronisk dla zwierząt.

Rozdział 2

Podstawy teoretyczne i przegląd literatury

2.1 Problem bezdomności zwierząt i filozofia No-Kill

Zjawisko bezdomności zwierząt to poważny problem społeczny i ekologiczny na całym świecie. Szacuje się, że globalna populacja bezdomnych psów i kotów liczona jest w setkach milionów [4]. Szczególnie dotkliwie problem ten występuje w Stanach Zjednoczonych, gdzie każdego roku do schronisk trafia ponad 6 milionów porzuconych lub bezdomnych zwierząt domowych. Historycznie wysoki odsetek z nich był poddawany eutanazji z braku miejsc i możliwości adopcji – jeszcze kilkanaście lat temu uśmiercano miliony psów i kotów rocznie, co stanowiło znaczną część wszystkich przyjmowanych zwierząt [5].

W ostatnich latach, dzięki upowszechnieniu sterylizacji, licznym kampaniom adopcyjnym oraz zmianie podejścia do zarządzania schroniskami, sytuacja zaczęła się stopniowo poprawiać. Obecnie do amerykańskich schronisk wchodzi rocznie ok. 6,3 mln zwierząt, a liczba eutanazji znacząco spadła w porównaniu do dekady ubiegłej [1]. Trend ten odzwierciedla globalny zwrot w kierunku bardziej humanitarnego traktowania bezdomnych zwierząt, którego centralnym elementem jest filozofia *No-Kill*.

Filozofia *No-Kill* zakłada rezygnację z rutynowej eutanazji zwierząt w schronisku *wyłącznie z powodu braku miejsc* – wszystkie zdrowe lub rokujące na wyleczenie zwierzęta powinny pozostać przy życiu i oczekiwać na adopcję tak długo, jak będzie to konieczne. W praktyce za schronisko *no-kill* uznaje się placówkę osiągającą co najmniej 90% tzw. współczynnika ocalenia (ang. *save rate*), czyli odsetka zwierząt opuszczających schronisko

żywych [2]. Takie podejście wymaga wdrożenia szeregu strategii zwiększających liczbę udanych adopcji oraz zmniejszających napływ nowych zwierząt do systemu (m.in. programy sterylizacji, rozbudowa wolontariatu).

Przykładem skutecznej realizacji idei No-Kill jest miasto Austin w Teksasie. W 2010 r. władze Austin przyjęły kompleksowy plan działań, którego celem było osiągnięcie statusu no-kill, a już w kolejnym roku miejskie schronisko Austin Animal Center przekroczyło próg 90% uratowanych zwierząt [2]. Od tego czasu Austin utrzymuje reputację największego miasta *No-Kill* w USA. Sukces ten zainspirował wiele innych społeczności – w ostatnich latach odsetek amerykańskich schronisk deklarujących status no-kill znacząco wzrósł [1]. Należy jednak podkreślić, że status ten nie oznacza całkowitego wyeliminowania eutanazji: nadal uśmiercane są zwierzęta poważnie chore lub niebezpieczne, lecz nie dopuszcza się uśpienia zdrowego zwierzęcia z powodów ekonomicznych.

Dane gromadzone w schroniskach stanowią cenne źródło informacji do oceny efektywności adopcji. Większość schronisk prowadzi szczegółową ewidencję przyjęć (ang. *intake*) i opuszczeń (ang. *outcome*) zwierząt, co pozwala śledzić m.in. czas pobytu (*length of stay*), stan zdrowia, rasę czy wiek. Analiza takich danych umożliwia wyliczenie kluczowych mierników operacyjnych i zastosowanie zaawansowanych metod analitycznych w celu **predykcji** wyników adopcji. Przykładowo, badania wskazują, że cechy takie jak wiek czy wielkość zwierzęcia istotnie wpływają na tempo jego adopcji – szczenięta znajdują domy szybciej niż psy starsze, a zwierzęta o umaszczeniu odbiegającym od preferowanego mogą oczekiwać na adopcję dłużej [5].

2.2 Predykcyjne modelowanie adopcji

Wyzwania związane z poprawą wskaźników adopcji przyczyniły się do rosnącego zainteresowania metodami predykcyjnymi. Modelowanie to polega na wykorzystaniu metod statystycznych oraz algorytmów uczenia maszynowego do przewidywania, czy i kiedy dane zwierzę zostanie adoptowane. Modele uczą się na danych historycznych w celu uchwycenia zależności między cechami zwierzęcia a wynikiem adopcyjnym [6].

Do najprostszych metod predykcji należą modele statystyczne, w tym regresja logistyczna. Umożliwia ona oszacowanie prawdopodobieństwa adopcji na podstawie zmiennych takich jak wiek, płeć czy rasa. Choć regresja cechuje się wysoką interpretowalnością, ma ograniczoną zdolność chwytania nieliniowych zależności. Dlatego coraz

częściej sięga się po metody o większej mocy predykcyjnej, takie jak zespoły drzew decyzyjnych (np. lasy losowe) czy algorytm z rodziny *gradient boosting*.

Najbardziej rozpowszechnionym algorytmem tego typu jest XGBoost (Extreme Gradient Boosting), wyróżniający się wydajnością w zadaniach klasyfikacyjnych [7]. W ostatnich latach popularność zyskał również CatBoost – biblioteka zoptymalizowana do przetwarzania cech kategorycznych [8]. W kontekście danych schronisk, które obfitują w atrybuty kategoryczne (rasa, umaszczenie, typ przyjęcia), modele te okazują się szczególnie skuteczne. Badania z wykorzystaniem danych schroniskowych, m.in. praca Sazary i in. (2022), wykazały, że zaawansowane modele klasyfikacyjne potrafią z dużą dokładnością przewidywać szybkość adopcji, identyfikując wiek i rasę jako kluczowe predyktory sukcesu [6].

Istotnym elementem projektowania modeli jest także ocena **istotności cech** oraz interpretowalność. Złożone modele zespołowe działają często jak „czarne skrzynki”. Aby zrozumieć ich decyzje, stosuje się metody takie jak SHAP (*Shapley Additive Explanations*) [9]. Metoda ta pozwala określić, w jaki sposób konkretna cecha (np. czarne umaszczenie) wpływa na obniżenie lub podwyższenie prawdopodobieństwa adopcji dla danego zwierzęcia.

2.3 Reprodukowalność i inżynieria danych (MLOps) - in progress

Wraz z rozwojem projektów z zakresu sztucznej inteligencji pojawiła się potrzeba wypracowania praktyk zapewniających reprodukowalność badań. Odpowiedzią na te wyzwania jest podejście MLOps (*Machine Learning Operations*), które integruje proces projektowania modeli z ich wdrażaniem i utrzymaniem [10].

Jednym z filarów MLOps jest zagwarantowanie spójnego środowiska uruchomieniowego. Służy do tego konteneryzacja, najczęściej realizowana z użyciem technologii Docker. Zapewnia ona, że kod trenujący model będzie działał identycznie niezależnie od środowiska, co jest kluczowe dla reprodukowalności badań naukowych [11].

Kolejnym ważnym elementem jest wersjonowanie danych. W przeciwieństwie do kodu, duże zbiory danych nie nadają się do przechowywania w systemie Git. Dlatego w niniejszej pracy wykorzystano narzędzie DVC (*Data Version Control*), które umożliwia śledzenie zmian w zbiorach danych i modelach, zapewniając pełną historię eksperymentów [12]. Ostatnim etapem jest prezentacja wyników, zrealizowana w tej pracy za pomocą biblioteki Streamlit, pozwalającej na tworzenie interaktywnych wizualizacji danych [13].

Rozdział 3

Dane i przygotowanie zbioru badawczego

W niniejszym rozdziale opisano proces przygotowania zbioru danych do analizy statystycznej. Jednostką obserwacji w badaniu jest epizod pobytu zwierzęcia w schronisku, rozumiany jako pojedyncze przyjęcie, przypisany do niego wynik kończący pobyt oraz zestaw cech znanych w momencie przyjęcia, czyli cech *intake-time-only*. W rozdziale przedstawiono kolejne etapy przekształcania danych surowych do postaci analitycznej.

3.1 Źródło danych i zakres analizy

Materiał empiryczny pochodzi ze schroniska Austin Animal Center (AAC) i został pobrany z bazy Austin Open Data. Baza obejmuje dwie tabele: rejestr przyjęć zwierząt (*intakes*) oraz rejestr wyników kończących pobyt (*outcomes*). Opcjonalnie dane wzbogacono o zmienne kontekstowe, takie jak pogoda.

Zakres czasowy badania obejmuje przyjęcia od 1 października 2013 roku do 4 maja 2025 roku. Analizę ograniczono do psów i kotów, ponieważ stanowią one zasadniczą część populacji schroniskowej. Uwzględnienie rzadziej występujących gatunków, na przykład dzikich zwierząt, mogłoby obniżyć stabilność estymacji.

Wykorzystane dane mają charakter obserwacyjny. Pochodzą z rutynowej dokumentacji schroniska, a nie z kontrolowanego eksperymentu. Z tego powodu analiza obejmuje wyłącznie relacje statystyczne między atrybutami zwierzęcia znanymi w momencie przyjęcia a wynikiem pobytu. Nie formułuje się na tej podstawie wniosków przyczynowo-skutkowych.

3.2 Charakterystyka zbiorów wejściowych

Zbiór analityczny łączy dane o przyjęciu z danymi o wyniku końcowym. Rozdzielenie tych warstw na etapie modelowania pozwala ograniczyć ryzyko wykorzystania informacji z przeszłości, czyli wycieku danych.

Tabela 3.1: Porównanie dwóch podstawowych zbiorów wejściowych

Warstwa danych	Przykładowe pola kluczowe	Rola w procesie
Rejestr przyjęć	animal_id, animal_type, intake_datetime, intake_type, intake_condition, sex_upon_intake, age_upon_intake, breed, color	Źródło atrybutów wejściowych (X)
Rejestr wyników	animal_id, animal_type, outcome_datetime, outcome_type, outcome_subtype, sex_upon_outcome	Źródło zmiennej docelowej (y)

Metadane generowane na końcu pobytu, takie jak `outcome_type` i `outcome_datetime`, wyodrębniono jako zmienne docelowe. Podział ten zapisano w oddzielnych plikach konfiguracyjnych JSON dla cech oraz targetów.

3.3 Standaryzacja i czyszczenie danych

Czyszczenie danych przeprowadzono ostrożnie, bez sztucznej imputacji braków. Nazwy zmiennych zapisano w formacie `snake_case`. Daty ujednolicono do lokalnej strefy czasowej schroniska, konwertując ciągi znaków do formatu `datetime64`.

Sprawdzono kompletność kluczowych atrybutów: `animal_id`, `animal_type`, `intake_datetime`, `outcome_datetime` oraz `outcome_type`. Obserwacje z brakami w tych polach usunięto. Dokładne duplikaty rekordów zostały odfiltrowane.

Tabela 3.2: Atrycja danych w procesie budowy finalnego zbioru modelowego

Zbiór danych na danym etapie	Liczba wierszy	Liczba usuniętych
Zbiór źródłowy wejść (<code>intakes.csv</code>)	173 812	—
Zbiór źródłowy wyjść (<code>outcomes.csv</code>)	173 775	—
Standaryzacja i filtracja wejść	163 901	9 911
Standaryzacja i filtracja wyjść	163 880	9 895
Dopasowane epizody z targetem	162 390	1 511
Finalny zbiór modelowy	162 390	0

Większość usuniętych rekordów dotyczyła zwierząt innych niż psy i koty. Usunięto również 1 511 przyjęć pozbawionych chronologicznie poprawnego wyniku końcowego.

W modelowaniu nadzorowanym potraktowano je jako obserwacje bez dostępnej etykiety docelowej i wykluczono z finalnego zbioru; w ujęciu analizy przeżycia mogłyby być one rozważane jako obserwacje cenzorowane. Brakujące dane w atrybutach predykcyjnych występowały pojedynczo: odnotowano 9 braków wieku i 1 brak płci.

3.4 Konstrukcja epizodów i dopasowanie rekordów

Jednostką analizy jest epizod pobytu. Ponieważ to samo zwierzę (`animal_id`) może być kilkakrotnie rejestrowane w schronisku, każde przyjęcie połączono z najbliższym w czasie, niewykorzystanym wcześniej wynikiem. Zastosowano więc metodę najbliższego wolnego zdarzenia w czasie, aby odtworzyć możliwie spójną historię pobytu.

Taka procedura zapobiega powstawaniu ujemnych czasów pobytu oraz wielokrotnemu przypisaniu tego samego wyniku do różnych przyjęć. Audyt zbioru potwierdził poprawność łączenia — nie odnotowano epizodów nakładających się w czasie.

3.5 Zmienne docelowe

Zdefiniowano dwie główne zmienne docelowe przeznaczone do późniejszego modelowania:

Tabela 3.3: Formalne definicje zmiennych docelowych

Zmienna	Definicja	Interpretacja
<code>classification_target</code>	1 dla <code>Adoption</code> , 0 dla innych	Binarny wynik adopcji
<code>regression_target_days</code>	$(outcome_time - intake_time) \div 86400$	Całkowita długość pobytu (dni)
<code>days_to_adoption</code>	Wartość <code>regression_target_days</code> dla adoptowanych	Długość pobytu do adopcji

Adopcją zakończyło się 50,87% uwzględnionych epizodów, czyli 82 609 przypadków. Pozostałe 49,13% obejmuje powroty do właściciela, transfery, eutanazję oraz zgony. Czas do dowolnego zdarzenia potraktowano jako klasyczny problem regresji, ponieważ długość zajmowania boksu przekłada się bezpośrednio na koszty operacyjne placówki.

3.6 Konstrukcja cech wejściowych

Cechy wejściowe zbudowano wyłącznie na podstawie informacji dostępnych w chwili przyjęcia.

Tabela 3.4: Grupy cech wejściowych

Grupa	Zmienne
Cechy ogólne	animal_type, sex_upon_intake, intake_condition
Wiek	age_days, age_years, age_group (np. baby, senior)
Rasa	breed, primary_breed, simplified_breed_group
Umaszczenie	color, primary_color, simplified_color_group
Kontekst przyjęcia	intake_season, intake_type, covid_period

Aby ograniczyć liczbę kategorii, rasy i umaszczenia pogrupowano w szersze klasy, takie jak `pit_bull_type`, `terrier_type` czy `domestic_cat`. Oryginalna zmienna opisująca rasę zawierała 2 761 unikalnych wartości, z których większość występowała bardzo rzadko.

Na podstawie daty przyjęcia zdefiniowano okresy związane z pandemią: przed COVID-19, czyli do 1 marca 2020 r.; w trakcie pandemii, od marca 2020 do grudnia 2021; oraz po pandemii, od 1 stycznia 2022 r. Wiek przekształcono z wartości tekstowych, na przykład `2 years`, do postaci w pełni numerycznej w dniach oraz do kategorii wiekowych.

Cechy wejściowe dodatkowo przebadano pod kątem współliniowości, czyli multikolinearności. W tym celu zastosowano analizę wskaźnika VIF (*Variance Inflation Factor*), aby sprawdzić, czy modele oparte na założeniach addytywnych, takie jak regresja logistyczna, nie będą zniekształcone przez redundantne informacje, na przykład silne skorelowanie wieku w dniach z wiekiem w latach. Zmienne o krytycznie wysokim współczynniku VIF usunięto na wczesnym etapie selekcji cech.

3.7 Charakterystyka opisowa zbioru

Zbiór obejmujący 162 390 pobyków pozwala przedstawić podstawowe statystyki opisowe. Najważniejsze wskaźniki zmieniały się w czasie:

- **Przed COVID-19 (108 812 epizodów):** wskaźnik adopcji wynosił 46,3%, a mediana całkowitej długości pobytu, liczona dla każdego wyniku, była równa 5,25 dnia.
- **COVID-19 (17 947 epizodów):** wskaźnik adopcji wzrósł do 57,2%, a mediana pobytu do 8,01 dnia.

- **Post COVID-19 (35 631 epizodów):** wskaźnik adopcji wyniósł 61,5%, a mediana pobytu 9,83 dnia.

Zmiany te zbiegają się ze zmianą struktury przyjmowanych zwierząt. Odsetek psów spadł z 60,45% w okresie przedpandemicznym do 50,64%. Jednocześnie odsetek młodych zwierząt (baby) wzrósł z 44,11% do 54,34%.

Psy i koty różnią się pod względem dynamiki adopcji. Ogólny wskaźnik adopcji był zbliżony dla obu grup: 50,28% dla psów i 51,68% dla kotów. Wśród zwierząt adoptowanych do 30 dni schronisko opuszcza jednak 73,6% psów i 54,5% kotów.

Prawdopodobieństwo adopcji maleje wraz z wiekiem zwierzęcia. Grupa najmłodsza (baby) charakteryzuje się wskaźnikiem adopcji na poziomie 59,7%, młodzież (young) — 47,5%, zwierzęta dorosłe (adult) — 39,6%, a starsze (senior) — 31,0%.

Sposób przyjęcia również wiąże się ze znaczną zmiennością wyników. Wśród 116 393 zwierząt znalezionych na ulicy (Stray) adopcją zakończyło się 48,7% pobytów. Natomiast wśród 34 142 zrzeczeń właścicielskich (Owner Surrender) wskaźnik ten wyniósł 67,1%.

3.8 Ograniczenia danych

Wykorzystany zbiór danych ma kilka ograniczeń.

Po pierwsze, pochodzi z placówki no-kill, czyli schroniska utrzymującego wysoki współczynnik uratowań i niestosującego rutynowej eutanazji zdrowych zwierząt [2]. Wyniki mogą więc różnić się od wyników uzyskanych dla schronisk o innej specyfice działania.

Po drugie, wpisy dotyczące rasy i umaszczenia są deklaracją pracownika dokonaną przy przyjęciu, a nie wynikiem badań genetycznych. Etykiety takie jak `pit_bull_type` odzwierciedlają administracyjny sposób kategoryzacji psów oraz ludzką percepcję ich wyglądu.

Ograniczeniem technicznym było wykluczenie pobytów bez jednoznacznie zakończonego wyniku, co wynika z wymogu posiadania etykiety docelowej w nadzorowanym uczeniu maszynowym.

3.9 Podsumowanie przygotowania danych

W wyniku opisanych przekształceń utworzono finalny zbiór modelowy obejmujący 162 390 epizodów pobytu psów i kotów w Austin Animal Center. Każdy rekord

reprezentuje pojedyncze przyjęcie zwierzęcia, zestaw cech znanych w momencie tego przyjęcia oraz chronologicznie dopasowany wynik końcowy. Taka konstrukcja pozwala analizować proces pobytu z perspektywy informacji dostępnych przed rozstrzygnięciem sprawy zwierzęcia, a jednocześnie ogranicza ryzyko wycieku danych z przyszłości.

Najważniejszymi decyzjami przygotowawczymi były: ograniczenie populacji do psów i kotów, usunięcie rekordów bez podstawowych znaczników czasu i wyniku, dopasowanie przyjęć do najbliższych niewykorzystanych wyników oraz przekształcenie zmiennych opisowych do postaci możliwej do wykorzystania przez modele statystyczne. Szczególną uwagę zwrócono na zmienne, które mogą być dostępne dopiero po zakończeniu pobytu, ponieważ ich użycie prowadziło do sztucznego zawyżenia jakości predykcji.

Przygotowany zbiór stanowi podstawę dwóch zadań empirycznych rozwijanych w kolejnych rozdziałach: klasyfikacji prawdopodobieństwa adopcji oraz regresji długości pobytu do dowolnego dopasowanego wyniku. Rozdział następny opisuje metodykę modelowania, sposób podziału danych w czasie, dobór algorytmów oraz metryki użyte do oceny uzyskanych modeli.

Rozdział 4

Metodyka modelowania i oceny modeli

W rozdziale przedstawiono metodykę budowy i oceny modeli predykcyjnych. Problem badawczy sformułowano jako dwa odrębne zadania: klasyfikację binarną, czyli przewidywanie adopcji względem innych wyników, oraz regresję, czyli przewidywanie liczby dni do zakończenia pobytu. Zrezygnowano z analizy przeżycia (ang. *survival analysis*) na rzecz prognozowania całkowitej długości pobytu (ang. *length of stay*). W rozdziale opisano podział zbioru, dobór algorytmów uczących oraz zastosowane metryki oceny. Omówiono również interpretację wyników z wykorzystaniem wartości SHAP oraz protokół badawczy służący zapewnieniu odtwarzalności obliczeń.

Tabela 4.1: Etapy procesu modelowania i oceny

Etap badawczy	Działanie
1. Przygotowanie cech	Wykorzystanie zbioru zdefiniowanego w rozdziale 3. Wykluczenie atrybutów rejestrowanych po przyjęciu w celu uniknięcia wycieku informacji (ang. <i>data leakage</i>).
2. Podział danych	Podział chronologiczny: zbiór treningowy (2013–2021), walidacyjny (2022–2023) oraz testowy (2024–2025).
3. Uczenie modeli	Trenowanie modeli bazowych i zespołowych osobno dla klasyfikacji i regresji.
4. Ocena modeli	Ocena klasyfikacji za pomocą AUC-ROC, AUC-PR, F1-Score oraz regresji za pomocą MAE, RMSE i MedAE.
5. Interpretacja	Analiza wyjaśnień globalnych i lokalnych za pomocą SHAP oraz wpływ zdefiniowanych Rodzin Cech.
6. Reprodukowalność	Deterministyczna inicjalizacja algorytmów (<code>random_state=42</code>) oraz statyczny zapis wyników.

4.1 Cel modelowania

Celem modelowania predykcyjnego jest prognozowanie wyników wyłącznie na podstawie informacji dostępnych w momencie przyjęcia zwierzęcia do schroniska. Analiza koncentruje się na mocy predykcyjnej modeli, a nie na wnioskowaniu przyczynowo-skutkowym.

Modele mają określić, w jakim stopniu atrybuty takie jak gatunek, kategoria wiekowa czy okoliczności przyjęcia pozwalają przewidzieć dwie wartości: (1) prawdopodobieństwo adopcji zwierzęcia oraz (2) całkowity czas zajmowania miejsca w schronisku do momentu zakończenia pobytu, na przykład adopcji, transferu lub powrotu do właściciela. Takie podejście dostarcza prognoz, które mogą być przydatne w zarządzaniu placówką, ponieważ czas pobytu każdego zwierzęcia wiąże się z kosztami operacyjnymi.

4.2 Formalne sformułowanie problemu

Modele uczono dla dwóch zadań:

1. **Klasyfikacja binarna (`classification_target`):** zmienna objaśniana $Y^{(kl)} \in \{0, 1\}$, gdzie $Y^{(kl)} = 1$ oznacza adopcję, a $Y^{(kl)} = 0$ inny wynik końcowy. Szacowane jest prawdopodobieństwo adopcji $P(Y^{(kl)} = 1 | X)$.
2. **Regresja długości pobytu (`regression_target_days`):** zmienna ciągła wyrażona w dobach, reprezentująca czas do zdarzenia kończącego pobyt. Model estymuje wartość oczekiwaną długości trwania epizodu $E(T | X)$.

Nie zastosowano modeli analizy przeżycia, takich jak model proporcjonalnych hazardów Coxa czy Random Survival Forest. Wymagałoby to bardziej złożonej estymacji w obecności cenzurowania prawostronnego. Uczenie predykcyjne zdefiniowano jako klasyczną regresję na zamkniętych pobytach, dla których długość pobytu można zmierzyć bezpośrednio.

Zbiór predyktorów X nie zawiera cech będących składową wyniku końcowego.

4.3 Przygotowanie danych i podział chronologiczny

Dane mają charakter czasowy, dlatego zrezygnowano z klasycznej walidacji krzyżowej (ang. *k-fold cross-validation*) z tasowaniem próbek. Celem było uniknięcie wycieku informacji. Uczenie modelu na późniejszych rocznikach i testowanie go na

wcześniejszych mogłoby zawyżyć ocenę skuteczności, ponieważ model korzystałby pośrednio z późniejszych wzorców.

Zbiór 162 390 epizodów podzielono chronologicznie na trzy części:

- **Zbiór treningowy:** lata 2013–2021. Pula obejmująca 126 759 rekordów psów i kotów.
- **Zbiór walidacyjny:** lata 2022–2023. Obejmuje 21 811 epizodów. Przeznaczony do doboru parametrów modeli i wskaźników odcięcia.
- **Zbiór testowy:** lata 2024–2025. Obejmuje 13 820 epizodów. Służy wyłącznie do ostatecznej oceny najlepszych algorytmów na najnowszych danych.

Taki podział pozwala ocenić odporność modelu na zmiany wzorców w czasie (ang. *concept drift*), zwłaszcza w okresie po pandemii COVID-19.

4.4 Algorytmy predykcyjne

W badaniu porównano proste modele odniesienia z bardziej zaawansowanymi algorytmami zespołowymi. Pozwala to ocenić, czy zastosowanie bardziej złożonych metod poprawia jakość predykcji.

Modele bazowe:

- **Modele odniesienia (Dummy):** przewidują klasę większościową w klasyfikacji lub medianę w regresji. Wyznaczają minimalny poziom odniesienia dla oceny błędu w ujęciu deterministycznym.
- **Modele liniowe:** regresja logistyczna dla binarnej zmiennej celu oraz regresja grzbietowa (Ridge) dla regresji długości pobytu. Zapewniają stabilność wyników i umożliwiają stosunkowo prostą analizę wag atrybutów.

Modele zaawansowane (drzewa decyzyjne):

- **Lasy Losowe (Random Forest):** model zespołowy ograniczający wariancję przez uśrednianie prognoz.
- **Histogram-based Gradient Boosting:** wariant sekwencyjnego uczenia na błędach, wykorzystujący kubełkowanie zmiennych numerycznych w celu skrócenia czasu uczenia na dużych zbiorach.

- **CatBoost:** architektura z rodziny wzmacniania gradientowego (ang. *Gradient Boosting*). Zawiera mechanizmy przetwarzania zmiennych kategorycznych bez konieczności sztucznej wektoryzacji (*one-hot encoding*). Z tego powodu dobrze nadaje się do danych zawierających setki nominalnych wartości ras i umaszczeń zwierząt.

Dla danych tabelarycznych z dużą liczbą zmiennych kategorycznych wybrano modele oparte na drzewach decyzyjnych (*gradient boosting*). Decyzja ta wynika z tego, że algorytmy te są często uznawane za jeden ze standardów dla tego typu danych (ang. *state-of-the-art*). W przeciwieństwie do modeli liniowych, dobrze wychwytyją nieliniowe interakcje między zmiennymi, na przykład specyficzny wpływ wieku tylko u konkretnej rasy psów, i nie wymagają rygorystycznego skalowania danych numerycznych.

Zrezygnowano z zastosowania głębokich sieci neuronowych (ang. *Deep Learning*). Literatura badawcza i praktyka inżynierska wskazują, że sieci neuronowe często nie poprawiają jakości estymacji na niejednorodnych zbiorach tabelarycznych w porównaniu z algorytmami z rodziny *gradient boosting*. Jednocześnie wymagają większych zasobów obliczeniowych i ograniczają łatwość interpretacji wyników, co określa się często jako problem czarnej skrzynki.

W procesie strojenia modeli, szczególnie CatBoost, przyjęto zachowawczą strategię doboru hiperparametrów, aby ograniczyć ryzyko przeuczenia (ang. *overfitting*). Zastosowano umiarkowaną głębokość drzew decyzyjnych (`depth=6`), co ogranicza zapamiętywanie szumu z danych treningowych, oraz niski współczynnik uczenia (`learning_rate=0.05`), pozwalający na stopniową i stabilną zbieżność algorytmu w trakcie 1000 iteracji. Dodatkowym mechanizmem kontrolnym było wczesne zatrzymywanie (`early_stopping_rounds=50`), które automatycznie przerywało proces uczenia, gdy metryka na zbiorze walidacyjnym przestawała się poprawiać.

4.5 Metryki oceny

Zastosowano następujące metryki oceny:

Zadanie klasyfikacji:

- **AUC-ROC (Area Under the Receiver Operating Characteristic Curve):** miara ogólnej zdolności modelu do rozróżniania klas. Wartość 1.0 oznacza idealne rozróżnianie, a 0.5 prognozę losową.

- **AUC-PR (Area Under the Precision-Recall Curve):** metryka przydatna przy niewielkiej nierównowadze klas, opisująca skuteczność wykrywania kluczowej klasy.
- **F1-Score, precyzja (Precision) i czułość (Recall):** miary punktowe zależne od wyboru progu odcięcia (ang. *threshold*). W metodyce pracy zrezygnowano z naiwnego wyboru progu 0.5. Optymalny próg decyzyjny dla każdego algorytmu został dobrany na niezależnym zbiorze walidacyjnym pod kątem maksymalizacji wskaźnika F1, a następnie zastosowany na zbiorze testowym w celu ewaluacji.
- **Ocena kalibracji (Brier Score):** zdolność modelu do rozróżniania klas, czyli wysokie AUC, nie oznacza jeszcze, że generowane przez niego prawdopodobieństwa odpowiadają rzeczywistemu prawdopodobieństwu sukcesu. W celu oceny kalibracji wygenerowano wykresy kalibracyjne oraz zastosowano punktację Brier Score. Miara ta oblicza średni błąd średniokwadratowy prognozowanego prawdopodobieństwa względem rzeczywistego wyniku. Jest to ważne z punktu widzenia budowy wiarygodnego narzędzia analitycznego dla personelu schroniska.

Zadanie regresji:

- **MAE (Mean Absolute Error):** średni błąd bezwzględny, mierzony w dniach. Jest to główna metryka oceniająca przeciętną pomyłkę modelu.
- **MedAE (Median Absolute Error):** mediana błędów bezwzględnych. Jest to metryka odporna na błędy skrajne, na przykład przypadki zwierząt pozostających w schronisku latami.
- **RMSE (Root Mean Square Error):** pierwiastek błędu średniokwadratowego. Metryka silniej penalizuje największe pomyłki modelu.

4.6 Interpretowalność (SHAP)

Wyniki modeli predykcyjnych w kontekście schroniskowym i weterynaryjnym powinny być możliwie przejrzyste. Do analizy wpływu poszczególnych cech wykorzystano wartości SHAP (ang. *SHapley Additive exPlanations*).

Metoda ta wywodzi się z kooperatywnej teorii gier i pozwala oszacować wkład poszczególnych atrybutów w końcową prognozę modelu.

1. **Wyjaśnienia globalne (SHAP Summary):** zestawienie pokazujące średni wpływ cech na decyzje modelu w całym zbiorze, na przykład związek młodego wieku z wyższym prawdopodobieństwem adopcji.
2. **Wyjaśnienia lokalne:** ocena znaczenia atrybutów w konkretnym pojedynczym epizodzie. Funkcja ta rozkłada prognozę na czynniki zwiększające lub zmniejszające końcowy wynik.
3. **Analiza Rodzin Cech:** atrybuty pogrupowano w „Rodziny Cech”, na przykład Wiek, Wygląd i Kontekst. Takie podejście umożliwia odrzucenie lub zachowanie wybranych grup zmiennych oraz sprawdzenie ogólnego spadku celności bez konieczności osobnego analizowania wpływu pojedynczych wektorów.

4.7 Protokół eksperymentu

W celu zapewnienia odtwarzalności eksperymentu zastosowano następujące zasady:

1. **Jednolite ziarno losowości:** ustalono deterministyczne ziarno liczb pseudolosowych (`random_state=42`) dla algorytmów.
2. **Rozdzielenie obliczeń i wizualizacji:** proces uczenia odbywa się poprzez dedykowany skrypt (`scripts/run_full_pipeline.py`).
3. **Zapis modeli:** wyniki modelowania i metadane ewaluacyjne zapisywane są bezpośrednio na dysk jako estymatory `.joblib` oraz tabele `.csv`. Interfejs analityczny jedynie odczytuje zapisane parametry, bez konieczności kosztownego ponownego uczenia modeli.

4.8 Ograniczenia

Zastosowane modele mają kilka ograniczeń. Głównym ograniczeniem technicznym było wykluczenie pobytów nieukończonych w momencie pobrania bazy, czyli obserwacji objętych cenzorowaniem prawostronnym. Było to konieczne do przeprowadzenia wariantu regresji długości pobytu.

Ponadto modele odzwierciedlają statystyczne uwarunkowania lokalnego rynku w określonym przedziale czasu, szczególnie zasady działania AAC jako schroniska no-kill o wskaźniku przeżycia powyżej 90%. Prawidłowości przypisane na przykład do etykiet rasy mogą zależeć od lokalnej struktury społecznej i sposobu postrzegania zwierząt. Ich

bezpośrednie przeniesienie do innych schronisk bez ponownego trenowania lub kalibracji mogłoby obniżyć skuteczność predykcijną.

Rozdział 5

Wyniki badań i interpretacja modeli

5.1 Ramy interpretacyjne rozdziału


Ten rozdział zbiera wyniki po dwóch wcześniejszych etapach pracy: przygotowaniu danych i opisanu metod. Punktem wyjścia jest 162 390 dopasowanych epizodów pobytu (przyjęcie–wynik) psów i kotów. Modele oceniano w porządku chronologicznym, a nie po losowym przemieszaniu rekordów: lata 2013–2021 posłużyły do uczenia, lata 2022–2023 do walidacji i ustawiania progów decyzyjnych, natomiast lata 2024–2025 do jednego, końcowego testu. Takie ustawienie jest bardziej wymagające, ale lepiej przypomina sytuację, w której model ma pracować na danych z przyszłości.

Wyniki trzeba czytać z podziałem na dwa osobne zadania. Klasyfikacja odpowiada na pytanie o prawdopodobieństwo adopcji. Regresja szacuje liczbę dni do *dowolnego* dopasowanego wyniku pobytu, a więc nie jest prostą miarą „szybkości adopcji”. W tej zmiennej mieszczą się także inne zakończenia, między innymi eutanazja i powrót do właściciela. Dlatego atrybut `days_to_adoption` pełni tu tylko funkcję pomocniczą i opisową. Klasyfikatory oceniano za pomocą ROC-AUC, PR-AUC, Precision, Recall i F1-Score, a regresję przez MAE, RMSE i MedAE.

W dalszej części najpierw zestawiono jakość modeli, a następnie wrócono do hipotez badawczych. Osobne miejsce zajmuje interpretacja modeli, ponieważ same metryki nie wystarczają do oceny, czy wynik można rozsądnie wykorzystać w praktyce schroniskowej [9].

5.2 Porównanie jakości modeli

Najpierw warto uporządkować całą ścieżkę analizy. Schemat pokazuje, jak od zbioru modelowego przechodzą do porównania algorytmów, wyboru modelu końcowego i interpretacji jego zachowania.




Rysunek 5.1: Logika ewaluacji modeli klasyfikacyjnych i regresyjnych.

Na zbiorze testowym z lat 2024–2025 nie wygrał jeden model „do wszystkiego”. W klasyfikacji adopcji najlepiej poradził sobie HistGradientBoosting, natomiast w regresji długości pobytu najniższy błąd uzyskał CatBoost.

Różnica między zadaniami jest dobrze widoczna w metrykach. Klasyfikacja, z ROC-AUC około 0,840, okazała się stabilniejsza niż przewidywanie czasu pobytu, gdzie MAE wyniosło około 18,5 dnia. Warto też zwrócić uwagę na gatunek: wyniki dla kotów są lepsze niż dla psów. Może to oznaczać, że ścieżki pobytu kotów są w badanym materiale bardziej powtarzalne albo mniej zależne od nietypowych przypadków.

Na wykresach łatwiej zobaczyć skalę tej przewagi niż w samej tabeli. Rysunek 5.2 pokazuje, że modele boostingowe wyraźnie odsuwają się od modelu bazowego, którym była Regresja Logistyczna.



Rysunek 5.2: Zbiorcze porównanie zdolności dyskryminacyjnej badanych algorytmów na zbiorze łącznym oraz podzbiorach gatunkowych.


Dokładne wartości metryk na odłożonym zbiorze testowym zebrano w tabeli 5.1.

Tabela 5.1: Wyniki najlepszych modeli na zbiorze testowym (2024–2025)

Zadanie	Podzbiór danych	Najlepszy model	Główna miara (ROC-AUC / MAE)	PR-AUC	F1-Score	Precision	Recall	RMSE	MedAE
Klasyfikacja	Zbiór łączny	HistGradientBoosting	0,840 (ROC-AUC)	0,884	0,818	0,835	0,801	–	–
Klasyfikacja	Psy	HistGradientBoosting	0,806 (ROC-AUC)	0,857	0,799	0,817	0,781	–	–
Klasyfikacja	Koty	HistGradientBoosting	0,865 (ROC-AUC)	0,899	0,842	0,846	0,839	–	–
Regresja	Zbiór łączny	CatBoost	18,55 (MAE dni)	–	–	–	–	38,36	6,28
Regresja	Psy	CatBoost	21,56 (MAE dni)	–	–	–	–	45,99	6,28
Regresja	Koty	CatBoost	15,79 (MAE dni)	–	–	–	–	30,12	5,71

Te liczby potwierdzają, że modele bazowe spełniły swoją rolę kontrolną. Naiwne przewidywanie mediany lub dominanty pozwalało sprawdzić, czy dane niosą jakikolwiek sygnał predykcyjny. Najwięcej informacji analitycznej dały jednak modele boostingowe, zgodnie z szerszymi wynikami badań nad danymi tabelarycznymi [7, ?, ?]. Regresja logistyczna pozostaje użyteczna jako prostszy punkt odniesienia, ale to modele nieliniowe lepiej wykorzystały strukturę danych tabelarycznych.

Osobno sprawdzono cechy kontekstowe, takie jak pogoda i wcześniejszy wolumen przyjęć. Ich dodanie nie przyniosło dużej, jednolitej poprawy we wszystkich rodzinach modeli. W klasyfikacji pojawił się niewielki zysk dla CatBoosta w zbiorze łącznym, ale nie przełożył się on na wyraźną poprawę dla psów. W praktyce oznacza to, że zewnętrzny



Rysunek 5.3: Szczegółowy przebieg krzywej ROC dla zwycięskiego klasyfikatora (Hist-GradientBoosting). Widoczne wyraźne wysklepienie nad linią losową (AUC = 0.50).

kontekst środowiskowy w momencie przyjęcia należy traktować ostrożnie, raczej jako uzupełnienie niż główne źródło informacji.


5.3 Weryfikacja hipotez badawczych

Najwięcej materiału do interpretacji dostarczają trzy hipotezy: H1, H3 i H5.

Hipoteza H1 (Wpływ okoliczności przyjęcia w relacji do wyglądu)


Wyniki wspierają hipotezę, że okoliczności przyjęcia mają większe znaczenie niż same cechy wyglądu. W analizie opisowej najwyższe wskaźniki adopcji pojawiają się przy zrzeczeniu właścicielskim (`Owner Surrender`) oraz kategorii `Abandoned`. Podobny obraz widać w modelu: analizy SHAP i ablacja Rodzin Cech wskazują silniejszy sygnał po stronie zmiennych opisujących typ i okoliczności przyjęcia niż po stronie koloru czy innych cech wyglądu. Nie jest to dowód przyczynowy. To raczej spójna asocjacja, którą model wykorzystuje przy predykcji; podobną potrzebę ostrożności przy interpretowaniu cech schroniskowych podkreślają wcześniejsze badania nad adopcją i długością pobytu [5, ?].

Hipoteza H3 (Wpływ wieku zwierzęcia)



Rysunek 5.4: Porównanie ważności rodzin cech dla wyniku klasyfikacji. Cechy okoliczności przyjęcia (Intake) dominują nad wyglądem.


W przypadku wieku zależność jest czytelna i zgodna z intuicją oraz wcześniejszymi badaniami nad wynikami schroniskowymi [?, 5]. Najmłodsze zwierzęta najczęściej kończyły pobyt adopcją: grupa Baby osiąga wskaźnik 59,7%. Dla grupy Young jest to 47,5%, dla zwierząt dorosłych 39,6%, a dla seniorów 31,0%. Wiek pojawia się też wysoko w globalnych wyjaśnieniach modelu, więc nie jest to wyłącznie efekt prostego zestawienia opisowego.



Rysunek 5.5: Spadek prawdopodobieństwa adopcji postępujący wraz z wiekiem zwierzęcia (w latach).

Hipoteza H5 (Okres pandemii COVID-19)

Okres COVID-19 nie daje się sprowadzić do prostej historii o większym popycie na adopcje. W danych opisowych widać wzrost odsetka adopcji: z 46,3% przed pandemią do 61,5% po pandemii. Jednocześnie mediana liczby dni do opuszczenia schroniska rośnie z 5,25 do 9,83 dnia. Ten pozorny paradoks sugeruje zmianę struktury przyjmowanych zwierząt albo zmianę pojemności operacyjnej ośrodka, co jest spójne z obserwacjami o zmianach praktyk schroniskowych i przepływów zwierząt w pierwszym okresie pandemii [?, ?]. Sama informacja o pandemii pomaga więc opisać okres, ale nie powinna być czytana jako samodzielne wyjaśnienie mechanizmu.



Rysunek 5.6: Różnice we wskaźnikach adopcji przed, w trakcie oraz po pandemii COVID-19.

Pozostałe dwie hipotezy, H2 o sezonowości i H4 o ciemnym umaszczeniu, mają w tej analizie bardziej pomocniczy charakter. Zwierzęta oznaczone techniczną kategorią `is_black_or_dark` historycznie osiągały niższe wskaźniki adopcji. Trzeba jednak zachować tu ostrożność: taki wynik pokazuje asocjację w danych, ale sam w sobie nie dowodzi dyskryminacji po stronie osób adoptujących; literatura dotycząca wpływu umaszczenia i etykiet rasowych na wyniki adopcyjne również wskazuje na niejednoznaczność tych efektów [3, ?, ?].

Tabela 5.2: Status hipotez badawczych w świetle wyników

Hipoteza	Zakres	Status	Najważniejsza obserwacja
H1	Okoliczności przyjęcia vs wygląd	Wsparta opisowo i predykcynie	Cechy intake-related wykazują wyższą doniosłość (SHAP importance) niż atrybuty umaszczenia.
H2	Sezonowość	Analiza opisowa	Różnice sezonowe istnieją, ale stanowią czynnik drugorzędny predykcynie.
H3	Wiek	Wsparta opisowo i predykcynie	Wskaźnik adopcji maleje z 59,7% (baby) do 31,0% (senior).
H4	Ciemne umaszczenie	Analiza opisowa	Niższa obserwowana adopcyjność w technicznej kategorii dark/black.
H5	Okres COVID-19	Wsparta opisowo	Wzrost adopcji (z 46% do 61%) przy jednoczesnym wzroście czasu pobytu (z 5 do 9 dni mediany).


5.4 Interpretacja i wiarygodność modelu

Interpretacja modelu nie jest tu dodatkiem estetycznym, lecz warunkiem sensownego użycia wyników. W środowisku weterynaryjnym i schroniskowym decyzje dotyczą konkretnych zwierząt, dlatego model typu „czarna skrzynka” (ang. *black-box*) łatwo może budzić nieufność personelu. Pracownik schroniska powinien wiedzieć, dlaczego szczeniak albo starszy pies został oznaczony jako przypadek podwyższonego ryzyka. Do tego wykorzystano metody *Explainable AI* (XAI), przede wszystkim wartości SHAP [9]. Globalne wykresy SHAP są zgodne z intuicją wynikającą z danych: starszy wiek obniża prawdopodobieństwo adopcji, a młody wiek działa w przeciwnym kierunku. Taka zgodność nie rozwiązuje wszystkich problemów interpretacyjnych, ale ułatwia rozmowę o modelu z osobami, które miałyby z niego korzystać.

Trzeba przy tym uczciwie zaznaczyć jedną decyzję metodologiczną. Najlepszym klasyfikatorem na teście był HistGradientBoosting, ale pełne wygenerowanie wykresów SHAP jest, ze względów narzędziowych i dostępności *TreeExplainer*, wygodniejsze dla CatBoosta. Z tego powodu część interpretacji opiera się na modelach wspomagających. Służą one do pokazania kierunków zależności, a nie do zastępowania właściwej oceny modelu końcowego.

Drugim filarem użyteczności jest kalibracja. Samo wysokie ROC-AUC mówi, że model dobrze porządkuje przypadki, ale nie gwarantuje jeszcze, że podawane prawdopodobieństwa są dobrze wyskalowane [?, ?]. To szczególnie ważne na krańcach rozkładu

predykcji, gdzie błędna pewność modelu może być bardziej kłopotliwa niż pojedyncza pomyłka klasyfikacyjna.



Rysunek 5.7: Krzywa kalibracyjna (Calibration Curve) pokazująca, w jakim stopniu przewidywane przez model prawdopodobieństwo adopcji odpowiada rzeczywistej częstotliwości (Perfectly calibrated).

Oszacowania sprawdzono więc pod kątem luki kalibracyjnej (Brier Score) oraz progów decyzyjnych (`threshold`). Progi dobrano na niezależnym zbiorze walidacyjnym z lat 2022–2023, a potem przeniesiono bez zmian na test z lat 2024–2025. Dla małych podgrup, poniżej 100 obserwacji w zbiorze testowym, wyniki należy czytać szczególnie ostrożnie.

Najostrożniej trzeba interpretować regresję czasu pobytu. Proces opuszczania schroniska jest częściowo losowy i zależy od czynników, których nie ma w tabeli danych. Model nie jest więc „wyrocznią” wskazującą dokładny dzień wyjścia psa czy kota ze schroniska. Lepiej traktować go jako filtr ryzyka i narzędzie do porządkowania uwagi personelu. Z takiego założenia wynika późniejsza architektura Dashboardu oraz środowiska MLOps opisana w kolejnym rozdziale.

Rozdział 6

Architektura systemu i reprodukowalność eksperymentów

W niniejszym rozdziale przedstawiono warstwę inżynierijską i techniczną projektu. Badania oparte na uczeniu maszynowym wymagają nie tylko oceny skuteczności predykcyjnej, opisanej w rozdziale 5, lecz także zapewnienia odtwarzalności (ang. *reproducibility*). Zgodnie z dobrymi praktykami oprogramowania naukowego, na przykład postulatami *The Turing Way* [14], rzetelne badanie powinno być możliwe do niezależnego odtworzenia na podstawie dostarczonego kodu i danych. W tym celu wdrożono uporządkowaną architekturę systemu, skonteneryzowane środowisko Docker, zautomatyzowane skrypty wykonawcze oraz zestaw testów.

6.1 Środowisko wdrożeniowe i konteneryzacja (Docker)

Podstawą reprodukowalności wdrożonego rozwiązania jest skonteneryzowanie go przy użyciu technologii Docker [11]. Zamiast opierać się na lokalnych środowiskach programistycznych, które mogą różnić się konfiguracją i zależnościami, cały system analityczny i aplikacyjny został umieszczony w izolowanym obrazie.

6.1.1 Uzasadnienie złożoności systemu (Dlaczego MLOps?)

Na pierwszy rzut oka do wytrenowania modelu uczenia maszynowego mógłby wystarczyć pojedynczy skrypt w Pythonie. Potrzeba zastosowania bardziej rozbudowanej

architektury Docker, izolowanych potoków i środowisk testowych wynika jednak bezpośrednio z charakteru problemu badawczego.

Praca na 160 tysiącach epizodów zwierząt obejmujących 10 lat działalności schroniska wiąże się z istotnym ryzykiem wycieku danych (ang. *data leakage*). W nieustrukturyzowanym kodzie łatwo o sytuację, w której podczas transformacji danych przypadkowo uwzględniona zostanie informacja z przyszłości, na przykład powód eutanazji jako predyktor, mimo że model ma działać już na etapie przyjęcia zwierzęcia. Dodatkowym problemem jest zjawisko „cichej degradacji” (ang. *silent failure*). W przypadku błędnie podanych danych model nie musi wygenerować technicznego błędu, takiego jak `Exception`, lecz może bez widocznego ostrzeżenia zwrócić nieprawidłową predykcję ryzyka. Z tego powodu uporządkowana infrastruktura MLOps była ważna dla zapewnienia bezstronności, audytowalności i kontroli jakości wygenerowanych rezultatów, a nie tylko dla uzyskania wysokich metryk.

6.1.2 Architektura serwisów (Docker Compose)

Zastosowano narzędzie Docker Compose (`docker-compose.yml`), które definiuje architekturę systemu jako zbiór odseparowanych kontenerów, czyli serwisów, korzystających ze wspólnych zasobów. Taka struktura pozwala uruchomić wybraną warstwę systemu za pomocą jednej komendy. W ramach architektury zdefiniowano następujące serwisy operacyjne:

```
services:
  dashboard:
    build: .
    ports: ["8501:8501"]
    volumes: [./models:/app/models]
  pipeline-full:
    build: .
    command: python scripts/run_full_pipeline.py
    volumes: [./data:/app/data, ./reports:/app/reports]
  test:
    build: .
    command: python -m pytest tests/ -v
```

Listing 6.1: Kluczowe definicje serwisów wyizolowane w architekturze `docker-compose.yml`

Wszystkie te serwisy współdzielą na poziomie kontenerów zmapowane wolumeny pamięci, czyli katalogi `data/`, `models/`, `reports/` i `logs/`. Umożliwia to przepływ wytworzonych artefaktów między poszczególnymi warstwami bez powielania danych. Istotne jest także odseparowanie zapisu od konsumpcji: `pipeline-full` zapisuje

artefakty do katalogu `reports/`, natomiast `dashboard` korzysta z modeli zapisanych w katalogu `models/`.

6.2 Architektura *Artifact-First* i separacja warstw

Dzięki skonteneryzowaniu różnych ról systemu możliwe było zastosowanie podejścia *Artifact-First*. Oznacza ono ścisłe rozdzielenie zasobochłonnego procesu uczenia modeli od lekkiej warstwy prezentacyjnej, czyli aplikacji dla użytkownika końcowego.

Decyzja ta wynika z praktycznych ograniczeń środowiska docelowego. Typowe placówki ratownictwa zwierząt nie dysponują infrastrukturą serwerową wyposażoną w akceleratory graficzne (GPU), które mogą być potrzebne do efektywnego trenowania wybranych modeli. Dodatkowo interaktywne retrenowanie modelu po wprowadzeniu każdego nowego zwierzęcia, czyli tzw. uczenie online, wiązałoby się z ryzykiem operacyjnym. Błędnie wprowadzony rekord mógłby szybko pogorszyć jakość działania całego systemu.

- **Warstwa eksperymentalna (Jupyter):** przeznaczona dla *data scientistów* do testowania hipotez.
- **Warstwa treningowa (Pipeline):** z uwagi na duży wolumen danych, obejmujący ponad 160 tys. epizodów, operacje te zajmują znaczny czas. Wyniki uruchomienia kontenera `pipeline-full` są „zamrażane” w formie statycznych artefaktów: wyuczonych modeli w formacie `.joblib`, tabel wyników w formacie `.csv` oraz wygenerowanych wykresów `.png`.
- **Warstwa konsumpcyjna (Dashboard):** aplikacja demonstracyjna, opisana w rozdziale 7, nie posiada uprawnień do modyfikacji algorytmów. Jej rola ogranicza się do ładowania do pamięci RAM gotowych modeli zapisanych na dysku.

Takie podejście obniża wymagania sprzętowe po stronie serwera aplikacji i wspiera niezmienność decyzji algorytmicznych. Pracownik schroniska otrzymuje predykcję z modelu wcześniej przetestowanego, a nie z modelu zmienionego najnowszymi danymi.

6.3 Organizacja kodu i modułowość

Projekt ustrukturyzowano jako standardowy pakiet języka Python zarządzany przez `pyproject.toml`. Struktura repozytorium odpowiada podziałowi kompetencji:

1. `src/aac_adoption/` – główny kod źródłowy biblioteki, podzielony na domeny: `data` (przetwarzanie epizodów), `features` (rejestr cech), `models` (uczenie i ewaluacja) oraz `reporting` (agregacja wyników).
2. `scripts/` – narzędzia wykonawcze (CLI), np. skrypt `run_full_pipeline.py`.
3. `tests/` – zestaw zautomatyzowanych testów jednostkowych i integracyjnych uruchamianych z kontenera testowego.
4. `notebooks/` – notatniki Jupyter służące analizie odkrywczej.

6.4 Automatyzacja potoku (Pipeline) a notatniki Jupyter

W uczeniu maszynowym częstym problemem jest „ukryty dług techniczny” (ang. *hidden technical debt*) [10]. Modele budowane wyłącznie przez sekwencyjne uruchamianie komórek w notatnikach Jupyter mogą stać się trudne do odtworzenia.

Dlatego w niniejszej architekturze Jupyter (`notebooks/`) służy wyłącznie do badania i rozwoju (R&D). Gdy dana logika okazuje się skuteczna, jest przenoszona do produkcyjnego kodu źródłowego w `src/`. Ostateczne trenowanie modeli realizowane jest przez w pełni skryptowy, centralny potok wywoływany w kontenerze `pipeline-full`:

```
docker-compose up pipeline-full
```

Listing 6.2: Uruchomienie pełnego potoku eksperymentalnego

6.4.1 Fazy zautomatyzowanego potoku i Data Provenance

Komenda ta zamyka proces badawczy w deterministycznych ramach, uruchamiając sekwencyjnie 18 zdefiniowanych kroków widocznych w skrypcie `run_full_pipeline.py`. Proces ten można podzielić na następujące makrofazy:

1. **Zarządzanie danymi:** automatyczne pobranie surowych danych, jeśli ich brakuje, czyszczenie oraz budowa ujednoliconego zbioru (`build_dataset`).
2. **Modelowanie:** trening modeli bazowych, strojenie hiperparametrów algorytmów drzewiastych oraz kalibracja klasyfikatorów.
3. **Diagnostyka i wyjaśnialność:** generowanie wykresów diagnostycznych i przeliczanie wartości SHAP dla całego zbioru.

4. **Raportowanie:** automatyczne zapisywanie artefaktów, czyli tabel i wykresów, bezpośrednio do katalogu `reports/`.

Szczególną uwagę w potoku poświęcono koncepcji **Data Provenance**, czyli proveniencji danych. Po poprawnym zakończeniu wszystkich 18 kroków potok generuje plik `run_receipt.json`. Pełni on funkcję zapisu technicznego przebiegu eksperymentu: zawiera dokładny znacznik czasu, skrót SHA z repozytorium Git określający wersję kodu oraz pełną listę wykonanych kroków. Dzięki temu można określić, w jakich warunkach powstały modele udostępniane później schronisku.

6.5 Rygor testowy i audyty danych

Złożoność przetwarzania danych weryfikowano na każdym etapie za pomocą zautomatyzowanych zestawów testów, uruchamianych w ramach komendy `docker-compose up test`. System zwraca jednoznaczne logi dokumentujące poprawność architektury:

```
===== test session starts ✓
  ↳ =====
collected 24 items
tests/test_data_leakage.py::test_future_dates_not_in_features PASSED ✓
  ↳ [ 15%]
tests/test_data_leakage.py::test_target_variable_exclusion PASSED ✓
  ↳ [ 18%]
tests/test_model_pipeline.py::test_model_artifact_generation PASSED ✓
  ↳ [ 42%]
...
===== 24 passed in 12.4s ✓
  ↳ =====
```

Listing 6.3: Fragment wydruku środowiska testowego dokumentujący pomyślne zakończenie audytu wycieku danych (leakage audit)

Wszystkie niedeterministyczne operacje algorytmiczne w kodzie posiadają zamrożone ziarno losowości. Nie zastępuje ono chronologicznego podziału danych opisanego w sekcji 4.3, lecz stabilizuje elementy losowe obecne w procedurach uczenia i oceny modeli:

```
RANDOM_STATE = 42

classifier = HistGradientBoostingClassifier(random_state=RANDOM_STATE)
regressor = CatBoostRegressor(random_seed=RANDOM_STATE, verbose=False)
```

Listing 6.4: Przykład utrzymania stałego ziarna losowości w modelowaniu

W połączeniu z powtarzalną architekturą Docker wspiera to odtwarzalność potoku analitycznego na innej maszynie serwerowej. Celem takiej organizacji jest uzyskanie tych samych tabel wyników oraz wykresów przy ponownym uruchomieniu eksperymentu, z zastrzeżeniem możliwych minimalnych różnic numerycznych wynikających z wersji

bibliotek, architektury sprzętowej lub ustawień wielowątkowości. Tak rozumiana reprodukowalność odpowiada kryteriom audytowalności prac naukowych.

Rozdział 7

Aplikacja demonstracyjna i sposób prezentacji wyników

Zbudowanie skutecznego algorytmu analitycznego działającego w środowisku konsolowym, opisanym w poprzednich rozdziałach, rozwiązuje problem z perspektywy *data science*, ale nie tworzy jeszcze narzędzia wygodnego dla pracowników schroniska. Aby ograniczyć barierę wejścia i pokazać praktyczną użyteczność opracowanych modeli, stworzono interaktywną aplikację demonstracyjną (dashboard).

W niniejszym rozdziale przedstawiono cele, architekturę oraz przykładowe scenariusze użycia tego narzędzia wizualnego, które stanowi końcowy element praktycznej części pracy.

7.1 Cel i środowisko aplikacji

Głównym celem aplikacji jest umożliwienie personelowi Austin Animal Center (AAC) korzystania z wyników modelu predykcyjnego bez konieczności posiadania wiedzy programistycznej lub analitycznej.

Kluczowym założeniem projektowym, zgodnym z opisaną w rozdziale 6 architekturą *Artifact-First*, jest pasywność aplikacji w kontekście uczenia maszynowego. Aplikacja nie trenuje modeli interaktywnie. Zamiast tego pobiera wcześniej zatwierdzone i zamrożone po weryfikacji testowej artefakty ze współdzielonego wolumenu Dockera dostępnego dla kontenera jako katalog `models/`.

Poniższy fragment kodu pokazuje lekkość warstwy konsumpcyjnej. Interfejs wczytuje wcześniej wytrenowany model i przechodzi w stan gotowości operacyjnej:

```

import streamlit as st
import joblib

@st.cache_resource
def load_model():
    # Model ładuje się tylko raz po starcie kontenera "dashboard"
    return joblib.load('models/adoption_model.joblib')

model = load_model()

```

Listing 7.1: Mechanizm buforowania wczytywania modelu zapobiegający degradacji wydajności

Dzięki temu system, działający jako izolowany kontener `dashboard`, ogranicza ryzyko uszkodzeń wynikających z wprowadzania błędnych danych przez operatora. Czas oczekiwania na prognozę pozostaje krótki, ponieważ aplikacja korzysta z gotowego modelu, a nie uruchamia procesu trenowania.

7.2 Główne moduły funkcjonalne (widoki)

Interfejs użytkownika podzielono na logiczne sekcje odpowiadające najczęstszym operacjom w schronisku.

7.2.1 Single Animal Predictor (symulator pojedynczego przyjęcia)

Jest to główny moduł operacyjny przeznaczony dla personelu pracującego przy tak zwanej „bramie” (*intake*), czyli na etapie przyjęcia zwierzęcia do ośrodka. Umożliwia on manualne wprowadzenie cech zwierzęcia znanych w momencie przyjęcia.

Użytkownik definiuje z rozwijanych list między innymi:

- gatunek, płeć oraz wiek w miesiącach lub latach,
- typ i okoliczności przyjęcia, na przykład zrzeczenie właścicielskie, znalezienie na ulicy lub uratowanie z wypadku,
- cechy wyglądu, w tym rasę dominującą oraz umaszczenie.

Po zatwierdzeniu formularza wbudowany w aplikację skrypt mapuje wartości z interfejsu na odpowiedni, stabelaryzowany wektor wejściowy i przekazuje go do wiodącego modelu klasyfikacyjnego. Pracownik otrzymuje następnie czytelny wynik:

1. **Ocena ryzyka długiego pobytu** – aplikacja klasyfikuje przypadek, używając wcześniej ustalonego progu decyzyjnego.
2. **Kwantyfikacja** – prezentowane jest bazowe prawdopodobieństwo adopcji w procentach.



Rysunek 7.1: Interfejs *Single Animal Predictor* przeznaczony do oceny pojedynczego przyjęcia zwierzęcia.


Uwaga. Ze względu na dynamiczny charakter aplikacji Streamlit zrzut ekranu należy wygenerować manualnie podczas działania systemu i umieścić pod ścieżką `assets/streamlit_screenshot.png` przed ostatecznym generowaniem pliku PDF.

7.2.2 Wyjaśnialność decyzji (Interactive SHAP)

Wartość prawdopodobieństwa jest użyteczną informacją, jednak personel weterynaryjny potrzebuje również zrozumienia powodów stojących za oceną algorytmu, czyli tak zwanej *explainability*. Dlatego dla predykcji pojedynczego zwierzęcia aplikacja może prezentować lokalne wyjaśnienie SHAP, na przykład w postaci wykresu typu *force plot* lub *waterfall plot*.

W perspektywie globalnej, czyli dla całego zbioru, wartości te układają się w interpretowalne wzorce, co prezentuje poniższy wykres.

Pracownik na ekranie aplikacji widzi analogiczny wykres, ale ograniczony do jednego zwierzęcia. Może sprawdzić, które konkretne atrybuty, na przykład podeszły wiek psa, ciemne umaszczenie czy trudna sytuacja znalezienia, obniżyły wynik, a które, na



Rysunek 7.2: Globalne podsumowanie wpływu najważniejszych cech (SHAP Summary) na decyzję klasyfikacyjną modelu. Kolor czerwony oznacza wyższą wartość danej cechy.

przykład przynależność do bardziej pożądanego typu rasy, działały na jego korzyść. Jest to istotny element budowania zaufania między człowiekiem a algorytmem i ograniczania ryzyka odrzucenia systemu z powodu postrzegania go jako „czarnej skrzynki” (*black-box*).

+

7.2.3 Przegląd historycznych grup zwierząt

Dla stanowisk kierowniczych aplikacja udostępnia widok umożliwiający przeglądanie historycznych grup zwierząt z populacji AAC. Pozwala to na nakładanie filtrów i obserwację zmian krzywych adopcyjności oraz median długości pobytu w czasie. Aplikacja może wskazać obszary wymagające uwagi, na przykład nagromadzenie starszych kotów w określonym kwartale roku, bez konieczności generowania zapytań SQL przez analityka.

7.3 Scenariusze użycia w pracy schroniska (triaging)

Największą wartością dodaną aplikacji z punktu widzenia operacyjnego nie jest precyzyjna predykcja konkretnej daty, lecz możliwość zastosowania selekcji priorytetowej, czyli tak zwanego *triagingu*.

W tradycyjnym środowisku każdy przyjmowany pies otrzymuje standardową opiekę. Czasem dopiero po kilku miesiącach personel zauważa, że dane zwierzę źle znosi pobyt w schronisku i zaczyna funkcjonować jak długoterminowy „rezydent”. W scenariuszu wspartym aplikacją:

1. zwierzę jest wprowadzane do bazy,
2. aplikacja flaguje je jako przypadek wysokiego ryzyka długiego pobytu, na przykład ze względu na bardzo niskie prawdopodobieństwo adopcji lub długi estymowany czas pobytu,
3. pracownik już pierwszego dnia widzi ten alert i może uruchomić procedury zaradcze, na przykład przekazanie zwierzęcia do tymczasowego domu zastępczego (*foster*), rozpoczęcie intensywniejszej promocji w lokalnych mediach społecznościowych lub szybką interwencję behawiorysty.

Ograniczenia aplikacji pozostają zgodne z ograniczeniami samego modelu. Jeżeli profil zwierzęcia wykracza poza ramy historyczne, na których uczono system, na przykład dotyczy całkowicie nowej rasy egzotycznej w regionie, narzędzie powinno wyświetlić ostrzeżenie lub poprosić o przyporządkowanie zwierzęcia do szerszej grupy bazowej. Aplikacja nie maskuje niepewności – w przypadku braku wystarczających danych powinna wyświetlić ostrzeżenie, zamiast przedstawiać pozornie pewną predykcję opartą na zgadywaniu.

Rozdział 8

Podsumowanie i wnioski końcowe

Ostatni rozdział pracy stanowi syntezę przeprowadzonych badań, ocenę stopnia realizacji założonych celów oraz wskazanie obszarów wymagających dalszej eksploracji w przyszłości.

Głównym celem niniejszej pracy było zbadanie możliwości wykorzystania technik uczenia maszynowego do przewidywania adopcyjności i czasu pobytu zwierząt, czyli psów i kotów, w schronisku typu *No-Kill* na podstawie danych dostępnych wyłącznie w momencie ich przyjęcia. Wyniki eksperymentów, oparte na analizie ponad 160 tysięcy epizodów z Austin Animal Center, wskazują na wysoką skuteczność analityczną zastosowanych algorytmów z rodziny drzew decyzyjnych, w szczególności modeli *Gradient Boosting*. Zbudowane modele pozwalają identyfikować wzorce związane z późniejszym losem zwierzęcia.

8.1 Odpowiedzi na pytania badawcze (hipotezy)

Podsumowanie statusu pięciu głównych hipotez sformułowanych we wstępie pracy przedstawia poniższa macierz ewaluacyjna.

8.2 Ograniczenia badawcze i metodologiczne

Ocena modeli predykcyjnych wymaga wskazania ich ograniczeń.

1. **Cenzorowanie prawostronne (*Right-Censoring*)**. Do trenowania klasycznych algorytmów predykcyjnych, w szczególności regresji długości pobytu, konieczne

Tabela 8.1: Macierz ewaluacyjna hipotez badawczych

Hipoteza	Podsumowanie wyników z eksperymentów	Ostateczny status
H1: Okoliczności przyjęcia mają większy wpływ predykcyjny na wynik pobytu niż wrodzone cechy wyglądu zwierzęcia.	Modele, w tym analiza ważności cech SHAP, wskazują, że kategoria przyjęcia (Owner Surrender, Stray, Confiscate) generuje silniejszy i bardziej jednoznaczny sygnał decyzyjny niż cechy umaszczenia.	Wsparta
H2: Występuje istotna sezonowość w adopcjach, z miesiącami o wyraźnie niższej adopcyności.	Mimo występowania różnic opisowych między miesiącami i porami roku, cechy sezonowe okazały się mieć drugorzędne znaczenie predykcyjne dla samego modelu uczenia maszynowego w porównaniu do wieku czy typu przyjęcia.	Wsparta częściowo (opisowo)
H3: Wiek zwierzęcia w momencie przyjęcia jest odwrotnie proporcjonalny do szansy na jego adopcję.	Hipoteza znajduje silne wsparcie w wynikach. Grupa wiekowa <i>Baby</i> ma wskaźnik adopcji rzędu blisko 60%, podczas gdy u zwierząt zaklasyfikowanych jako <i>Senior</i> spada on w okolice 31%. Wiek jest jednym z najważniejszych predyktorów w globalnych wyjaśnieniach modeli.	Wsparta
H4: Zwierzęta o ciemnym umaszczeniu przebywają w schronisku statystycznie dłużej ze względu na niższą adopcynność.	Analiza opisowa wykazała nieznacznie niższe wskaźniki adopcji dla grupy <i>dark/black</i> . Efekt ten na etapie wielowymiarowego uczenia maszynowego bywa jednak niwelowany przez cechy o wyższym priorytecie, takie jak wiek i grupa rasy. Wskazuje to na statystyczną korelację, ale nie potwierdza strukturalnej dyskryminacji.	Wsparta częściowo (opisowo)
H5: Okres pandemii COVID-19 trwale zaburzył historyczne wzorce przepływu populacji schroniskowej.	Potwierdzono strukturalną zmianę. Pandemia zwiększyła sam odsetek zwierząt adoptowanych, ale jednocześnie wyraźnie wydłużyła medianę długości pobytu z około 5 do blisko 10 dni, co zmieniło całkowitą dynamikę rotacji w placówce.	Wsparta

było pominięcie epizodów, które nie posiadały wpisanego wyniku zakończenia w momencie zrzutu bazy danych. W efekcie modele mogły zostać nieznacznie przesunięte w stronę krótszych, szybciej zakończonych pobytów. Zjawisko to jest ograniczeniem wynikającym z odstąpienia od technik analizy przeżycia (*Survival Analysis*).

2. **Specyfika schronisk typu *No-Kill*.** Wszystkie zidentyfikowane wzorce odnoszą się do placówki działającej w środowisku o wysokiej świadomości społecznej, czyli w mieście Austin w stanie Teksas, oraz utrzymującej wskaźnik przeżywalności, tak zwany *live release rate*, znacznie powyżej 90%. Z tego powodu przeniesienie modelu z Austin do schroniska miejskiego w innej jurysdykcji, szczególnie o bardziej restrykcyjnej polityce eutanazji, czyli tak zwanego *high-kill shelter*, mogłoby prowadzić do utraty właściwości kalibracyjnych.
3. **Brak zmiennych behawioralnych.** W wektorze wejściowym, zgodnie z założeniem predykcji tuż po przyjęciu (*intake-only*), nie zawarto oceny behawioralnej zwierzęcia. Zmienne takie jak reakcja na stres, agresja lękowa czy przyjazność, oceniane zazwyczaj w pierwszych 72 godzinach po przyjęciu, mogłyby poprawić skuteczność wariantu regresyjnego (MAE).

8.3 Kierunki dalszych badań (future work)


Rezultaty uzyskane w niniejszej pracy wskazują na możliwość dalszego rozwijania projektu w kierunku naukowym i wdrożeniowym:

- **Wdrożenie głębokiej analizy przeżycia (*Deep Survival Analysis*).** Rozwiązaniem ograniczającym problem cenzorowania prawostronnego mogłoby być zastąpienie standardowej regresji sieciami neuronowymi przewidującymi funkcję hazardu w czasie, na przykład algorytmami *DeepSurv*. Pozwoliłoby to na ciągłe aktualizowanie prawdopodobieństwa adopcji z każdym kolejnym dniem pobytu zwierzęcia w boksie.
- **Przetwarzanie tekstu (NLP) uwag weterynaryjnych.** Wiele cennych, subtelnych sygnałów, na przykład „pies ma skłonność do ucieczek”, jest przechowywanych w nieskompresowanych notatkach personelu medycznego. Wykorzystanie dużych modeli językowych (LLM) do ekstrakcji i kwantyfikacji tych danych mogłoby wzbogacić słownik cech kontekstowych. Dane te nie są dostępne w publicznych zbiorach wykorzystanych w niniejszej pracy.
- **Praktyczne wdrożenie operacyjne (*Continuous Triaging*).** Rozbudowanie zaprezentowanego w pracy narzędzia *Streamlit* do postaci zintegrowanego systemu klasy ERP, który łączyłby się bezpośrednio z systemami ewidencyjnymi schronisk, na przykład *Chameleon Software* lub *Shelterluv*, mogłoby umożliwić automatyczne flagowanie nowych przypadków trudnych adopcyjnie jeszcze przed porannym przeglądem dokonywanym przez weterynarza.

Wdrożenie systemów uczenia maszynowego w sektorze ratownictwa zwierząt nie zastąpi specjalistycznej wiedzy ludzkiego personelu. Może jednak stanowić narzędzie wspierające zarządzanie ryzykiem i dystrybucję ograniczonych zasobów. Skierowanie większej uwagi behawioralnej i promocyjnej na zwierzęta zidentyfikowane przez model jako szczególnie narażone na długi pobyt może być praktycznym krokiem w stronę usprawnienia systemu współczesnej opieki nad bezdomnymi zwierzętami.

8.4 Podsumowanie końcowe i reprodukowalność

Przeprowadzona w niniejszej pracy analiza ponad 160 tysięcy epizodów schroniskowych wskazuje, że algorytmy uczenia maszynowego, w szczególności modele z rodziny *Gradient Boosting*, mogą skutecznie modelować losy zwierząt wyłącznie na



Rysunek 8.1: Zarys budowy behawioralnych profili ryzyka (*vulnerable profiles*) zidentyfikowanych w trakcie badania, które mogłyby stanowić podstawę dla zautomatyzowanego systemu powiadomień operacyjnych.

podstawie początkowego profilu wejściowego. Zidentyfikowano kluczowe determinanty ryzyka, potwierdzając większe znaczenie okoliczności przyjęcia, takich jak zrzeczenie lub znalezienie zwierzęcia, oraz wieku w porównaniu z tradycyjnymi cechami fizycznymi.

Wartość poznawcza pracy polega zatem nie tylko na osiągnięciu satysfakcjonujących miar predykcyjnych, lecz także na uporządkowaniu procesu analitycznego w sposób możliwy do interpretacji przez odbiorców nietechnicznych. Zastosowanie wyjaśnień SHAP pozwoliło przejść od samego wyniku klasyfikacji do wskazania czynników, które najbardziej zwiększały lub zmniejszały prawdopodobieństwo adopcji oraz ryzyko dłuższego pobytu. Dzięki temu model może być rozumiany jako narzędzie wspomagające decyzje, a nie jako zamknięta, nieprzejrzysta procedura automatycznego rozstrzygania.

Z perspektywy praktycznej najważniejszym wnioskiem jest możliwość wcześniejszego wykrywania przypadków wymagających dodatkowej uwagi organizacyjnej. Jeżeli już w momencie przyjęcia można wskazać zwierzęta potencjalnie narażone na dłuższy pobyt, schronisko może szybciej zaplanować działania promocyjne, konsultacje behawioralne lub wsparcie wolontariuszy. Taki sposób wykorzystania predykcji zachowuje nadrzędną rolę personelu i nie zastępuje indywidualnej oceny zwierzęcia, lecz dostarcza dodatkowego sygnału wspierającego priorytetyzację ograniczonych zasobów.

Technicznym elementem wzmacniającym wiarygodność tych ustaleń było obudowanie ich architekturą *MLOps*, opartą na konteneryzacji Docker i automatycznych audytach

wycieku danych (Pytest). Zastosowanie środowisk `jupyter` do R&D oraz wyizolowanych potoków uruchomieniowych `pipeline-full` zapewniło wysoką odtwarzalność procesu badawczego. Zbudowanie interfejsu Streamlit pokazało natomiast, w jaki sposób metody sztucznej inteligencji mogą zostać wprowadzone do codziennej pracy personelu nietechnicznego poprzez interaktywne raportowanie wartości SHAP.

Zgodnie z dobrymi praktykami oprogramowania naukowego cały kod źródłowy projektu, wraz z konfiguracją Docker Compose oraz testami jednostkowymi, został przygotowany w sposób umożliwiający audyt, weryfikację i replikację badań w przyszłości.

Bibliografia

- [1] Shelter Animals Count. Intake and outcome data analysis: Annual report 2024. Online, <https://www.shelteranimalscount.org/explore-the-data/statistics-2024>, 2025. dostęp 08.02.2026.
- [2] Austin Animal Center. No-kill implementation plan. Online, <https://www.austintexas.gov/page/no-kill-plan>, 2010. dostęp 08.02.2026.
- [3] H. J. Svoboda and C. L. Hoffman. Investigating the role of coat colour, age, sex, and breed on outcomes for dogs at two animal shelters in the united states. *Animal Welfare*, 24(4):497–506, November 2015.
- [4] FOUR PAWS. Stray animals: Pets without a home. Online, <https://www.fourpawsusa.org/campaigns-topics/topics/help-for-strays/stray-animals-pets-without-a-home>, 2023. dostęp 08.02.2026.
- [5] Janae Bradley and Suchithra Rajendran. Increasing adoption rates at animal shelters: a two-phase approach to predict length of stay and optimal shelter allocation. *BMC Veterinary Research*, 17(1):70, 2021.
- [6] Cem Sazara and Xin Gao. Predicting animal shelter pet adoption times and feature importance analysis using catboost. In *2022 IEEE 11th International Conference on Intelligent Systems (IS)*, pages 1–4, 2022.
- [7] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [8] Anna Veronika Dorogush, Vasily Ershov, and Andrey Gulin. Catboost: gradient boosting with categorical features support. *arXiv preprint arXiv:1810.11363*, 2018.
- [9] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

- [10] D. Sculley, Gary Holt, Daniel Golovin, Eugene Davydov, et al. Hidden technical debt in machine learning systems. In *Advances in Neural Information Processing Systems*, volume 28, 2015.
- [11] Dirk Merkel. Docker: Lightweight linux containers for consistent development and deployment. *Linux Journal*, 2014(239), 2014.
- [12] Ruslan Kuprieiev et al. Data version control (dvc): Documentation. Online, <https://dvc.org/doc>, 2024. dostęp 08.02.2026.
- [13] Streamlit Inc. Streamlit documentation. Online, <https://docs.streamlit.io>, 2023. dostęp 08.02.2026.
- [14] The Turing Way Community. The turing way: A handbook for reproducible, ethical and collaborative research. Zenodo, <https://doi.org/10.5281/zenodo.3233853>, 2025. dostęp 12.06.2026.

Spis rysunków

Rysunek 5.1	Logika ewaluacji modeli klasyfikacyjnych i regresyjnych.	24
Rysunek 5.2	Zbiorcze porównanie zdolności dyskryminacyjnej badanych algorytmów na zbiorze łącznym oraz podzbiorach gatunkowych.	25
Rysunek 5.3	Szczegółowy przebieg krzywej ROC dla zwycięskiego klasyfikatora (HistGradientBoosting). Widoczne wyraźne wysklepienie nad linią losową ($AUC = 0.50$).	26
Rysunek 5.4	Porównanie ważności rodzin cech dla wyniku klasyfikacji. Cechy okoliczności przyjęcia (Intake) dominują nad wyglądem.	27
Rysunek 5.5	Spadek prawdopodobieństwa adopcji postępujący wraz z wiekiem zwierzęcia (w latach).	27
Rysunek 5.6	Różnice we wskaźnikach adopcji przed, w trakcie oraz po pandemii COVID-19.	28
Rysunek 5.7	Krzywa kalibracyjna (Calibration Curve) pokazująca, w jakim stopniu przewidywane przez model prawdopodobieństwo adopcji odpowiada rzeczywistej częstotliwości (Perfectly calibrated).	30
Rysunek 7.1	Interfejs <i>Single Animal Predictor</i> przeznaczony do oceny pojedynczego przyjęcia zwierzęcia.	39
Rysunek 7.2	Globalne podsumowanie wpływu najważniejszych cech (SHAP Summary) na decyzję klasyfikacyjną modelu. Kolor czerwony oznacza wyższą wartość danej cechy.	40
Rysunek 8.1	Zarys budowy behawioralnych profili ryzyka (<i>vulnerable profiles</i>) zidentyfikowanych w trakcie badania, które mogłyby stanowić podstawę dla zautomatyzowanego systemu powiadomień operacyjnych.	45