



POLSKO-JAPANEZKA AKADEMIA
TECHNIK KOMPUTEROWYCH

Wydzia Informatyki

Katedra Systemów Inteligentnych i Data Science
Data Science

Magdalena Sokolowska
S32924

**Dane, które ratuj ycie: Analiza i wizualizacja
czynników wpywajcych na adopcj psów i kotów
w Austin Animal Center z wykorzystaniem
metod uczenia maszynowego**

Praca dyplomowa magisterska

Promotor: prof. dr hab. Grzegorz Wójcik

Warszawa, stycze 2026 r.

Streszczenie

Tutaj znajdzie si streszczenie caej pracy.

Sowa kluczowe: data science, koty, psy

Abstract

Life-Saving Data: Analyzing Factors Affecting Adoptions at the Austin Animal Center via Machine Learning and Visualization

Keywords: programming, bluetooth, horse riding

Spis treści

1	Wstęp	1
1.1	Kontekst problemu i znaczenie badań	1
1.2	Cel, hipotezy i pytania badawcze	3
1.3	Zakres i struktura pracy	5
2	Podstawy teoretyczne i przegląd literatury	9
2.1	Problem bezdomności zwierząt i filozofia No-Kill	9
2.2	Predykcyjne modelowanie adopcji	10
2.3	Reprodukowalność i inżynieria danych (MLOps)	14
3	Dane i przygotowanie zbioru badawczego	15
3.1	Źródło danych i zakres analizy	15
3.2	Charakterystyka zbiorów wejściowych	16
3.3	Standaryzacja i czyszczenie danych	16
3.4	Konstrukcja epizodów i dopasowanie rekordów	17
3.5	Zmienne docelowe	18
3.6	Konstrukcja cech wejściowych	18
3.7	Charakterystyka opisowa zbioru	19
3.8	Ograniczenia danych	20
3.9	Podsumowanie przygotowania danych	23
4	Metodyka modelowania i oceny modeli	25
4.1	Cel modelowania	26
4.2	Formalne sformułowanie problemu	26
4.3	Przygotowanie danych i podział chronologiczny	26
4.4	Algorytmy predykcyjne	27
4.5	Metryki oceny	29
4.6	Interpretowalność (SHAP)	31

4.7	Protokół eksperymentu	32
4.8	Ograniczenia	33
5	Wyniki badań i interpretacja modeli	35
5.1	Ramy interpretacyjne rozdziału	35
5.2	Porównanie jakości modeli	36
5.2.1	Porównanie modeli regresyjnych	40
5.3	Weryfikacja hipotez badawczych	42
5.4	Interpretacja i wiarygodność modelu	47
5.4.1	Analiza błędów i wiarygodność modelu	51
6	Architektura systemu i reprodukowalność eksperymentów	54
6.1	środowisko wdrożeniowe i konteneryzacja (Docker)	54
6.1.1	Uzasadnienie zożności systemu (Dlaczego MLOps?)	54
6.1.2	Architektura serwisów (Docker Compose)	55
6.2	Architektura <i>Artifact-First</i> i separacja warstw	56
6.3	Organizacja kodu i modułowość	57
6.4	Automatyzacja potoku (Pipeline) a notatniki Jupyter	58
6.4.1	Fazy zautomatyzowanego potoku i Data Provenance	58
6.5	Rygor testowy i audyty danych	60
7	Aplikacja demonstracyjna i sposób prezentacji wyników	63
7.1	Cel i środowisko aplikacji	63
7.2	Główne moduły funkcjonalne (widoki)	65
7.2.1	Single Animal Predictor (symulator pojedynczego przyjęcia)	65
7.2.2	Wyjaśnianie decyzji (Interactive SHAP)	66
7.2.3	Laboratorium hipotez (Hypothesis Lab)	66
7.2.4	Przegląd historycznych grup zwierząt i analiza warunkowa	67
7.3	Scenariusze użycia w pracy schroniska (triaging)	69
7.4	Ograniczenia aplikacji i kierunki dalszego rozwoju	70
8	Podsumowanie i wnioski końcowe	71
8.1	Odpowiedzi na pytania badawcze i weryfikacja hipotez	71
8.2	Ograniczenia badawcze i metodologiczne	73
8.3	Kierunki dalszych badań i rekomendacje praktyczne	74
8.3.1	Rekomendacje dla personelu schronisk	74
8.4	Podsumowanie końcowe i reprodukowalność	76

Bibliografia	77
Lista figur	86

Rozdział 1

Wstęp


1.1 Kontekst problemu i znaczenie badań

Każdego roku do schronisk dla zwierząt na całym świecie trafiają miliony bezdomnych psów i kotów, co stanowi ogromne wyzwanie organizacyjne i logistyczne. W samych Stanach Zjednoczonych szacuje się, że rocznie do schronisk trafia około 6 milionów psów i kotów [1, 2]. Efektywne zarządzanie takimi liczbami podopiecznych wymaga zapewnienia odpowiedniej opieki, zasobów i przestrzeni każdemu zwierzęciu, przy jednoczesnym dążeniu do jak najszybszego znalezienia mu nowego domu. Jednym z kluczowych wskaźników skuteczności pracy schroniska jest czas pobytu zwierzęcia pod jego opieką (ang. *Length of Stay*, LOS). Im krótszy jest LOS, tym mniejsze obciążenie dla zwierzęcia (ograniczenie stresu, ryzyka chorób i zgonu) oraz dla placówki (niższe koszty utrzymania i więcej wolnego miejsca dla kolejnych potrzebujących).

Coraz więcej schronisk przyjmuje filozofię *No-Kill*, która zakłada unikanie eutanazji zdrowych zwierząt poprzez osiągnięcie bardzo wysokiego odsetka adopcji i uratowania. Przykładem spektakularnego sukcesu podejścia *No-Kill* jest *Austin Animal Center* (AAC) w Teksasie. Od 2011 roku miasto Austin może poszczycić się mianem największego miasta w USA o statusie *No-Kill*, utrzymując współczynnik uratowania (ang. *live-release rate*) powyżej 90% [3]. Schronisko AAC przyjmuje ponad 18 tysięcy zwierząt rocznie [3], co czyni je jednym z największych tego typu placówek komunalnych w kraju i jednocześnie stawia przed nim ogromne wymagania w zakresie efektywnego wykorzystania danych i zasobów. Dążenie do utrzymania wysokiego odsetka adopcji przy tak dużej skali działalności wymaga ciągłego usprawniania procesów i podejmowania trafnych decyzji operacyjnych.


W ostatnich latach zauważalny jest istotny zwrot od podejmowania decyzji w oparciu o dowiadczanie i intuicję personelu ku podejściu opartemu na danych (*data-driven*). Większość schronisk gromadzi szczegółowe informacje o każdym przyjęciu i opuszczeniu zwierzęcia (intake & outcome), jednak w wielu przypadkach dane te nie są w żadnym stopniu wykorzystywane do wyciągania praktycznych wniosków. Zastosowanie nowoczesnych metod analizy danych i uczenia maszynowego otwiera możliwość lepszego zrozumienia, jakie czynniki sprzyjają szybkim adopcjom, a jakie wiążą się z dłuższym pobytem zwierzęcia w schronisku lub – w skrajnych przypadkach – ich upiędzeniem. Modele predykcyjne mogą pomóc przewidywać prawdopodobieństwo adopcji konkretnego zwierzęcia oraz zidentyfikować obszary wymagające interwencji (np. grupy zwierząt o podwyższonym ryzyku długotrwałego pobytu). Tym samym, badania czcące dane schronisk z metodami *machine learning* mają istotne znaczenie praktyczne: mogą przyczynić się do optymalizacji pracy schronisk, lepszego alokowania zasobów oraz, co najważniejsze, ratowania większej liczby zwierząt poprzez skracanie czasu oczekiwania na nowy dom i uniknięcie śmierci.

Analizowany w niniejszej pracy zbiór danych obejmuje 162 390 dopasowanych epizodów pobytu (przyjęcie–wynik) zarejestrowanych w systemie AAC w latach 2013–2025, w tym 93 805 epizodów dotyczących psów oraz 68 585 dotyczących kotów.



Rysunek 1.1: Liczba przyjęć zwierząt do schroniska Austin Animal Center w kolejnych latach (2013–2025). Wyraźnie widoczny jest spadek wolumenu przyjęć w latach 2020–2021 związany z ograniczeniami pandemii COVID-19, a następnie stopniowy powrót do wartości sprzed pandemii.

Dotychczasowe badania wykazały obiecujące rezultaty w zakresie predykcji adopcji z wykorzystaniem uczenia maszynowego. Bradley i Rajendran [4] zaproponowali dwufazowy model predykcji czasu pobytu w schronisku, natomiast Sazara i Gao [5]



Rysunek 1.2: Liczba adopcji zarejestrowanych w AAC w kolejnych latach (2013–2025). Zestawienie z Rysunkiem 3.2 ilustruje zmienną relację między wolumenem przyj a skutecznością adopcji w poszczególnych latach.

zastosowali algorytm CatBoost do przewidywania czasu adopcji, uzyskując wysoką trafność i identyfikując wiek oraz rasę jako najważniejsze cechy. Niniejsza praca rozszerza te podejścia o chronologiczny podział danych, analizę interpretowalności SHAP oraz wdrożenie interaktywnego systemu decyzyjnego.

Warto tu wspomnieć o wymiarze etycznym. Dane wykorzystywane w niniejszej pracy pochodzą z publicznie dostępnych rejestrów Austin Animal Center i nie zawierają danych osobowych adopterów. Jednakże zastosowanie modeli predykcyjnych w kontekście schroniskowym wiąże się z ryzykiem utrwalenia istniejących uprzedzeń (np. dyskryminacji rasowej zwierząt). Dlatego model zaprojektowano jako narzędzie wspierające, a nie zastępujące decyzje personelu schroniska.

1.2 Cel, hipotezy i pytania badawcze

Celem niniejszej pracy jest opracowanie kompleksowego, zaawansowanego systemu analitycznego wykorzystującego metody uczenia maszynowego do prognozowania adopcji zwierząt na podstawie danych historycznych ze schroniska oraz identyfikacji najważniejszych czynników wpływających na przebieg tych adopcji. W szczególności praca skupia się na oszacowaniu prawdopodobieństwa adopcji oraz czasu oczekiwania na adopcję dla psów i kotów przyjętych do *Austin Animal Center* w latach 2013–2025. Osigniecie celu naukowego wymaga zbudowania dokładnego modelu predykcyjnego, ale wyzwaniem może być również zadbanie o jego interpretowalność oraz użyteczność praktyczną dla nietechnicznych

użytkowników. Ą Dlatego te celem wdroeniowym jest implementacja systemu, który integruje powstały model w formie interaktywnej aplikacji (*dashboard*) przeznaczonej dla personelu i wolontariuszy schroniska. System ten ma umożliwić eksplorację wyników predykcji (np. przewidywanego czasu adopcji danego zwierzęcia) oraz przeprowadzanie analiz typu co-jeli w celu wsparcia decyzji dotyczących działań ukierunkowanych na zwiększenie szans adopcyjnych.

Równolegle, celem analitycznym niniejszej pracy jest pogłębiona identyfikacja tych cech zwierząt oraz czynników zewnętrznych, które istotnie wpływają na zmniejszenie prawdopodobieństwa adopcji, co może stanowić podstawę do dalszych interwencji, zmian w działaniach operacyjnych lub kampanii adopcyjnych ukierunkowanych na najbardziej narażone grupy.

Aby zrealizować powyższe cele, sformuowano następujące kluczowe pytania badawcze:

1. **Które zmienne opisujące zwierzę oraz okoliczności jego przyjęcia do schroniska najsilniej wpływają na prawdopodobieństwo szybkiej adopcji?** Jakie cechy (np. wiek, rasa, umaszczenie, płeć, stan zdrowia, typ przyjęcia) wykazują największą moc predykcyjną w kontekście skrócenia lub wydłużenia czasu pobytu zwierzęcia w schronisku?
2. **Jak modele uczenia maszynowego wypadają na tle prostszych metod w zadaniu przewidywania adopcji zwierząt?** Innymi słowami, czy zastosowanie algorytmów klasy *ensemble* (np. gradient boosting w modelach XGBoost/CatBoost) zapewnia wyrażenie lepszej trafności prognoz niż podstawowe podejścia bazowe (takie jak proste modele regresyjne lub losowe strategię decyzji)?
3. **Czy istnieją istotne różnice w wzorcach adopcji między psami a kotami oraz jak te wzorce zmieniają się w czasie?** Pytanie to dotyczy zarówno ewentualnych odmiennych czynników wpływających na adopcję w zależności od gatunku, jak i trendów czasowych (np. czy w kolejnych latach obserwuje się poprawę skuteczności adopcji, zmiany sezonowe itp.).

Mając na uwadze powyższe pytania oraz przegląd literatury przedmiotu, przyjęto również kilka hipotez badawczych, które zostaną zweryfikowane w toku analizy:

H1: Sposób, w jaki zwierzę trafia do schroniska (np. jako bezdomne znajduje się przywiezione przez osoby miejskie, czy jako zwierzę oddane bezpośrednio przez właściciela), ma istotniejszy wpływ na prawdopodobieństwo i tempo jego adopcji niż cechy wyglądu. Innymi słowami, zakłada się, że typ przyjęcia (ang. *intake type*) stanowi silniejszy prognostyk sukcesu adopcyjnego niż przynależność do konkretnej rasy.

- H2:** Występuje wyrany efekt sezonowości w przebiegu adopcji. Pewne okresy w roku (np. miesiące letnie lub okolice przerw witecznych) sprzyjają szybszym adopcjom, skracając średni czas pobytu zwierząt w schronisku, podczas gdy w innych okresach tempo adopcji spada. Hipoteza ta opiera się na założeniu, że czynniki zewnętrzne (takie jak wakacje, kampanie społeczne czy warunki pogodowe) wpływają na popyt na adopcje.
- H3:** Wiek zwierzęcia ma istotny wpływ na jego szanse adopcyjne – młodsze zwierzęta są adoptowane szybciej niż starsze. Zgodnie z obserwacjami z praktyki schroniskowej, szczeniaki i kociaki cieszą się większym zainteresowaniem niż osobniki dorosłe lub starsze.
- H4:** Umaszczenie zwierzęcia wpływa na prawdopodobieństwo adopcji – zwierzęta o ciemnym umaszczeniu (np. czarne psy i koty) są adoptowane rzadziej. Zjawisko to, znane jako *black dog syndrome*, jest często przytaczane w mediach, choć literatura naukowa nie jest w tej kwestii jednogłosa [6]. W ramach pracy zweryfikowane zostanie, czy w danych z AAC zjawisko to jest rzeczywiście obserwowalne.
- H5:** Pandemia COVID-19 (2020–2021) spowodowała istotne zmiany w dynamice adopcji zwierząt: w roku 2020 odnotowano wzrost wskaźnika adopcji i skrócenie mediany czasu pobytu (tzw. *pandemic adoption surge*), natomiast rok 2021 przyniósł częściowe odwrócenie tego trendu wraz ze stopniowym powrotem do normalnej działalności schroniska.

Powysze hipotezy zostaną poddane weryfikacji w dalszych rozdziałach pracy. Analiza ich trafności pozwoli nie tylko odpowiedzieć na postawione pytania badawcze, lecz także lepiej zrozumieć dynamik procesów adopcyjnych. Praca obejmuje pełny cykl projektowy: od analizy danych i budowy modeli predykcyjnych po wdrożenie działającego systemu wspierającego decyzje w schronisku.


1.3 Zakres i struktura pracy

Zakres analizy obejmuje dane historyczne pochodzące z *Austin Animal Center* z lat 2013–2025, które zawierają informacje zarówno o przyjęciach zwierząt do schroniska (*intake*), jak i o ich dalszych losach (*outcome*, w szczególności adopcjach). Dane te pozwalają prześledzić pełny cykl pobytu zwierzęcia w schronisku – od momentu znalezienia lub oddania, a do chwili adopcji lub innego zakończenia opieki. W pracy skoncentrowano się na dwóch dominujących w schronisku gatunkach, tj. psach i kotach, z pominięciem mniej licznych gatunków egzotycznych. Analizy zostały przeprowadzone oddzielnie dla psów i kotów wszędzie tam, gdzie było to zasadne, aby uchwycić ewentualne różnice między

Tabela 1.1: Zestawienie głównych hipotez badawczych weryfikowanych w pracy.

Identyfikator	Tre hipotezy
H1	Typ przyjęcia do schroniska ma istotniejszy wpływ na prawdopodobieństwo i tempo adopcji niż cechy wyglądu (np. rasa).
H2	Występuje wyraźna sezonowość w adopcjach, wpływająca na czas pobytu zwierząt w schronisku w zależności od pory roku.
H3	Młodsze zwierzęta (szczeniaki, kociaki) mają wyższe szanse na szybką adopcję w porównaniu do starszych osobników.
H4	Zjawisko „black dog syndrome” (rzadsze adopcje zwierząt o ciemnym umaszczeniu) jest zauważalne w analizowanym zbiorze danych.
H5	Pandemia COVID-19 (2020–2021) wpłynęła na dynamikę adopcji oraz zmiany w średnim czasie pobytu zwierząt.

tymi grupami. Pod względem merytorycznym praca dotyczy zagadnienia z obszaru nauk o danych (data science), uczenia maszynowego oraz inżynierii oprogramowania, co znajduje odzwierciedlenie w strukturze pracy.



Rysunek 1.3: Schemat blokowy metodyki badawczej i przepływu pracy (pipeline MLOps).

Rozdział niniejszej pracy został ułożony w taki sposób, aby stopniowo wprowadzać czytelnika w temat i następnie przejść do szczegółów implementacyjnych rozwiązania. Rozdział 2 przedstawia przegląd literatury oraz teoretyczne podstawy związane z problematyką bezdomności zwierząt i adopcji w kontekście zarządzania schroniskami. Omówiono w nim

kluczowe pojęcia (takie jak zasada *No-Kill* czy metryki w pracy schronisk), a także metody analizy danych i algorytmy uczenia maszynowego wykorzystywane dotychczas do rozwiązywania podobnych problemów. Rozdział 3 zawiera opis danych wykorzystanych w badaniu ród i charakterystyk zbioru danych z AAC, sposób ich wstępnego przetworzenia oraz analiz eksploracyjny (EDA). Celem tej części jest zrozumienie struktury danych, wstępna identyfikacja trendów i potencjalnych zależności (np. typowe przedziały wiekowe zwierząt, sezonowo przyjęć i adopcji, itp.) oraz przygotowanie odpowiedniego zestawu cech do modelowania.

W Rozdziale 4 przedstawiono metodologię budowy modeli predykcyjnych. Opisano proces doboru cech (*feature engineering*) istotnych z punktu widzenia przewidywania adopcji, a także wybrane algorytmy uczenia maszynowego. Szczególnie uwagę poświęcono modelom typu *gradient boosting*, takim jak XGBoost i CatBoost, ze względu na ich wysoką skuteczność w zadaniach z danymi tabelarycznymi. Omówiono konfigurację tych modeli, strategię walidacji krzywej oraz metryki oceny, które pozwolą na porównanie ich z prostszymi modelami bazowymi. Rozdział 5 prezentuje uzyskane wyniki eksperymentów. Przedstawiono w nim porównanie jakości predykcji różnych modeli (m.in. porównanie modeli *gradient boosting* z modelami liniowymi) oraz analizę interpretowalności najlepszego modelu. Wykorzystano do tego techniki objaśniania decyzji czarnej skrzynki, w szczególności wartości SHAP (*Shapley Additive Explanations*), które pozwalają określić wpływ poszczególnych cech (np. wieku, rasy, typu intaku) na przewidywane prawdopodobieństwo adopcji. Taka analiza dostarcza cennych informacji, czy model podejmuje decyzje w sposób zgodny z intuicją i wiedzą dziedzinową (np. czy potwierdza, że modele zwierząt adoptowane są szybciej), a także może ujawnić nieoczywiste zależności w danych.

Rozdział 6 koncentruje się na aspekcie inżynierskim rozwiązania, opisując zastosowane podejście *MLOps* do zapewnienia powtarzalności i niezawodności procesu analitycznego. W rozdziale tym omówiono, w jaki sposób stworzony model i towarzyszący mu kod zostały zintegrowane w ramach tzw. potoku przetwarzania (*pipeline*) obejmującego: wersjonowanie danych i eksperymentów z użyciem narzędzia DVC (*Data Version Control*), konteneryzację środowiska i zależności za pomocą Dockera, oraz automatyzację trenowania i wdrażania modelu z wykorzystaniem ciągłej integracji i dostarczania (CI/CD, np. na platformie GitHub Actions). Rozdział 7 przedstawia zaprojektowaną aplikację internetową (dashboard) służącą jako interfejs użytkownika dla opracowanego modelu. Opisano funkcjonalności prototypowej aplikacji stworzonej w technologii *Streamlit* m.in. możliwość sprawdzania prognoz dla wybranego zwierzęcia, symulacji scenariuszy (np. jak zmiana pewnych cech wpływa na przewidywane szanse adopcji), czy przegląd globalnych statystyk i trendów. Rozdział ten ukazuje, jak wyniki zaawansowanej analizy danych mogą zostać opakowane w przystępne narzędzie wspierające

codzienn prac schroniska. Wreszcie, Rozdział 8 to podsumowanie uzyskanych wyników oraz wnioski. Zawarto w nim omówienie stopnia realizacji celu pracy, weryfikację hipotez w świetle przeprowadzonych analiz oraz rekomendacje dotyczące wdrożenia wypracowanych rozwiązań w praktyce. Przedstawiono także propozycje dalszych kierunków rozwoju zarówno jeśli chodzi o ulepszenia modelu (np. uwzględnienie dodatkowych danych lub zastosowanie alternatywnych technik uczenia), jak i rozszerzenie funkcjonalności systemu dla schroniska.

Niniejsza praca stanowi zatem poczynienie badań nad danymi schroniska z praktycznym wdrożeniem rozwiązania informatycznego. Wkład własny autora przejawia się zarówno w warstwie analitycznej, jak i inżynierskiej. Od strony analitycznej obejmuje on przygotowanie i oczyszczenie zbioru danych, przeprowadzenie eksploracji w celu sformułowania hipotez, a następnie zaprojektowanie i wytrenowanie modeli predykcyjnych dostosowanych do specyfiki danych AAC. Od strony inżynierskiej, istotnym elementem pracy jest zaprojektowanie i zaimplementowanie kompletnego procesu MLOps. Obejmuje to m.in.: zautomatyzowanie procesu trenowania modelu i aktualizacji prognoz, wprowadzenie kontroli wersji dla danych i modeli (co zapewnia odtwarzalność wyników), konteneryzację aplikacji dla ułatwienia jej uruchomienia na dowolnej platformie, oraz integrację tych komponentów w ramach ciągłej integracji/dostarczania. Dodatkowo, autor stworzył aplikację webową, która udostępnia wyniki modeli szerszemu gronu odbiorców w intuicyjnej formie. Dzięki temu podejściu, praca nie tylko odpowiada na postawione pytania badawcze, ale również dostarcza narzędzia mogącego znaleźć praktyczne zastosowanie w poprawie efektywności działania schronisk dla zwierząt.

Rozdzia 2

Podstawy teoretyczne i przegląd literatury

2.1 Problem bezdomności zwierząt i filozofia No-Kill

Zjawisko bezdomności zwierząt to poważny problem społeczny i ekologiczny na całym świecie. Szacuje się, że globalna populacja bezdomnych psów i kotów liczona jest w setkach milionów [7]. Szczególnie dotkliwie problem ten występuje w Stanach Zjednoczonych, gdzie każdego roku do schronisk trafia ponad 6 milionów porzuconych lub bezdomnych zwierząt domowych. Historycznie wysoki odsetek z nich był poddawany eutanazji z braku miejsc i możliwości adopcji – jeszcze kilkanaście lat temu umiercano miliony psów i kotów rocznie, co stanowiło znaczny procent wszystkich przyjmowanych zwierząt [4].

W ostatnich latach, dzięki upowszechnieniu sterylizacji, licznym kampaniom adopcyjnym oraz zmianie podejścia do zarządzania schroniskami, sytuacja zaczęła się stopniowo poprawiać. Obecnie do amerykańskich schronisk wchodzi rocznie ok. 6,3 mln zwierząt, a liczba eutanazji znacząco spada w porównaniu do dekadzie ubiegłej [1]. Trend ten odzwierciedla globalny zwrot w kierunku bardziej humanitarnego traktowania bezdomnych zwierząt, którego centralnym elementem jest filozofia *No-Kill*.

Filozofia *No-Kill* zakłada rezygnację z rutynowej eutanazji zwierząt w schronisku wyłącznie z powodu braku miejsc – wszystkie zdrowe lub rokujące na wyleczenie zwierzęta powinny pozostać przy życiu i oczekiwać na adopcję tak długo, jak będzie to konieczne. W praktyce za schronisko *no-kill* uznaje się placówki osiągające co najmniej 90% tzw. współczynnika ocalenia (ang. *save rate*), czyli odsetka zwierząt opuszczających schroniska żywych [3]. Takie podejście wymaga wdrożenia szeregu strategii zwiększających liczb

udanych adopcji oraz zmniejszających napływ nowych zwierząt do systemu (m.in. programy sterylizacji, rozbudowa wolontariatu).

Przykładem skutecznej realizacji idei No-Kill jest miasto Austin w Teksasie. W 2010 r. władze Austin przyjęły kompleksowy plan działań, którego celem było osiągnięcie statusu no-kill, a już w kolejnym roku miejskie schronisko Austin Animal Center przekroczyło próg 90% uratowanych zwierząt [3]. Od tego czasu Austin utrzymuje reputację największego miasta *No-Kill* w USA. Sukces ten zainspirował wiele innych społeczności – w ostatnich latach odsetek amerykańskich schronisk deklarujących status no-kill znacząco wzrósł [1]. Należy jednak podkreślić, że status ten nie oznacza całkowitego wyeliminowania eutanazji: nadal umierają z zwierzęta powalone chore lub niebezpieczne, lecz nie dopuszcza się upienienia zdrowego zwierzęcia z powodów ekonomicznych.

Dane gromadzone w schroniskach stanowią cenne źródło informacji do oceny efektywności adopcji. Większość schronisk prowadzi szczegółową ewidencję przyjęć (ang. *intake*) i opuszczeń (ang. *outcome*) zwierząt, co pozwala łączyć m.in. czas pobytu (*length of stay*), stan zdrowia, rasę czy wiek. Analiza takich danych umożliwia wyliczenie kluczowych mierników operacyjnych i zastosowanie zaawansowanych metod analitycznych w celu **predykcji** wyników adopcji. Przykładowo, badania wskazują, że cechy takie jak wiek czy wielkość zwierzęcia istotnie wpływają na tempo jego adopcji – szczeniaki znajdujące domy szybciej niż psy starsze, a zwierzęta o umaszczeniu odbiegającym od preferowanego mogą oczekiwać na adopcję dłużej [4]. Zjawisko to, często określane mianem *Black Dog Syndrome* (syndrom czarnego psa), sugeruje, że psy o ciemnym umaszczeniu są rzadziej wybierane przez adoptujących [8, 9, 6]. Ponadto istotne znaczenie w procesie adopcji odgrywają interakcje między zwierzęciem a potencjalnym opiekunem w schronisku [10].

2.2 Predykcyjne modelowanie adopcji

Wyzwania związane z poprawą wskaźników adopcji przyczyniły się do rosnącego zainteresowania metodami predykcyjnymi. Modelowanie to polega na wykorzystaniu metod statystycznych oraz algorytmów uczenia maszynowego do przewidywania, czy i kiedy dane zwierzę zostanie adoptowane. Modele uczą się na danych historycznych w celu uchwycenia zależności między cechami zwierzęcia a wynikiem adopcyjnym [5].

Do najprostszych metod predykcji należą modele statystyczne, w tym regresja logistyczna. W modelu tym prawdopodobieństwo adopcji $P(y = 1|X)$ dla wektora cech

X modelowane jest za pomoc funkcji logistycznej:

$$P(y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}} \quad (2.1)$$

gdzie β_0 to wyraz wolny, $\beta_1, \dots, \beta_n$ to współczynniki regresji odpowiadające poszczególnym cechom, za $x_1, \dots, x_n$ to wartoci cech opisujcych dane zwierz.

Cho regresja cechuje si wysok interpretowalnoci, ma ograniczon zdolno chwytania nieliniowych zalenoci. Dlatego coraz czciej siga si po metody o wikszej mocy predykcynnej, takie jak zespy drzew decyzyjnych, które w przeciwiestwie do modeli gbokiego uczenia (ang. *Deep Learning*) wykazuj wysz skuteczno na typowych danych tabelarycznych [11].

Lasy losowe (*Random Forests*), zaproponowane przez Breimana [12], cz przewidywania wielu niezalenie trenowanych drzew decyzyjnych, co zmniejsza wariancj modelu i zapobiega przeuczeniu. Alternatywnym, potnym podejciem s algorytmy z rodziny *gradient boosting* [13], które iteracyjnie buduj drzewa, gdzie kade kolejne drzewo stara si zminimalizowa funkcj straty $\mathcal{L}$ z poprzednich iteracji. W przypadku binarnej klasyfikacji czsto stosowan funkcj straty jest *log-loss*:


$$\mathcal{L}(y, \hat{p}) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)] \quad (2.2)$$

gdzie N to liczba próbek treningowych, $y_i \in \{0, 1\}$ to rzeczywista etykieta klasy (1 – adoptowane), a $\hat{p}_i$ to prognozowane prawdopodobieństwo adopcji dla i -tej próbki.

Najbardziej rozpowszechnionymi algorytmami tego typu s XGBoost [14] oraz LightGBM [15]. W ostatnich latach popularno zyska równie CatBoost biblioteka zoptymalizowana do przetwarzania cech kategoriycznych bez koniecznoci obszernego kodowania zmiennych (ang. *categorical encoding*), np. *one-hot encodingu* [16]. W kontekcie danych schroniskowych, które obfituj w atrybuty kategoriyczne (rasa, umaszczenie, typ przyjcia), optymalne metody kodowania zmiennych oraz radzenie sobie z czsto wystpujczym problemem niezbilansowanych klas (ang. *class imbalance*) [17] odgrywaj kluczow rol w trenowaniu modeli. Badania z wykorzystaniem danych schroniskowych, m.in. praca Szary i in. (2022), wykazay, e zaawansowane modele klasyfikacyjne potrafi z du dokadnoci przewidywa szybko adopcji, identyfikujc wiek i ras jako kluczowe predyktory sukcesu [5].

Ocen jakoci modeli klasyfikacyjnych przeprowadza si z uciem krzywej ROC (ang. *Receiver Operating Characteristic*), która dla rónych progów decyzyjnych modelu ilustruje zaleno midzy czuoci (ang. *True Positive Rate*, TPR) a odsetkiem faszywych alarmów (ang.

False Positive Rate, $FPR = 1 - \text{swoisto}$). Pole pod tą krzywą, czyli metryka AUC (ang. *Area Under the Curve*), pozwala ocenić zdolność modelu do rozróżniania klas [18]. Do weryfikacji trafności probabilistycznych predykcji stosuje się także wskaźnik Briera (ang. *Brier Score*) [19]. Do modelowania czasu do zdarzenia (np. długi pobytu w schronisku) stosuje się analizę przeżycia, wykorzystując takie narzędzia jak estymator Kaplana-Meiera [20] i model proporcjonalnego hazardu Coxa [21].




Rysunek 2.1: Krzywe Kaplana-Meiera szacujące prawdopodobieństwo pozostania w schronisku bez adopcji, w podziale na gatunek zwierzęcia (dane Austin Animal Center, 2013–2025). Spadek krzywej odpowiada momentom adopcji; krzywe ucinane są przez obserwacje ocenzone.

Istotnym elementem projektowania modeli jest także ocena **istotności cech** oraz interpretowalność. Zoone modele zespołowe działają często jak czarne skrzynki. Metoda SHAP (*Shapley Additive Explanations*) [22] pozwala na alokację wkładu każdej cechy do ostatecznej predykcji modelu, w oparciu o wartości Shapleya z teorii gier:

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} (v(S \cup \{i\}) - v(S)) \quad (2.3)$$

gdzie ϕ_i to wartość Shapleya dla cechy i , N to zbiór wszystkich cech, a $v(S)$ to przewidywanie modelu dla podzbioru cech S . Metoda ta pozwala określić, w jaki sposób konkretna cecha (np. czarne umaszczenie) wpływa na obniżenie lub podwyższenie prawdopodobieństwa adopcji dla danego zwierzęcia.

Przegląd najistotniejszych prac badawczych wykorzystujących uczenie maszynowe do analizy danych schroniskowych zestawiono w Tabeli 2.1.



Rysunek 2.2: Podsumowanie wartoci SHAP dla modelu klasyfikacji adopcji (CatBoost). Kady punkt reprezentuje jedn obserwacj; kolor koduje warto cechy (czerwony – wysoka, niebieski – niska). Cechy posortowane malejco wedug redniej bezwzgdnej wartoci SHAP.

Tabela 2.1: Zestawienie wybranych prac dotyczcych modelowania adopcji zwierz

Publikacja	Zastosowane algorytmy	Kluczowe wnioski
Bradley i Rajendran (2021) [4]	Regresja logistyczna, Analiza przeycia	Wiek i wielko psa silnie wpywaj na czas do adopcji. Optymalna alokacja zasobów schroniska.
Sazara i Gao (2022) [5]	CatBoost, XGBoost	Drzewa wzmacniane gradientowo osigaj wysok precyzj, uyto SHAP do interpretacji.
Cain i in. (2020) [9]	Lasy losowe, SVM	Umaszczenie (np. Black Dog Syndrome) oraz rasa wpywaj na preferencje adoptujcych.
Hawes i in. (2022) [23]	LightGBM, Random Forest	Algorytmy ensemble s skuteczne w przewidywaniu ryzyka przeduonego pobytu w schronisku.

2.3 Reprodukowalno i inżynieria danych (MLOps)

Wraz z rozwojem projektów z zakresu sztucznej inteligencji pojawia się potrzeba wypracowania praktyk zapewniających reprodukowalność badań. Odpowiedzią na te wyzwania jest podejście MLOps (*Machine Learning Operations*), które integruje proces projektowania modeli z ich wdrażaniem, testowaniem i utrzymaniem [24]. W kontekście badań opartych na uczeniu maszynowym, infrastruktura MLOps pozwala na standaryzację całego cyklu życia modelu.

Jednym z filarów MLOps jest zagwarantowanie spójnego środowiska uruchomieniowego. Dzięki do tego konteneryzacja, najczęściej realizowana z użyciem technologii Docker. Zapewnia ona, że kod trenujący model, wraz ze wszystkimi zależnościami, będzie działał identycznie niezależnie od środowiska (np. u lokalnego dewelopera czy na serwerze obliczeniowym), co jest kluczowe dla reprodukowalności badań naukowych [25].

Kolejnym ważnym elementem jest wersjonowanie danych i eksperymentów. W przeciwieństwie do kodu, który skutecznie podlega kontroli wersji w systemie Git, dane zbiory danych i binarne pliki modeli wymagają innych narzędzi. W niniejszej pracy wykorzystano narzędzie DVC (*Data Version Control*), które umożliwia śledzenie zmian w zbiorach danych, budowanie powtarzalnych potoków (*pipelines*) transformacji i uczenia modelu oraz gwarantuje pełną historię eksperymentów [26]. Do szczegółowego śledzenia metryk (np. dokładności na zbiorze walidacyjnym) i hiperparametrów podczas procesu uczenia wykorzystuje się systemy do *experiment tracking* (np. MLflow czy Weights & Biases).

Cały proces podlega automatyzacji za pomocą praktyk CI/CD (*Continuous Integration* i *Continuous Deployment*). CI/CD pozwala na automatyczne sprawdzanie jakości kodu (ang. *linting*), uruchamianie testów jednostkowych, a także weryfikację poprawności trenowanych modeli przy każdej zmianie w repozytorium. Tego rodzaju automatyzacja minimalizuje ryzyko wprowadzenia błędów i zapewnia stałą jakość dostarczanych rozwiązań. Ostatnim etapem jest prezentacja wyników, zrealizowana w tej pracy za pomocą biblioteki Streamlit, pozwalającej na tworzenie interaktywnych wizualizacji danych i udostępnianie wyników interesariuszom w postaci aplikacji webowej [27].

Rozdzia 3

Dane i przygotowanie zbioru badawczego

W niniejszym rozdziale opisano proces przygotowania zbioru danych do analizy statystycznej. Jednostk obserwacji w badaniu jest epizod pobytu zwierzcia w schronisku, rozumiany jako pojedyncze przyjcie, przypisany do niego wynik koczcy pobyt oraz zestaw cech znanych w momencie przyjcia, czyli cech *intake-time-only*. W rozdziale przedstawiono kolejne etapy przeksztaconia danych surowych do postaci analitycznej.

3.1 ródo danych i zakres analizy

Materia empiryczny pochodzi ze schroniska Austin Animal Center (AAC) i zosta pobrany z bazy Austin Open Data. Baza obejmuje dwie tabele: rejestr przyj zwierzt (*intakes*) oraz rejestr wyników koczcy pobyt (*outcomes*). Opcjonalnie dane wzbogacono o zmienne kontekstowe, takie jak pogoda.

Zakres czasowy badania obejmuje przyjcia od 1 padziernika 2013 roku do 4 maja 2025 roku. Analiz ograniczono do psów i kotów, poniewa stanowi one zasadnicz cz populacji schroniskowej. Uwzglndnienie rzadziej wystpujcych gatunków, na przykad dzikich zwierzt, mogoby obniy stabilno estymacji.

Wykorzystane dane maj charakter obserwacyjny. Pochodz z rutynowej dokumentacji schroniska, a nie z kontrolowanego eksperymentu. Z tego powodu analiza obejmuje wycznie relacje statystyczne midzy atrybutami zwierzcia znanymi w momencie przyjcia a wynikiem pobytu. Nie formuuje si na tej podstawie wniosków przyczynowo-skutkowych.

3.2 Charakterystyka zbiorów wejciowych

Zbiór analityczny czy dane o przyjęciu z danymi o wyniku kocowym. Rozdzielenie tych warstw na etapie modelowania pozwala ograniczyć ryzyko wykorzystania informacji z przyszłości, czyli wycieku danych.

Tabela 3.1: Porównanie dwóch podstawowych zbiorów wejciowych

Warstwa danych	Przykładowe pola kluczowe	Rola w procesie
Rejestr przyj	animal_id, animal_type, intake_datetime, intake_type, intake_condition, sex_upon_intake, age_upon_intake, breed, color	różno atrybutów wejciowych (X)
Rejestr wyników	animal_id, animal_type, outcome_datetime, outcome_type, outcome_subtype, sex_upon_outcome	różno zmiennej docelowej (y)

Metadane generowane na kocu pobytu, takie jak `outcome_type` i `outcome_datetime`, wyodrębniono jako zmienne docelowe. Podział ten zapisano w oddzielnych plikach konfiguracyjnych JSON dla cech oraz targetów.

3.3 Standaryzacja i czyszczenie danych

Czyszczenie danych przeprowadzono ostrożnie, bez sztucznej imputacji braków. Nazwy zmiennych zapisano w formacie `snake_case`. Daty ujednolicono do lokalnej strefy czasowej schroniska, konwertując ciągi znaków do formatu `datetime64`.

Sprawdzono kompletno kluczowych atrybutów: `animal_id`, `animal_type`, `intake_datetime`, `outcome_datetime` oraz `outcome_type`. Obserwacje z brakami w tych polach usunęto. Dokładne duplikaty rekordów zostały odfiltrowane.

Tabela 3.2: Redukcja liczby rekordów w kolejnych etapach budowy zbioru modelowego

Zbiór danych na danym etapie	Liczba wierszy	Liczba usunitych
Zbiór różowy wej (<code>intakes.csv</code>)	173 812	—
Zbiór różowy wyj (<code>outcomes.csv</code>)	173 775	—
Standaryzacja i filtracja wej	163 901	9 911
Standaryzacja i filtracja wyj	163 880	9 895
Dopasowane epizody z targetem	162 390	1 511
Finalny zbiór modelowy	162 390	0


Większość usunitych rekordów dotyczy zwierząt innych niż psy i koty. Usunęto również 1 511 przyjęć pozbawionych chronologicznie poprawnego wyniku kocowego. W modelowaniu

nadzorowanym potraktowano je jako obserwacje bez dostępczej etykiety docelowej i wykluczono z finalnego zbioru; w ujęciu analizy przeżycia mogłyby być one rozważane jako obserwacje cenzorowane. Brakujące dane w atrybutach predykcyjnych występowały pojedynczo: odnotowano 9 braków wieku i 1 brak pci.

3.4 Konstrukcja epizodów i dopasowanie rekordów

Jednostką analizy jest epizod pobytu. Ponieważ to samo zwierzę (`animal_id`) może być kilkakrotnie rejestrowane w schronisku, każde przyjęcie poczyniono z najbliższym w czasie, niewykorzystanym wcześniej wynikiem. Zastosowano więc metodę najbliższego wolnego zdarzenia w czasie, aby odtworzyć możliwie spójną historię pobytu.

Taka procedura zapobiega powstawaniu ujemnych czasów pobytu oraz wielokrotnemu przypisaniu tego samego wyniku do różnych przyjęć. Audyt zbioru potwierdził poprawność cenzury — nie odnotowano epizodów nakładających się w czasie.



Rysunek 3.1: Porównanie strategii dopasowania rekordów przyjęcia i wyniku.

3.5 Zmienne docelowe

Zdefiniowano dwie główne zmienne docelowe przeznaczone do późniejszego modelowania:

Tabela 3.3: Formalne definicje zmiennych docelowych

Zmienna	Definicja	Interpretacja
classification_target	1 dla Adoption, 0 dla innych	Binarny wynik adopcji
regression_target_days	$(outcome_time - intake_time) \div 86400$	Długo pobytu do dowolnego wyniku (adopcja, transfer, eutanazja lub zgon)
days_to_adoption	Warto regression_target_days dla adoptowanych	Stosowana wycennie w opisowej analizie czasu oczekiwania (nie jako cel modelowania regresji)

Adopcję zakończyło się 50,87% uwzględnionych epizodów, czyli 82 609 przypadków. Pozostałe 49,13% obejmuje powroty do waciciela, transfery, eutanazję oraz zgony. Czas do dowolnego zdarzenia potraktowano jako klasyczny problem regresji, ponieważ długo zajmowania boksu przekłada się bezpośrednio na koszty operacyjne placówki.

3.6 Konstrukcja cech wejściowych

Cechy wejściowe zbudowano wycennie na podstawie informacji dostępnych w chwili przyjęcia.

Tabela 3.4: Grupy cech wejściowych

Grupa	Zmienne
Cechy ogólne	animal_type, sex_upon_intake, intake_condition
Wiek	age_days, age_years, age_group (np. baby, senior)
Rasa	breed, primary_breed, simplified_breed_group
Umaszczenie	color, primary_color, simplified_color_group
Kontekst przyjęcia	intake_season, intake_type, covid_period
Cechy binarne	has_name, is_mixed_breed, is_black_or_dark
Cechy czasowe	intake_month, intake_year, intake_season

Aby ograniczyć liczbę kategorii, rasy i umaszczenia pogrupowano w szersze klasy, takie jak pit_bull_type, terrier_type czy domestic_cat. Oryginalna zmienna


opisująca ras zawiera 2 761 unikalnych wartości, z których większość występuje bardzo rzadko.

Na podstawie daty przyjęcia zdefiniowano okresy związane z pandemią: przed COVID-19, czyli do 1 marca 2020 r.; w trakcie pandemii, od marca 2020 do grudnia 2021; oraz po pandemii, od 1 stycznia 2022 r. Wiek przekształcono z wartości tekstowych, na przykład `2 years`, do postaci w pełni numerycznej w dniach oraz do kategorii wiekowych.

Cechy wejściowe przebadano pod kątem multikolinearności za pomocą wskaźnika VIF (ang. *Variance Inflation Factor*). Za próg krytyczny przyjęto $VIF > 10$. Analiza wykazała krytyczną redundancję pomiędzy wariantami reprezentacji wieku: `age_days` uzyskała wartość $VIF = 2971$, a `age_group_senior` — $VIF = 4341$. Warianty liniowo zależne od siebie zredukowano do jednej numerycznej reprezentacji. Modele drzewiaste są odporne na multikolinearność, jednak ograniczenie redundancji zmniejsza przestrzeń cech i przyspiesza uczenie.


3.7 Charakterystyka opisowa zbioru

Zbiór obejmujący 162 390 pobyty pozwala przedstawić podstawowe statystyki opisowe. Najważniejsze wskaźniki zmieniały się w czasie:



Rysunek 3.2: Roczna liczba przyjęć zwierząt do Austin Animal Center w latach 2013–2025.

- **Przed COVID-19 (108 785 epizodów):** wskaźnik adopcji wynosi 46,3%, a mediana całkowitej długości pobytu, liczona dla każdego wyniku, była równa 5,25 dnia.



Rysunek 3.3: Roczna liczba adopcji w Austin Animal Center.

- **COVID-19 (17 946 epizodów):** wskanik adopcji wzrósł do 57,2%, a mediana pobytu do 8,01 dnia.
- **Post COVID-19 (35 624 epizodów):** wskanik adopcji wyniósł 61,5%, a mediana pobytu 9,83 dnia.

Zmiany te zbiegają się ze zmianami struktury przyjmowanych zwierząt. Odsetek psów spadł z 60,45% w okresie przedpandemicznym do 50,65%. Jednocześnie odsetek młodych zwierząt (baby) wzrósł z 44,11% do 54,34%.


Psy i koty różnią się pod względem dynamiki adopcji. Ogólny wskanik adopcji był zbliżony dla obu grup: 50,28% dla psów i 51,68% dla kotów. Wśród zwierząt adoptowanych do 30 dni schronisko opuszcza jednak 73,6% psów i 54,5% kotów.

Prawdopodobieństwo adopcji maleje wraz z wiekiem zwierzęcia. Grupa najmłodsza (baby) charakteryzuje się wskanikiem adopcji na poziomie 59,7%, młodzie (young) — 47,5%, zwierzęta dorosłe (adult) — 39,6%, a starsze (senior) — 31,0%.


Sposób przyjęcia również wie się ze znaczną zmiennością wyników. Wśród 116 393 zwierząt znalezionych na ulicy (Stray) adopcję zakończyło się 48,7% pobytów. Natomiast wśród 34 142 zwierząt wacielskich (Owner Surrender) wskanik ten wyniósł 67,1%.

3.8 Ograniczenia danych


Wykorzystany zbiór danych ma kilka ograniczeń.




Rysunek 3.4: Skumulowane krzywe adopcji dla psów i kotów.




Rysunek 3.5: Krzywe Kaplana-Meiera prawdopodobieństwa adopcji w funkcji czasu pobytu, z podziałem na psy i koty.



Rysunek 3.6: Krzywe Kaplana-Meiera czasu do adopcji w podziale na grupy wiekowe zwierząt (wycznie adoptowane). Zwierzęta z grupy `baby` opuszczają schronisko najszybciej; krzywa dla grupy `senior` opada wolniej i osiąga niższy poziom skumulowanej adopcji.



Rysunek 3.7: Krzywe Kaplana-Meiera czasu do adopcji według sposobu przyjęcia (wycznie adoptowane). Zwierzęta przyjęte w ramach zrzecze wacicielskich (`Owner Surrender`) trafiają do nowych domów szybciej niż bezpaskie (`Stray`).



Rysunek 3.8: Porównanie wskaźników adopcji między typowymi profilami zwierząt.

Po pierwsze, pochodzi z placówki no-kill, czyli schroniska utrzymującego wysoki współczynnik uratowa i niestosującego rutynowej eutanazji zdrowych zwierząt [3]. Wyniki mogą więc różnić się od wyników uzyskanych dla schronisk o innej specyfice działania.

Po drugie, wpisy dotyczące rasy i umaszczenia są deklaracją pracownika dokonaną przy przyjęciu, a nie wynikiem badań genetycznych. Etykiety takie jak `pit_bull_type` odzwierciedlają administracyjny sposób kategoryzacji psów oraz ludzką percepcję ich wyglądu.

Ograniczeniem technicznym było wykluczenie pobytów bez jednoznacznie zakończonego wyniku, co wynika z wymogu posiadania etykiety docelowej w nadzorowanym uczeniu maszynowym.

3.9 Podsumowanie przygotowania danych

W wyniku opisanych przekształceń utworzono finalny zbiór modelowy obejmujący 162 390 epizodów pobytu psów i kotów w Austin Animal Center. Każdy rekord reprezentuje pojedyncze przyjęcie zwierzęcia, zestaw cech znanych w momencie tego przyjęcia oraz chronologicznie dopasowany wynik kocowy. Taka konstrukcja pozwala analizować proces pobytu z perspektywy informacji dostępnych przed rozstrzygnięciem sprawy zwierzęcia, a jednocześnie ogranicza ryzyko wycieku danych z przyszłości.

Najważniejszymi decyzjami przygotowawczymi były: ograniczenie populacji do psów i kotów, usunięcie rekordów bez podstawowych znaczników czasu i wyniku, dopasowanie

przyj do najbliższych niewykorzystanych wyników oraz przekształcenie zmiennych opisowych do postaci moliwej do wykorzystania przez modele statystyczne. Szczególnie uwag zwrócono na zmienne, które mogłyby być dostępne dopiero po zakończeniu pobytu, ponieważ ich użycie prowadzioby do sztucznego zawyżenia jakości predykcji.

Przygotowany zbiór stanowi podstawę dwóch zadań empirycznych rozwijanych w kolejnych rozdziałach: klasyfikacji prawdopodobieństwa adopcji oraz regresji długości pobytu do dowolnego dopasowanego wyniku. Rozdział następny opisuje metody modelowania, sposób podziału danych w czasie, dobór algorytmów oraz metryki użyte do oceny uzyskanych modeli.

Rozdzia 4

Metodyka modelowania i oceny modeli

W rozdziale przedstawiono metodyk budowy i oceny modeli predykcyjnych. Problem badawczy sformuowano jako dwa odrbne zadania: klasyfikacj binarn, czyli przewidywanie adopcji wzgldem innych wyników, oraz regresj, czyli przewidywanie liczby dni do zakoczenia pobytu. Zrezygnowano z analizy przeycia (ang. *survival analysis*) na rzecz prognozowania cakowitej dugoci pobytu (ang. *length of stay*). W rozdziale opisano podzia zbioru, dobór algorytmów uczcych oraz zastosowane metryki oceny. Omówiono równie interpretacj wyników z wykorzystaniem wartoci SHAP oraz protokół badawczy sucy zapewnieniu odtwarzalnoci oblicze.

Tabela 4.1: Etapy procesu modelowania i oceny

Etap badawczy	Dziaanie
1. Przygotowanie cech	Wykorzystanie zbioru zdefiniowanego w rozdziale 3. Wykluczenie atrybutów rejestrowanych po przyjciu w celu uniknienia wycieku informacji (ang. <i>data leakage</i>).
2. Podzia danych	Podzia chronologiczny: zbiór treningowy (2013–2021), walidacyjny (2022–2023) oraz testowy (2024–2025).
3. Uczenie modeli	Trenowanie modeli bazowych i zespoowych osobno dla klasyfikacji i regresji.
4. Ocena modeli	Ocena klasyfikacji za pomoc AUC-ROC, AUC-PR, F1-Score oraz regresji za pomoc MAE, RMSE i MedAE.
5. Interpretacja	Analiza wyjanie globalnych i lokalnych za pomoc SHAP oraz wpyw zdefiniowanych Rodzin Cech.
6. Reprodukowalno	Deterministyczna inicjalizacja algorytmów (<code>random_state=42</code>) oraz statyczny zapis wyników.

4.1 Cel modelowania

Celem modelowania predykcyjnego jest prognozowanie wyników wycznie na podstawie informacji dostpnych w momencie przyjcia zwierzcia do schroniska. Analiza koncentruje si na mocy predykcyjnej modeli, a nie na wnioskowaniu przyczynowo-skutkowym.

Modele maj okreli, w jakim stopniu atrybuty takie jak gatunek, kategoria wiekowa czy okolicznoci przyjcia pozwalaj przewidzie dwie wartoci: (1) prawdopodobiestwo adopcji zwierzcia oraz (2) cakowity czas zajmowania miejsca w schronisku do momentu zakoczenia pobytu, na przykad adopcji, transferu lub powrotu do waciciela. Takie podejcie dostarcza prognoz, które mog by przydatne w zarzdzaniu placówk, poniewa czas pobytu kadego zwierzcia wie si z kosztami operacyjnymi.

4.2 Formalne sformuowanie problemu

Modele uczono dla dwóch zada:

1. **Klasyfikacja binarna (`classification_target`):** zmienna objaniana $Y^{(kl)} \in \{0, 1\}$, gdzie $Y^{(kl)} = 1$ oznacza adopcj, a $Y^{(kl)} = 0$ inny wynik kocowy. Szacowane jest prawdopodobiestwo adopcji $P(Y^{(kl)} = 1 \mid X)$.
2. **Regresja dugoci pobytu (`regression_target_days`):** zmienna ciga wyraona w dobach, reprezentujca czas do zdarzenia koczego pobyt. Model estymuje warto oczekiwan dugoci trwania epizodu $E(T \mid X)$.

Nie zastosowano modeli analizy przeycia, takich jak model proporcjonalnych hazardów Coxa czy Random Survival Forest. Wymagaoby to bardziej zoonej estymacji w obecności cenzurowania prawostronnego. Uczenie predykcyjne zdefiniowano jako klasyczn regresj na zamknitych pobytach, dla których dugo pobytu mona zmierzy bezporednio.

Zbiór predyktorów X nie zawiera cech bdcych skadow wyniku kocowego.


4.3 Przygotowanie danych i podzia chronologiczny

Dane maj charakter czasowy, dlatego zrezygnowano z klasycznej walidacji krzywej (ang. *k-fold cross-validation*) z tasowaniem próbek. Celem byo uniknicie wycieku informacji. Uczenie modelu na póniejszych rocznikach i testowanie go na wczeniejszych

mogoby zawyżać ocen skuteczności, ponieważ model korzystałby pośrednio z późniejszych wzorców.

Zbiór 162 390 epizodów podzielono chronologicznie na trzy części:

- **Zbiór treningowy:** lata 2013–2021. Pula obejmująca 126 759 rekordów psów i kotów.
- **Zbiór walidacyjny:** lata 2022–2023. Obejmuje 21 811 epizodów. Przeznaczony do doboru parametrów modeli i wskaźników odcicia.
- **Zbiór testowy:** lata 2024–2025. Służy wyłącznie do ostatecznej oceny najlepszych algorytmów na najnowszych danych.



Rysunek 4.1: Chronologiczny podział zbioru danych

Taki podział pozwala ocenić odporność modelu na zmiany wzorców w czasie (ang. *concept drift*), zwłaszcza w okresie po pandemii COVID-19.

4.4 Algorytmy predykcyjne

W badaniu porównano proste modele odniesienia z bardziej zaawansowanymi algorytmami zespołowymi. Pozwala to ocenić, czy zastosowanie bardziej złożonych metod poprawia jakość predykcji.

Modele bazowe:

- **Modele odniesienia (Dummy):** przewidują klasę większościową w klasyfikacji lub medianę w regresji. Wyznaczają minimalny poziom odniesienia dla oceny modelu w ujęciu deterministycznym.
- **Modele liniowe:** regresja logistyczna dla binarnej zmiennej celu oraz regresja gradientowa (Ridge) dla regresji wielokrotnej. Zapewniają stabilność wyników i umożliwiają stosunkowo prostą analizę wag atrybutów. Prawdopodobieństwo w modelu regresji logistycznej wyraża się wzorem:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}} \quad (4.1)$$

Modele zaawansowane (drzewa decyzyjne):

- **Lasy Losowe (Random Forest, [12]):** model zespoowy czy predykcje T drzew decyzyjnych, kade uczone na losowym podzbiorze obserwacji (ang. *bagging*) i losowym podzbiorze $\sqrt{p}$ spośród p cech. Agregacja przez urednianie (regresja) lub gosowanie wiksziociowe (klasyfikacja) istotnie redukuje wariancj w porównaniu z pojedynczym drzewem. RF nie wymaga skalowania predyktorów, lecz wymaga jawnego kodowania zmiennych kategoriycznych.
- **Histogram-based Gradient Boosting (HistGB, [15, 13]):** wariant sekwencyjnego uczenia na pseudoresztkach, gdzie kade kolejne drzewo koryguje bdy poprzedniego. Kluczow innowacj jest dyskretyzacja predyktorów numerycznych do histogramów (≤ 255 kubeków), co skraca zoono uczenia. Algorytm obsuguje brakujce wartoci natywnie i nie wymaga skalowania ani imputacji.
- **CatBoost [16]:** architektura z rodziny wzmacniania gradientowego (ang. *Gradient Boosting*). Zawiera mechanizmy przetwarzania zmiennych kategoriycznych bez koniecznoci sztucznej wektoryzacji (*one-hot encoding*). Z tego powodu dobrze nadaje si do danych zawierajcych setki nominalnych wartoci ras i umaszcze zwierz. Ogólna funkcja celu minimalizowana w kolejnych iteracjach algorytmów z tej rodziny ma posta:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (4.2)$$

gdzie l to różniczkuwalna funkcja straty, $\hat{y}_i^{(t-1)}$ to predykcja z poprzedniej iteracji, f_t to nowo dodawane drzewo, a $\Omega(f_t)$ to czon regularyzacyjny [13].

Tabela 4.2: Porównanie wykorzystanych rodzin algorytmów predykcyjnych

Algorytm	Obsuga zm. kategoriycznych	Nieliniowo	Główne zastosowanie
Dummy	Brak	Nie dotyczy	Punkt odniesienia (ang. <i>baseline</i>)
Logistic/Ridge Regression	Wymaga wektoryzacji	Nie	Stabilne modele liniowe
Random Forest	Wymaga wektoryzacji	Tak	Algorytm zespoowy redukujcy wariancj
HistGradientBoosting	Natywna	Tak	Szybkie trenowanie dla duych zbiorów
CatBoost	Natywna, zaawansowana	Tak	Główne modele, wysoka skuteczno dla cech nominalnych

Dla danych tabelarycznych z du liczb zmiennych kategorycznych wybrano modele oparte na drzewach decyzyjnych (*gradient boosting*). Decyzja ta wynika z tego, e algorytmy te s czsto uznawane za jeden ze standardów dla tego typu danych (ang. *state-of-the-art*) [11]. W przeciwieństwie do modeli liniowych, dobrze wychwytyj nie-liniowe interakcje midzy zmiennymi, na przykad specyficzny wpyw wieku tylko u konkretnej rasy psów, i nie wymagaj rygorystycznego skalowania danych numerycznych.

Zrezygowano z zastosowania gbokich sieci neuronowych (ang. *Deep Learning*). Literatura badawcza i praktyka inynieryjna wskazuj, e sieci neuronowe czsto nie poprawiaj jakoci estymacji na niejednorodnych zbiorach tabelarycznych w porównaniu z algorytmami z rodziny *gradient boosting*. Jednoczenie wymagaj wikszych zasobów obliczeniowych i ograniczaj atwo interpretacji wyników, co okreła si czsto jako problem czarnej skrzynki.

W procesie strojenia modeli, szczególnie CatBoost, przyjto zachowawcz strategii doboru hiperparametrów, aby ograniczy ryzyko przeuczenia (ang. *overfitting*). Zastosowano umiarkowan gboko drzew decyzyjnych (`depth=6`), co ogranicza zapamitywanie szumu z danych treningowych, oraz niski współczynnik uczenia (`learning_rate=0.05`), pozwalajcy na stopniow i stabiln zbieno algorytmu w trakcie 1000 iteracji. Dodatkowym mechanizmem kontrolnym byo wczesne zatrzymywanie (`early_stopping_rounds=50`), które automatycznie przerywao proces uczenia, gdy metryka na zbiorze walidacyjnym przestawaa si poprawia.

Tabela 4.3: Wybrane hiperparametry dla modeli wzmacniania gradientowego

Algorytm	Parametr	Warto
CatBoost	depth	6
	learning_rate	0.05
	iterations	1000
	early_stopping_rounds	50
HistGradientBoosting	max_depth	None
	learning_rate	0.1

4.5 Metryki oceny

Zastosowano nastpujce metryki oceny:

Zadanie klasyfikacji:

- **AUC-ROC (Area Under the Receiver Operating Characteristic Curve, [18]):** miara ogólnej zdolności modelu do rozróżniania klas. Warto 1.0 oznacza idealne rozróżnianie, a 0.5 prognoz losow. Matematycznie można je wyrazić jako prawdopodobieństwo, że model oceni wyżej losowo wybrany przypadek pozytywny niż negatywny:

$$\text{AUC-ROC} = P(\hat{p}_1 > \hat{p}_0) \quad (4.3)$$

- **AUC-PR (Area Under the Precision-Recall Curve):** metryka przydatna przy nierównowadze klas, opisująca skuteczność wykrywania kluczowej klasy [28]. Precyzja i czułość zdefiniowane są jako:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN} \quad (4.4)$$

AUC-PR stanowi pole pod krzywą Precision–Recall wyznaczoną dla wszystkich możliwych progów odcicia. W przeciwieństwie do AUC-ROC, ignoruje przypadki prawdziwie negatywne, co czyni ją bardziej wrażliwą na wykrywanie klasy mniejszościowej [28].

- **F1-Score, precyzja (Precision) i czułość (Recall):** miary punktowe zależne od wyboru progu odcicia (ang. *threshold*). Miara F1 jest średnią harmoniczną precyzji i czułości:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4.5)$$

W metodyce pracy zrezygnowano z naiwnego wyboru progu 0.5. Optymalny próg decyzyjny dla każdego algorytmu został dobrany na niezależnym zbiorze walidacyjnym pod kątem maksymalizacji wskaźnika F1, a następnie zastosowany na zbiorze testowym w celu ewaluacji.

- **Ocena kalibracji (Brier Score):** wysoki wynik AUC nie gwarantuje, że szacowane prawdopodobieństwa odpowiadają rzeczywistej częstotliwości. Wynik Briera (ang. *Brier Score* [19]) mierzy średni błąd kwadratowy:

$$\text{BS} = \frac{1}{n} \sum_{i=1}^n (p_i - o_i)^2 \quad (4.6)$$

gdzie $p_i \in [0, 1]$ to prognozowane prawdopodobieństwo adopcji, a $o_i \in \{0, 1\}$ to rzeczywisty wynik. Warto BS = 0 odpowiada idealnej kalibracji [29]. W celu oceny

kalibracji wygenerowano wykresy kalibracyjne. Jest to wane z punktu widzenia budowy wiarygodnego narzdzia analitycznego dla personelu schroniska.

Zadanie regresji:

- **MAE (Mean Absolute Error):** redni bd bezwzgdny, mierzony w dniach. Jest to gówna metryka oceniajca przecitn pomyk modelu:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.7)$$

- **MedAE (Median Absolute Error):** mediana bdów bezwzgdnych. Jest to metryka odporna na bdy skrajne, na przykad przypadki zwierzt pozostajcych w schronisku latami.
- **RMSE (Root Mean Square Error):** pierwiastek bdu redniokwadratowego. Metryka silniej penalizuje najwiksze pomyki modelu:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4.8)$$

4.6 Interpretowalno (SHAP)

Wyniki modeli predycyjnych w kontekcie schroniskowym i weterynaryjnym powinny by moliwie przejrzyste. Do analizy wpywu poszczególnych cech wykorzystano wartoci SHAP (ang. *SHapley Additive exPlanations*) [22].


Metoda ta wywodzi si z kooperatywnej teorii gier i pozwala oszacowa wkad poszczególnych atrybutów w kocow prognoz modelu, wykorzystujc wartoci Shapleya okrelane wzorem:

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_x(S \cup \{j\}) - f_x(S)] \quad (4.9)$$

gdzie F to zbiór wszystkich cech, S to podzbiór cech niezawierajcy cechy j , a $f_x(S)$ to prognoza dla podzbioru cech S .

1. **Wyjanienia globalne (SHAP Summary):** zestawienie pokazujce redni wpyw cech na decyzje modelu w caym zbiorze, na przykad zwizek modego wieku z wyszym prawdopodobiestwem adopcji.

2. **Wyjaśnienia lokalne:** ocena znaczenia atrybutów w konkretnym pojedynczym epizodzie. Funkcja ta rozkłada prognoz na czynniki zwiększające lub zmniejszające kocowy wynik.
3. **Analiza Rodzin Cech:** atrybuty pogrupowano w „Rodziny Cech”, na przykład Wiek, Wygląd i Kontekst. Takie podejście umoliwia odrzucenie lub zachowanie wybranych grup zmiennych oraz sprawdzenie ogólnego spadku celności bez konieczności osobnego analizowania wpływu pojedynczych wektorów.




Rysunek 4.2: Wykres SHAP Summary (beeswarm) dla klasyfikatora adopcji [22]. Kady punkt odpowiada jednej obserwacji ze zbioru testowego. Kolor odzwierciedla wartość cechy (czerwony – wysoka, niebieski – niska), a pozycja pozioma – wartość SHAP. Szczegółowa interpretacja wyników w rozdziale 5.

4.7 Protokół eksperymentu

W celu zapewnienia odtwarzalności eksperymentu zastosowano następujące zasady:

1. **Jednolite ziarno losowości:** ustalono deterministyczne ziarno liczb pseudolosowych (`random_state=42`) dla algorytmów.
2. **Rozdzielenie oblicze i wizualizacji:** proces uczenia odbywa się poprzez dedykowany skrypt (`scripts/run_full_pipeline.py`).



Rysunek 4.3: Zagregowany wpływ Rodzin Cech na predykcje klasyfikatora (suma bezwzględnych wartości SHAP per Rodzina). Grupowanie cech pozwala ocenić relatywny wkład cech kategorii atrybutów.

3. **Zapis modeli:** wyniki modelowania i metadane ewaluacyjne zapisywane są bezpośrednio na dysk jako estymatory `.joblib` oraz tabele `.csv`. Interfejs analityczny jedynie odczytuje zapisane parametry, bez konieczności kosztownego ponownego uczenia modeli.

Algorytm 1 przedstawia uproszczony pseudokod procesu uczenia i oceny, realizowany w ramach protokołu badawczego.

4.8 Ograniczenia

Zastosowane modele mają kilka ograniczeń. Głównym ograniczeniem technicznym było wykluczenie pobytów nieukończonych w momencie pobrania bazy, czyli obserwacji objętych cenzorowaniem prawostronnym. Było to konieczne do przeprowadzenia wariantu regresji długości pobytu.

Ponadto modele odzwierciedlają statystyczne uwarunkowania lokalnego rynku w określonym przedziale czasu, szczególnie zasady działania AAC jako schroniska no-kill o wskaźniku przeżycia powyżej 90%. Prawidłowości przypisane na przykład do etykiet rasy mogą zależeć od lokalnej struktury społecznej i sposobu postrzegania zwierząt. Ich bezpośrednie przeniesienie do innych schronisk bez ponownego trenowania lub kalibracji mogłoby obniżyć skuteczność predykcji.

Algorytm 1: Protokół treningu i oceny modelu

Input: Zbiór danych D , konfiguracje hiperparametrów Θ

Output: Wytrenowane modele M , metryki oceny E

$D_{train} \leftarrow$ podzbiór D (lata 2013–2021);

$D_{val} \leftarrow$ podzbiór D (lata 2022–2023);

$D_{test} \leftarrow$ podzbiór D (lata 2024–2025);

foreach $zadanie \in \{klasyfikacja, regresja\}$ **do**

foreach $algorytm \in \{Dummy, Logistic/Ridge, RF, HistGB, CatBoost\}$ **do**

$M_{alg} \leftarrow$ Inicjuj($algorytm, \Theta_{alg}, random_state=42$);

 Trenuj M_{alg} na D_{train} używając `early_stopping` na D_{val} ;

if $zadanie == klasyfikacja$ **then**

 Optymalizuj próg odcicia dla metryki F1 na D_{val} ;

$\hat{y} \leftarrow$ Prognozuj dla D_{test} z modelem M_{alg} ;

$E_{alg} \leftarrow$ Oblicz metryki ewaluacyjne($\hat{y}, D_{test}$);

 Zapisz M_{alg} (`.joblib`) oraz E_{alg} (`.csv`);

Wyprowad globalne i lokalne wartości SHAP dla modeli CatBoost;

Rozdzia 5

Wyniki bada i interpretacja modeli

5.1 Ramy interpretacyjne rozdziau


Ten rozdzia zbiera wyniki po dwóch wczeniejszych etapach pracy: przygotowaniu danych i opisanu metod. Punktem wyjcia jest 162 390 dopasowanych epizodów pobytu (przyjcie–wynik) psów i kotów. Modele oceniano w porzdku chronologicznym, a nie po losowym przemieszaniu rekordów: lata 2013–2021 posuuy do uczenia, lata 2022–2023 do walidacji i ustawiania progów decyzyjnych, natomiast lata 2024–2025 do jednego, kocowego testu. Takie ustawienie jest bardziej wymagajce, ale lepiej przypomina sytuacj, w której model ma pracowa na danych z przyszoci.

Wyniki trzeba czyta z podziaem na dwa osobne zadania. Klasyfikacja odpowiada na pytanie o prawdopodobiestwo adopcji. Regresja szacuje liczb dni do *dowolnego* dopasowanego wyniku pobytu, a wic nie jest prost miar „szybkoci adopcji”. W tej zmiennej mieszcz si take inne zakoczenia, midzy innymi eutanazja i powrót do waciciela. Dlatego atrybut `days_to_adoption` peni tu tylko funkcj pomocnicz i opisow. Klasyfikatory oceniano za pomoc ROC-AUC, PR-AUC, Precision, Recall i F1-Score, a regresj przez MAE, RMSE i MedAE.

W dalszej czci najpierw zestawiono jako modeli, a nastpnie wrócono do hipotez badawczych. Osobne miejsce zajmuje interpretacja modeli, poniewa same metryki nie wystarczaj do oceny, czy wynik mona rozsennie wykorzysta w praktyce schroniskowej [22].

5.2 Porównanie jakości modeli

Najpierw warto uporządkować cięk analizy. Schemat pokazuje, jak od zbioru modelowego przechodzą do porównania algorytmów, wyboru modelu kocowego i interpretacji jego zachowania.




Rysunek 5.1: Logika ewaluacji modeli klasyfikacyjnych i regresyjnych.

Na zbiorze testowym z lat 2024–2025 nie wygra jeden model „do wszystkiego”. W klasyfikacji adopcji najlepiej poradzi sobie HistGradientBoosting, natomiast w regresji długości pobytu najniższy błąd uzyska CatBoost.

Różnica między zadaniami jest dobrze widoczna w metrykach. Klasyfikacja, z ROC-AUC około 0,840, okazała się stabilniejsza niż przewidywanie czasu pobytu, gdzie MAE wyniosło około 18,5 dnia. Warto też zwrócić uwagę na gatunek: wyniki dla kotów są lepsze niż dla psów. Może to oznaczać, że cięki pobytu kotów są w badanym materiale bardziej powtarzalne albo mniej zależne od nietypowych przypadków.

Na wykresach atwiej zobaczy skal tej przewagi ni w samej tabeli. Rysunek 5.2 pokazuje, e modele boostingowe wyranie odsuwaj si od modelu bazowego, którym bya Regresja Logistyczna.



Rysunek 5.2: Zbiorcze porównanie zdolności dyskryminacyjnej badanych algorytmów na zbiorze cznym oraz podzbiorach gatunkowych.


Dokadne wartoci metryk na odoonym zbiorze testowym zebrano w tabeli 5.1.

Tabela 5.1: Wyniki najlepszych modeli na zbiorze testowym (2024–2025)


Zadanie	Podzbiór danych	Najlepszy model	Gówna miara (ROC-AUC / MAE)	PR-AUC	F1-Score	Precision	Recall	RMSE	MedAE
Klasyfikacja	Zbiór czny	HistGradientBoosting	0,840 (ROC-AUC)	0,884	0,818	0,835	0,801	–	–
Klasyfikacja	Psy	HistGradientBoosting	0,806 (ROC-AUC)	0,857	0,799	0,817	0,781	–	–
Klasyfikacja	Koty	HistGradientBoosting	0,865 (ROC-AUC)	0,899	0,842	0,846	0,839	–	–
Regresja	Zbiór czny	CatBoost	18,55 (MAE dni)	–	–	–	–	38,36	6,28
Regresja	Psy	CatBoost	21,56 (MAE dni)	–	–	–	–	45,99	6,28
Regresja	Koty	CatBoost	15,79 (MAE dni)	–	–	–	–	30,12	5,71

Te liczby potwierdzaj, e modele bazowe speniy swoj rol kontroln. Naiwne przewidywanie mediany lub dominanty pozwalao sprawdzi, czy dane nios jakikolwiek sygna predykcyjny. Najwiecej informacji analitycznej day jednak modele boostingowe, zgodnie z szerszymi wynikami bada nad danymi tabelarycznymi [14, 16, 11]. Regresja logistyczna pozostaje uyteczna jako prostszy punkt odniesienia, ale to modele nieliniowe lepiej wykorzystay struktur danych tabelarycznych.


Uzupieniem analizy skuteczności klasyfikatora jest krzywa Precision-Recall (PR) oraz macierz pomyek, które dokadniej ilustruj rozkad bów modelu, a w szczególności proporcje wyników faszywie pozytywnych (FP) wzgldem faszywie negatywnych (FN). W kontekście schroniskowym minimalizowanie obu typów bów ma inne konsekwencje praktyczne: bdne wskazanie na wysok szans adopcji (FP) moe opóni konieczne interwencje



Rysunek 5.3: Wartości rzeczywiste kontra przewidywane dla modelu regresyjnego (CatBoost). Widoczny jest systematyczny niedoszacunek dla długich pobytów (powyżej 60 dni).




Rysunek 5.4: Rozkład reszt modelu regresyjnego. Silna asymetria prawostronna potwierdza koncentrację błędów na rzadkich przypadkach bardzo długich pobytów – MAE wynosi 18,55 dnia, natomiast mediana bdu zaledwie 6,28 dnia.



Rysunek 5.5: Szczegółowy przebieg krzywej ROC dla zwyczajnego klasyfikatora (HistGradientBoosting). Widoczne wyrwane wysklepienie nad lini losow (AUC = 0.50).

wspomagajce, a zbyt pesymistyczna prognoza (FN) prowadzi do marnowania zasobów na zwierz, które poradzioby sobie samo.




Rysunek 5.6: Krzywa Precision-Recall dla najlepszego modelu klasyfikacyjnego. Pozwala lepiej ocenić jako predykcji, zwłaszcza w sytuacji niezbalansowania klas.

Osobno sprawdzono cechy kontekstowe, takie jak pogoda i wcześniejszy wolumen przyj. Ich dodanie nie przyniosło dużej, jednolitej poprawy we wszystkich rodzinach modeli. W klasyfikacji pojawił się niewielki zysk dla CatBoosta w zbiorze cznym, ale nie przełożył się on na wyraźną poprawę dla psów. W praktyce oznacza to, że zewnętrzny kontekst rodowiskowy w momencie przyjcia należy traktować ostrożnie, raczej jako uzupełnienie niż główne źródło informacji.


5.2.1 Porównanie modeli regresyjnych

W zadaniu regresji szacującym liczbę dni do wyjścia ze schroniska, najlepsze wyniki uzyskał CatBoost. Do oceny tego zadania wykorzystano metryki opierające się na różnicy między predykcją a wartością rzeczywistą: średni błąd bezwzględny (MAE) oraz pierwiastek błędów średniokwadratowych (RMSE). Rysunki 5.8 i 5.9 pokazują graficzne zestawienie błędów dla poszczególnych algorytmów.


Modele boostingowe, a zwłaszcza CatBoost, poradziły sobie z tym wyzwaniem zauważalnie lepiej od średniej czy mediany bazowej. Algorytm ten jest w stanie optymalnie



Rysunek 5.7: Macierz pomyłek dla modelu kocowego, pozwalająca szczegółowo przeledezi rozkad poprawnych i bdných klasyfikacji.



Rysunek 5.8: Porównanie badanych algorytmów pod ktem redniego bdu bezwzglđnego (MAE) na zbiorze cznym oraz podzbiorach gatunkowych.



Rysunek 5.9: Zestawienie bdu RMSE dla modeli regresyjnych. Wyszła waga większych odchył uwypukla przewagę CatBoosta nad innymi algorytmami.

wyapa nieliniowe relacje w strukturze danych wejściowych, co ma kluczowe znaczenie przy zjawiskach z du liczb wartoci odstajcych.

5.3 Weryfikacja hipotez badawczych


Kada z piciu hipotez weryfikowana jest poniej zarówno na podstawie analizy opisowej, jak i wyników predykcyjnych modeli.

Hipoteza H1 (Wpyw okolicznoci przyjcia w relacji do wygldu)

Wyniki wspieraj hipotez, e okolicznoci przyjcia maj wiksze znaczenie ni same cechy wygldu. W analizie opisowej najwysze wskaniki adopcji pojawiaj si przy rzeczeniu wacicielskim (Owner Surrender) oraz kategorii Abandoned. Podobny obraz wida w modelu: analizy SHAP i ablacja Rodzin Cech wskazuj silniejszy sygna po stronie zmien-nych opisujcych typ i okolicznoci przyjcia ni po stronie koloru czy innych cech wygldu. Nie jest to dowód przyczynowy. To raczej spójna asocjacja, któr model wykorzystuje przy predykcji; podobn potrzeb ostronoci przy interpretowaniu cech schroniskowych podkrelaj wczeniejsze badania nad adopcj i dugoci pobytu [4, 9].


Hipoteza H3 (Wpyw wieku zwierzcia)

W przypadku wieku zaleno jest czytelna i zgodna z intuicj oraz wczeniejszymi badaniami nad wynikami schroniskowymi [9, 4]. Najmodsze zwierzta najczciej koczyły pobyt adopcj: grupa Baby osiga wskanik 59,7%. Dla grupy Young jest to 47,5%, dla



Rysunek 5.10: Porównanie wagi rodzin cech dla wyniku klasyfikacji. Cechy okolicznici przyjęcia (Intake) dominują nad wyglądem.


zwierząt dorosłych 39,6%, a dla seniorów 31,0%. Wiek pojawia się też wysoko w globalnych wyjaśnieniach modelu, więc nie jest to wyłącznie efekt prostego zestawienia opisowego.




Rysunek 5.11: Spadek prawdopodobieństwa adopcji postępuje wraz z wiekiem zwierzęcia (w latach).

Hipoteza H5 (Okres pandemii COVID-19)

Okres COVID-19 nie daje się sprowadzić do prostej historii o większym popycie na adopcję. W danych opisowych widać wzrost odsetka adopcji: z 46,3% przed pandemią do 61,5% po pandemii. Jednocześnie mediana liczby dni do opuszczenia schroniska spadła z 5,25 do 9,83 dnia. Ten pozorny paradoks sugeruje zmianę struktury przyjmowanych zwierząt albo zmian pojemności operacyjnej ośrodka, co jest spójne z obserwacjami o zmianach




Rysunek 5.12: Mediana liczby dni do adopcji w podziale na grupy wiekowe (wycznie zwierzta adoptowane). Niemowlta opuszczaj schronisko najszybciej.



Rysunek 5.13: Krzywe Kaplana-Meiera dla adopcji w podziale na grupy wiekowe [20]. Stromszy przebieg krzywej dla grupy baby potwierdza szybszy czas wyjcia ze schroniska.

praktyk schroniskowych i przepływów zwierząt w pierwszym okresie pandemii [23, 30]. Zmniejszenie ogólnej liczby przyjazdów w trakcie samej pandemii również jest czytelnym sygnałem zachodzących przemian. Sama informacja o pandemii pomaga więc opisać okres, ale nie powinna być czytana jako samodzielne wyjaśnienie mechanizmu.




Rysunek 5.14: Różnice we wskaźnikach adopcji przed, w trakcie oraz po pandemii COVID-19.

Hipoteza H2 (Wpływ sezonowości)


Sezonowość w danych wykazuje pewne różnice, jednak w ogólnym ujęciu ma ona charakter drugorzędny i pomocniczy. Zauważalne są wahania wskaźników w zależności od pory roku, co widoczne jest zarówno we wskaźnikach adopcji, jak i w medianie czasu pobytu. Efekt ten nie przeważa nad takimi zmiennymi jak okoliczności przyjęcia.

Hipoteza H4 (Ciemne umaszczenie i Black Dog Syndrome)


Hipoteza o ciemnym umaszczeniu, nawiązująca do tak zwanego *Black Dog Syndrome*, dotyczy przypuszczalnie niższych szans na adopcję dla zwierząt o ciemnym kolorze sierści. Historycznie, zwierzęta ujęte w kategorii `is_black_or_dark` faktycznie osiągały nieco niższe wskaźniki adopcji. Obecne zestawienia pokazują jednak ciekawe zjawisko polegające na nieznacznym odwróceniu tego efektu – można zaobserwować delikatne przeamanie *Black Dog Syndrome*, gdy zwierzęta ciemne zaczynają lokalnie zyskiwać w statystykach adopcyjnych. Wciąż jednak taki wynik ilustruje jedynie asocjacje w danych, a nie przyczyny.



Rysunek 5.15: Wolumen przyj w zalenoci od okresu wzgldem pandemii COVID-19.



Rysunek 5.16: Wskaniki adopcji w rozbiciu na pory roku. Wiosna i lato wykazuj wyzsze wskaniki ni jesie i zima.




Rysunek 5.17: Mediana czasu pobytu w zależności od sezonu.

decyzji ludzi; literatura opisująca zjawisko preferencji ze względu na wygląd ostrzega, że wpływ koloru i rasy bywa wysoce niejednoznaczny [6, 8, 9].


5.4 Interpretacja i wiarygodność modelu

Interpretacja modelu nie jest tu dodatkiem estetycznym, lecz warunkiem sensownego ujęcia wyników. W środowisku weterynaryjnym i schroniskowym decyzje dotyczące konkretnych zwierząt, dlatego model typu „czarna skrzynka” (ang. *black-box*) łatwo może budzić nieufność personelu. Pracownik schroniska powinien wiedzieć, dlaczego szczeniak albo starszy pies został oznaczony jako przypadek podwyższonego ryzyka. Do tego wykorzystano metody *Explainable AI* (XAI), przede wszystkim wartości SHAP [22]. Globalne wykresy SHAP są zgodne z intuicją wynikającą z danych: starszy wiek obniża prawdopodobieństwo adopcji, a młody wiek działa w przeciwnym kierunku. Taka zgodność nie rozwiązuje wszystkich problemów interpretacyjnych, ale ułatwia rozmowy o modelu z osobami, które miałyby z niego korzystać.

Wynik ten wymaga komentarza. Zmienna `has_name` (czy zwierzę miało imię w chwili przyjęcia) nie oznacza, że samo nadanie imienia zwiększa szansę adopcji – jest to asocjacja agregująca wiele kontekstów wacicielskich. Efekt predykcyjny jest jednak na tyle silny, że dominuje nad cechami wyglądu, wiekiem i rasą [31].




Rysunek 5.18: Porównanie wskaźnika adopcji ze względu na umaszczenie zwierzt, wskazujące na lekkie odwrócenie trendu dla grupy o ciemnym umaszczeniu.




Rysunek 5.19: Różnice w medianie czasu pobytu dla zwierzt z jasnym i ciemnym umaszczeniem.

Tabela 5.2: Status hipotez badawczych w wietle wyników


Hipoteza	Zakres	Status	Najwaniejsza obserwacja
H1	Okolicznoci przyjcia vs wyglđ	Wsparta opisowo i predykcynie	Cechy intake-related wykazuj wysz donioso (SHAP importance) ni atrybuty umaszczenia.
H2	Sezonowo	Analiza opisowa	Rónice sezonowe istniej, ale stanowi czynnik drugorzđny predykcynie.
H3	Wiek	Wsparta opisowo i predykcynie	Wskanik adopcji maleje z 59,7% (baby) do 31,0% (senior).
H4	Ciemne umaszczenie	Analiza opisowa	Historycznie nisza adopccyjno ulegajca lokalnemu odwróceniu (lekkie przeamanie efektu).
H5	Okres COVID-19	Wsparta opisowo	Wzrost adopcji (z 46% do 61%) przy jednoczesnym wzrocie czasu pobytu (z 5 do 9 dni mediany).



Rysunek 5.20: Zbiorczy wykres SHAP (Summary Plot) dla zadania klasyfikacji, obrazujcy wpyw poszczególnych wartoci cech na przewidywane prawdopodobieństwo adopcji.




Rysunek 5.21: Zestawienie rednich wartoci SHAP wedug rodzin cech dla klasyfikatora adopcji. Rodzina `name_identity` uzyskaa najwyszy sumaryczny wkad predykcyjny ($\approx 0,55$), wyprzedzajc cechy wiekowe ($\approx 0,48$) oraz rasowo-wygladowe ($\approx 0,26$).



Rysunek 5.22: Zbiorczy wykres SHAP dla regresji czasu pobytu, pokazujcy w jaki sposób dane parametry wyduaj lub skracaj prognozowany wynik.

Trzeba przy tym uczciwie zaznaczyć jedną decyzję metodologiczną. Najlepszym klasyfikatorem na teście byłby HistGradientBoosting, ale pociągające wygenerowanie wykresów SHAP jest, ze względów narzędziowych i dostępności *TreeExplainer*, wygodniejsze dla CatBoosta. Z tego powodu analiza interpretacji opiera się na modelach wspomagających. Służą one do pokazania kierunków zależności, a nie do zastępowania właściwej oceny modelu końcowego.

Drugim filarem użyteczności jest kalibracja. Samo wysokie ROC-AUC mówi, że model dobrze porządkuje przypadki, ale nie gwarantuje jeszcze, że podawane prawdopodobieństwa są dobrze wyskalowane [18, 19]. To szczególnie ważne na krótkich odcinkach rozkładu predykcji, gdzie błędna pewność modelu może być bardziej kłopotliwa niż pojedyncza pomyłka klasyfikacyjna.




Rysunek 5.23: Krzywa kalibracyjna (Calibration Curve) pokazująca, w jakim stopniu przewidywane przez model prawdopodobieństwo adopcji odpowiada rzeczywistej częstotliwości (Perfectly calibrated).

Oszacowania sprawdzono więc pod kątem luki kalibracyjnej (Brier Score) oraz progów decyzyjnych (`threshold`). Progi dobrano na niezależnym zbiorze walidacyjnym z lat 2022–2023, a potem przeniesiono bez zmian na test z lat 2024–2025. Dla małych podgrup, poniżej 100 obserwacji w zbiorze testowym, wyniki należy czytać szczególnie ostrożnie.

5.4.1 Analiza błędów i wiarygodność modelu


Istotnym aspektem sprawdzania jakości prognozy na wdrożeniu jest identyfikacja tych segmentów, w których algorytmy radzą sobie gorzej. Wykonano tzw. *error analysis*

przez wyizolowanie przekrojów (ang. *error slices*) najczęściej prowadzących do pomyki modelu. Dla klasyfikatora pozwala to wskazać konkretne podgrupy zwierząt wywołujące największy odsetek nietrafiionych prognoz, podczas gdy w regresji rzuca światło na przypadki z nadzwyczajnym wysokim błędem MAE.



Rysunek 5.24: Wizualizacja przekrojów błędów dla modelu klasyfikacyjnego. Ukazuje wycinki zbioru, w których skuteczność modelu jest najniższa.

Najostrożniej trzeba interpretować regresję czasu pobytu. Proces opuszczania schroniska jest częściowo losowy i zależy od czynników, których nie ma w tabeli danych. Model nie jest więc „wyroczni” wskazując dokładny dzień wyjścia psa czy kota ze schroniska. Lepiej traktować go jako filtr ryzyka i narzędzie do porządkowania uwagi personelu. Z takiego zaoferowania wynika późniejsza architektura Dashboardu oraz środowiska MLOps opisana w kolejnym rozdziale.



Rysunek 5.25: Analiza segmentacyjna błędów regresji. Rozbicie przypadków według wielkości MAE dla różnych profili zwierząt.

Rozdział 6

Architektura systemu i reprodukowalność eksperymentów

W niniejszym rozdziale przedstawiono warstwy inżynierskie i techniczne projektu. Badania oparte na uczeniu maszynowym wymagają nie tylko oceny skuteczności predykcyjnej, opisanej w rozdziale 5, lecz także zapewnienia odtwarzalności (ang. *reproducibility*). Zgodnie z dobrymi praktykami oprogramowania naukowego, na przykład postulatami *The Turing Way* [32], rzetelne badanie powinno być możliwe do niezależnego odtworzenia na podstawie dostarczonego kodu i danych. W tym celu wdrożono uporządkowaną architekturę systemu, skonteneryzowane środowisko Docker, zautomatyzowane skrypty wykonawcze oraz zestaw testów.

6.1 środowisko wdrożeniowe i konteneryzacja (Docker)

Podstawą reprodukowalności wdrożonego rozwiązania jest skonteneryzowanie go przy użyciu technologii Docker [25]. Zamiast opierać się na lokalnych środowiskach programistycznych, które mogą różnić się konfiguracją i zależnościami, cały system analityczny i aplikacyjny zostaje umieszczony w izolowanym obrazie.

6.1.1 Uzasadnienie zożoności systemu (Dlaczego MLOps?)

Na pierwszy rzut oka do wytrenowania modelu uczenia maszynowego mógłby wystarczyć pojedynczy skrypt w Pythonie. Potrzeba zastosowania bardziej rozbudowanej

architektury Docker, izolowanych potoków i środowisk testowych wynika jednak bezporównie z charakteru problemu badawczego.

Praca na 160 tysiącach epizodów zwierząt obejmujących 10 lat działalności schroniska wie się z istotnym ryzykiem wycieku danych (ang. *data leakage*). W nieustrukturyzowanym kodzie łatwo o sytuację, w której podczas transformacji danych przypadkowo uwzględniona zostanie informacja z przyszłości, na przykład powód eutanazji jako predyktor, mimo że model ma działać już na etapie przyjęcia zwierzęcia. Dodatkowym problemem jest zjawisko „cichłej degradacji” (ang. *silent failure*). W przypadku błędnie podanych danych model nie musi wygenerować technicznego błędu, takiego jak `Exception`, lecz może bez widocznego ostrzeżenia zwrócić nieprawidłową predykcję ryzyka. Z tego powodu uporządkowana infrastruktura MLOps była ważna dla zapewnienia bezstronności, audytowalności i kontroli jakości wygenerowanych rezultatów, a nie tylko dla uzyskania wysokich metryk.

6.1.2 Architektura serwisów (Docker Compose)


Zastosowano narzędzie Docker Compose (`docker-compose.yml`), które definiuje architekturę systemu jako zbiór odseparowanych kontenerów, czyli serwisów, korzystających ze wspólnych zasobów. Taka struktura pozwala uruchomić wybrane warstwy systemu za pomocą jednej komendy. W ramach architektury zdefiniowano następujące serwisy operacyjne:

```
services:
  dashboard:
    build: .
    ports: ["8501:8501"]
    volumes: [./models:/app/models]
  pipeline-full:
    build: .
    command: python scripts/run_full_pipeline.py
    volumes: [./data:/app/data, ./reports:/app/reports]
  test:
    build: .
    command: python -m pytest tests/ -v
```

Listing 6.1: Kluczowe definicje serwisów wyizolowane w architekturze `docker-compose.yml`

Wszystkie te serwisy współdzielą na poziomie kontenerów zmapowane wolumeny pamięci, czyli katalogi `data/`, `models/`, `reports/` i `logs/`. Umożliwia to przepływ wytworzonych artefaktów między poszczególnymi warstwami bez powielania danych. Istotne jest także odseparowanie zapisu od konsumpcji: `pipeline-full` zapisuje artefakty do katalogu `reports/`, natomiast `dashboard` korzysta z modeli zapisanych

w katalogu `models/`. Relacje między głównymi serwisami a udostępnianymi katalogami zilustrowano na rysunku 6.1.



Rysunek 6.1: Architektura serwisów Docker Compose i udostępniane wolumeny pamięci

6.2 Architektura *Artifact-First* i separacja warstw

Dzięki skonteneryzowaniu różnych ról systemu możliwe było zastosowanie podejścia *Artifact-First*. Oznacza ono cięse rozdzielenie zasobochonnego procesu uczenia modeli od lekkiej warstwy prezentacyjnej, czyli aplikacji dla użytkownika końcowego.

Decyzja ta wynika z praktycznych ograniczeń środowiska docelowego. Typowe platformy ratownictwa zwierząt nie dysponują infrastrukturą serwerową wyposażoną w akceleratory graficzne (GPU), które mogłyby być potrzebne do efektywnego trenowania wybranych modeli. Dodatkowo interaktywne retrenowanie modelu po wprowadzeniu każdego nowego zwierzęcia, czyli tzw. uczenie online, wiązałoby się z ryzykiem operacyjnym. Błędnie wprowadzony rekord mógłby szybko pogorszyć działanie całego systemu.

- **Warstwa eksperymentalna (Jupyter):** przeznaczona dla *data scientistów* do testowania hipotez.
- **Warstwa treningowa (Pipeline):** z uwagi na duży wolumen danych, obejmujący ponad 160 tys. epizodów, operacje te zajmują znaczny czas. Wyniki uruchomienia kontenera `pipeline-full` są „zamrażane” w formie statycznych artefaktów: wyuczonych modeli w formacie `.joblib`, tabel wyników w formacie `.csv` oraz wygenerowanych wykresów `.png`.

- **Warstwa konsumpcyjna (Dashboard):** aplikacja demonstracyjna, opisana w rozdziale 7, nie posiada uprawnień do modyfikacji algorytmów. Jej rola ogranicza się do adowania do pamięci RAM gotowych modeli zapisanych na dysku.

Takie podejście obniża wymagania sprzętowe po stronie serwera aplikacji i wspiera niezmiennie decyzje algorytmiczne. Pracownik schroniska otrzymuje predykcję z modelu wcześniej przetestowanego, a nie z modelu zmienionego najnowszymi danymi.

6.3 Organizacja kodu i moduowo

Projekt ustrukturyzowano jako standardowy pakiet języka Python zarządzany przez `pyproject.toml`. Struktura repozytorium (listing 6.2) odpowiada podziałowi kompetencji:

```
austin-analysis/
|-- docker-compose.yml
|-- pyproject.toml
|-- src/
|   |-- aac_adoption/
|       |-- data/
|       |-- features/
|       |-- models/
|       |-- reporting/
|-- scripts/
|   |-- run_full_pipeline.py
|-- tests/
|-- notebooks/
|-- models/
|-- reports/
```

Listing 6.2: Drzewo katalogów głównego projektu

1. `src/aac_adoption/` – główny kod źródłowy biblioteki, podzielony na domeny: `data` (przetwarzanie epizodów), `features` (rejestr cech), `models` (uczenie i ewaluacja) oraz `reporting` (agregacja wyników).
2. `scripts/` – narzędzia wykonawcze (CLI), np. skrypt `run_full_pipeline.py`.
3. `tests/` – zestaw zautomatyzowanych testów jednostkowych i integracyjnych uruchamianych z kontenera testowego.
4. `notebooks/` – notatniki Jupyter służące analizie odkrywczej.

6.4 Automatyzacja potoku (Pipeline) a notatniki Jupyter

W uczeniu maszynowym czystym problemem jest „ukryty dug techniczny” (ang. *hidden technical debt*) [24]. Modele budowane wycznie przez sekwencyjne uruchamianie komórek w notatnikach Jupyter mog sta si trudne do odtworzenia.

Dlatego w niniejszej architekturze Jupyter (`notebooks/`) suy wycznie do badania i rozwoju (R&D). Gdy dana logika okazuje si skuteczna, jest przenoszona do produkcyjnego kodu ródowego w `src/`. Ostateczne trenowanie modeli realizowane jest przez w peni skryptowy, centralny potok wywoywany w kontenerze `pipeline-full`:

```
docker-compose up pipeline-full
```


Listing 6.3: Uruchomienie penego potoku eksperymentalnego

6.4.1 Fazy zautomatyzowanego potoku i Data Provenance

Komenda ta zamyka proces badawczy w deterministycznych ramach, uruchamiajc sekwencyjnie 18 zdefiniowanych kroków widocznych w skrypcie `run_full_pipeline.py`. Proces ten mona podzieli na nastpujce makrofazy:

1. **Zarzdzanie danymi:** automatyczne pobranie surowych danych, jeli ich brakuje, czyszczenie oraz budowa ujednoliconego zbioru (`build_dataset`).
2. **Modelowanie:** trening modeli bazowych, strojenie hiperparametrów algorytmów drzewiastych oraz kalibracja klasyfikatorów.
3. **Diagnostyka i wyjanialno:** generowanie wykresów diagnostycznych i przeliczanie wartoci SHAP dla caego zbioru.
4. **Raportowanie:** automatyczne zapisywanie artefaktów, czyli tabel i wykresów, bezporednio do katalogu `reports/`.

Szczególn uwag w potoku powicono koncepcji **Data Provenance**, czyli proveniencji danych, oraz precyzyjnemu wersjonowaniu eksperymentów. Wersjonowanie kodu zapewnia system Git, a powizanie konkretnej wersji kodu z odpowiednimi artefaktami realizowane jest przez autorski mechanizm pokwitowa uruchomie (ang. *run receipts*). Kady krok potoku wywouje funkcj `write_producer_receipt()`, zapisujc do katalogu `reports/run_receipts/` osobny plik JSON dokumentujcy identyfikator uruchomienia, skrót SHA komitu Git, list artefaktów wejciowych i wyjciowych, czas wykonania



Rysunek 6.2: Porównanie strategii ewaluacji chronologicznej zastosowanej w potoku eksperymentalnym. Dane z lat 2013–2021 posuły do uczenia modeli, lata 2022–2023 do walidacji i doboru progu decyzyjnego, a lata 2024–2025 stanowi jednorazowy zbiór testowy. Podejście to odwzorowuje warunki rzeczywistego wdrożenia, w którym model musi generalizować na dane z przyszłości.

oraz status zakończenia. Integracja z narzędziem DVC (Data Version Control) [26] stanowi planowany kierunek dalszego rozwoju systemu [33].

Po poprawnym zakończeniu 18 kroków modelowania potok generuje plik `run_receipt.json`. Pełni on funkcję kompleksowego zapisu technicznego z przebiegu eksperymentu, dokumentując:

- dokładny znacznik czasu (timestamp) rozpoczęcia i zakończenia procedur,
- skrót SHA komitu Git, precyzyjnie identyfikujący wersję kodu źródłowego,
- pełną listę wszystkich wykonanych z powodzeniem faz (od czyszczenia danych, przez inżynierię cech, strojenie hiperparametrów, a po ocenę modeli),
- podsumowanie ewentualnych ostrzeżeń lub pominiętych kroków kalibracji.

Dzięki temu plikowi można bezbłędnie zidentyfikować, w jakich warunkach oraz na jakich danych trenujących powstały wyeksportowane modele.

6.5 Rygor testowy i audyty danych

Zoona przetwarzania danych weryfikowano na każdym etapie za pomocą zautomatyzowanych zestawów testów, uruchamianych w ramach komendy `docker-compose up test`. Rodowisko testowe pokrywa szereg krytycznych aspektów niezawodności, przede wszystkim: obronę przed wyciekami danych informujących o przyszłości (ang. *data leakage*), integralność strukturalną tabel bazowych (*data integrity*) oraz spójność przejścia surowych danych przez cały zintegrowany potok (*pipeline tests*). System zwraca jednoznaczne logi dokumentujące poprawność architektury:

```
===== test session starts ✓
  ↳ =====
collected 34 items

tests/test_leakage_audit.py::test_audit_leakage_columns_risk_levels ✓
  ↳ PASSED
tests/test_leakage_audit.py::test_no_leakage_columns_in_dataset ✓
  ↳ PASSED
tests/test_leakage_audit.py::test_no_future_columns_in_dataset ✓
  ↳ PASSED
tests/test_leakage_audit.py::test_all_prohibited_columns_rejected ✓
  ↳ PASSED
tests/test_split.py::test_chronological_split_dates ✓
  ↳ PASSED
tests/test_calibration_chronology.py::test_calibration_uses_val_data ✓
  ↳ PASSED
...
```

```
===== 34 passed in 18.2s ✓
↳ =====
```

Listing 6.4: Fragment wydruku rodowiska testowego dokumentujący pomyłne zakończenie audytu wycieku danych (leakage audit)


Wszystkim niedeterministycznym operacjom algorytmicznym w kodzie przypisano stałą ziarno losowości (`RANDOM_STATE = 42`). Nie zastępuje ono chronologicznego podziału danych opisanego w sekcji 4.3, lecz stabilizuje elementy losowe obecne w procedurach uczenia i oceny modeli:

```
RANDOM_STATE = 42

classifier = HistGradientBoostingClassifier(random_state=RANDOM_STATE)
regressor = CatBoostRegressor(random_seed=RANDOM_STATE, verbose=False)
```

Listing 6.5: Przykład utrzymania stałego ziarna losowości w modelowaniu

Poprawne uruchomienie całego środowiska Docker — od potoku treningowego po warstwę prezentacyjną — potwierdzono praktycznie. Rysunek 6.3 przedstawia stronę startową aplikacji demonstracyjnej uruchomionej w kontenerze `dashboard`.



Rysunek 6.3: Strona główna aplikacji demonstracyjnej (Streamlit) działającej w kontenerze `dashboard` po pomyślnym zakończeniu potoku `pipeline-full`. Widoczne zakładki odpowiadają modułom funkcjonalnym opisanym w rozdziale 7.

W porównaniu z powtarzalną architekturą Docker wspiera to odtwarzalność potoku analitycznego na innej maszynie serwerowej. Celem takiej organizacji jest uzyskanie tych samych tabel wyników oraz wykresów przy ponownym uruchomieniu eksperymentu, z

zastrzeżeniem możliwych minimalnych różnic numerycznych wynikających z wersji bibliotek, architektury sprzętowej lub ustawie wielowtkowoci. Tak rozumiana reprodukowalność odpowiada kryteriom audytowalności prac naukowych.

Rozdzia 7

Aplikacja demonstracyjna i sposób prezentacji wyników


Zbudowanie skutecznego algorytmu analitycznego działającego w środowisku konsolowym, opisanym w poprzednich rozdziałach, rozwiązuje problem z perspektywy *data science*, ale nie tworzy jeszcze narzędzia wygodnego dla pracowników schroniska. Aby ograniczyć barierę wejścia i pokazać praktyczną użyteczność opracowanych modeli, stworzono interaktywną aplikację demonstracyjną (dashboard).

W niniejszym rozdziale przedstawiono cele, architekturę oraz przykładowe scenariusze użycia tego narzędzia wizualnego, które stanowi końcowy element praktycznej części pracy.

7.1 Cel i środowisko aplikacji

Głównym celem aplikacji jest umożliwienie personelowi Austin Animal Center (AAC) korzystania z wyników modelu predykcyjnego bez konieczności posiadania wiedzy programistycznej lub analitycznej.

Kluczowym założeniem projektowym, zgodnym z opisaną w rozdziale 6 architekturą *Artifact-First*, jest pasywność aplikacji w kontekście uczenia maszynowego. Wybór biblioteki Streamlit [27] podyktowany był natywnym wsparciem dla języka Python, możliwością błyskawicznego prototypowania (ang. *rapid prototyping*) oraz czytelnym interfejsem użytkownika (UI). Streamlit pozwala na bezproblemową integrację wizualizacji danych. Aplikacja wspiera dwujęzyczność — użytkownik może przełączać interfejs między językiem polskim a angielskim za pomocą selektora widocznego w panelu bocznym, co czyni ją dostępną zarówno dla krajowego personelu, jak i anglojęzycznych wolontariuszy. Dodatkowo aplikacja została



Rysunek 7.1: Widok startowy aplikacji demonstracyjnej (*Executive Overview*) z widocznym selektorem języka interfejsu (Polish/English) w panelu bocznym oraz zestawieniem wyników selekcji modelu. Aplikacja dostępna jest lokalnie pod adresem `localhost:8501` po uruchomieniu `docker-compose up dashboard`.

zaprojektowana z uwzględnieniem obsługi przypadków brzegowych – w sytuacji brakujących danych wprowadzanych przez użytkownika lub pojawienia się bardzo rzadkich ras, system stosuje bezpieczne wartości domyślne, co zapobiega awarii podczas generowania predykcji. Aplikacja nie trenuje modeli interaktywnie. Zamiast tego pobiera wcześniej zatwierdzone i zamrozone po weryfikacji testowej artefakty ze współdzielonego wolumenu Dockera dostępnego dla kontenera jako katalog `models/`.

Poniższy fragment kodu pokazuje lekko warstwę konsumpcyjną. Interfejs wczytuje wcześniej wytrenowany model i przechodzi w stan gotowości operacyjnej:

```
import streamlit as st
import joblib

@st.cache_resource
def load_model():
    # Model ładuje się tylko raz po starcie kontenera "dashboard"
    return joblib.load('models/adoption_model.joblib')

model = load_model()
```

Listing 7.1: Mechanizm buforowania wczytywania modelu zapobiegający degradacji wydajności

Dzięki temu system, działający jako izolowany kontener dashboard, ogranicza ryzyko uszkodzeń wynikających z wprowadzania błędnych danych przez operatora. Czas oczekiwania na prognozę pozostaje krótki, ponieważ aplikacja korzysta z gotowego modelu, a nie uruchamia procesu trenowania.

7.2 Główne moduły funkcjonalne (widoki)

Interfejs użytkownika podzielono na logiczne sekcje odpowiadające najczęstszym operacjom w schronisku.

7.2.1 Single Animal Predictor (symulator pojedynczego przyjęcia)


Jest to główny moduł operacyjny przeznaczony dla personelu pracującego przy tak zwanej „bramie” (*intake*), czyli na etapie przyjęcia zwierzęcia do orodka. Umożliwia on manualne wprowadzenie cech zwierzęcia znanych w momencie przyjęcia.

Użytkownik definiuje z rozwijanych list między innymi:

- gatunek, płeć oraz wiek w miesiącach lub latach,
- typ i okoliczności przyjęcia, na przykład złodziejstwo wacielskie, znalezienie na ulicy lub uratowanie z wypadku,
- cechy wyglądu, w tym ras dominujące oraz umaszczenie.

Po zatwierdzeniu formularza wbudowany w aplikację skrypt mapuje wartości z interfejsu na odpowiedni, tabelaryzowany wektor wejściowy i przekazuje go do wiodącego modelu klasyfikacyjnego. Pracownik otrzymuje następnie czytelny wynik:

1. **Ocena ryzyka długiego pobytu** – aplikacja klasyfikuje przypadek, używając wcześniej ustalonego progu decyzyjnego.
2. **Kwantyfikacja** – prezentowane jest bazowe prawdopodobieństwo adopcji w procentach.



Rysunek 7.2: Główny interfejs aplikacji demonstracyjnej (Single Animal Predictor) wspomagający ocenę nowo przyjmowanego zwierzęcia.

7.2.2 Wyjaśnianie decyzji (Interactive SHAP)


Warto prawdopodobieństwa jest użyteczną informacją, jednak personel weterynaryjny potrzebuje również zrozumienia powodów stojących za oceną algorytmu, czyli tak zwanej *explainability*. Dlatego dla predykcji pojedynczego zwierzęcia aplikacja może prezentować lokalne wyjaśnienie SHAP, na przykład w postaci wykresu typu *force plot* lub *waterfall plot*.

W perspektywie globalnej, czyli dla całego zbioru, wartości te układają się w interpretowalne wzorce, co prezentuje poniższy wykres.

Pracownik na ekranie aplikacji widzi analogiczny wykres, ale ograniczony do jednego zwierzęcia. Może sprawdzić, które konkretne atrybuty, na przykład podeszły wiek psa, ciemne umaszczenie czy trudna sytuacja znalezienia, obniżyły wynik, a które, na przykład przynależność do bardziej podanego typu rasy, działa na jego korzyść. Jest to istotny element budowania zaufania między człowiekiem a algorytmem i ograniczania ryzyka odrzucenia systemu z powodu postrzegania go jako „czarnej skrzynki” (*black-box*) [34].

7.2.3 Laboratorium hipotez (Hypothesis Lab)

Zakładka *Hypothesis Lab* stanowi bezprecedensowe przedsięwzięcie analitycznej części pracy w przestrzeni interfejsu użytkownika. Prezentuje ona wyniki weryfikacji hipotez H1–H5 w formie skondensowanych kart wizualnych z kluczowymi statystykami i wykresami.




Rysunek 7.3: Przykładowy widok panelu objaśniającego (Interactive SHAP), umoliwiający zrozumienie, które cechy wpłynęły na prognozy algorytmu.

Dzięki temu kierownik schroniska, bez konieczności sięgania po pełny raport analityczny, może zweryfikować, czy sezonowy wzorzec adopcyjności (H2) jest zgodny z bieżącymi obserwacjami operacyjnymi.


7.2.4 Przegląd historycznych grup zwierząt i analiza warunkowa

Dla stanowisk kierowniczych aplikacja udostępnia widok umożliwiający przeglądanie historycznych grup zwierząt z populacji AAC oraz dokonywanie analizy warunkowej (ang. *what-if analysis*). Pozwala to na nakładanie filtrów i obserwację zmian krzywych adopcyjności oraz median długości pobytu w czasie, z podziałem na kluczowe archetypy, takie jak szczeniaki, dorosłe psy określonych ras czy koty. Aplikacja może wskazać obszary wymagające uwagi, na przykład nagromadzenie starszych kotów w określonym kwartale roku, bez konieczności generowania zapytań SQL przez analityka.

Dzięki wizualizacji profilowych kontrastów adopcyjności (np. porównaniu młodych psów ras małych ze starszymi psami ras dużych), personel schroniska może błyskawicznie ocenić, jak zmiana wybranych parametrów wpływa na przewidywany czas pobytu. Pozwala to na trafniejsze identyfikowanie grup najwyższego ryzyka, co w ujęciu syntetycznym prezentuje poniższy wykres.



Rysunek 7.4: Zakadka *Hypothesis Lab* umoliwiajca przegldanie wyników weryfikacji hipotez badawczych H1–H5 w formie interaktywnych kart analitycznych.




Rysunek 7.5: Panel analityczny udostpniajcy przegld historycznych grup zwierz i pozwalajcy na przeprowadzanie analiz warunkowych przez kierownictwo schroniska.

7.3 Scenariusze uycia w pracy schroniska (triaging)

Najwiksz wartoci dodan aplikacji z punktu widzenia operacyjnego nie jest precyzyjna predykcja konkretnej daty, lecz moliwo zastosowania selekcji priorytetowej, czyli tak zwanego *triagingu*.

W tradycyjnym rodowisku kady przyjmowany pies otrzymuje standardow opiek. Czasem dopiero po kilku miesicach personel zauwaa, e dane zwierz le znosi pobyt w schronisku i zaczyna funkcjonowa jak dugoterminowy „rezydent”. W scenariuszu wspartym aplikacj:

1. zwierz jest wprowadzane do bazy,
2. aplikacja flaguje je jako przypadek wysokiego ryzyka dugiego pobytu, na przykad ze wzgldu na bardzo niskie prawdopodobiestwo adopcji lub dugi estymowany czas pobytu,
3. pracownik ju pierwszego dnia widzi ten alert i moe uruchomi procedury zaradcze, na przykad przekazanie zwierzcia do tymczasowego domu zastpczego (*foster*), rozpoczcie intensywniejszej promocji w lokalnych mediach spoeczniowych lub szybk interwencji behawiorysty.



Rysunek 7.6: Schemat procesu selekcji priorytetowej (triaging) w schronisku z wykorzystaniem systemu predykcyjnego.

7.4 Ograniczenia aplikacji i kierunki dalszego rozwoju

Ograniczenia aplikacji wynikają bezpośrednio z ograniczeń modelu predykcyjnego opisanych w rozdziale 5. Należy wskazać następujące zastrzeżenia:

- **Brak uogólnienia poza populację AAC.** Predykcje dla zwierząt spoza zakresu danych treningowych należy traktować jako ekstrapolowane, a nie interpolowane.
- **Pasywno wobec danych rzeczywistych.** Aplikacja nie pobiera danych operacyjnych w czasie rzeczywistym. Wyświetlane statystyki odzwierciedlają stan artefaktów z ostatniego uruchomienia potoku `pipeline-full`.
- **Brak formalnej ewaluacji użyteczności.** Niniejsza wersja stanowi demonstrację koncepcyjną i nie była poddana testom użytkowników zgodnie z metodą HCI [35].

Rozdzia 8

Podsumowanie i wnioski kocowe

Ostatni rozdzia pracy stanowi syntezy przeprowadzonych bada, ocen stopnia realizacji zaoonych celów oraz wskazanie obszarów wymagajcych dalszej eksploracji w przyszoci.

Gównym celem niniejszej pracy byo zbadanie moliwoci wykorzystania technik uczenia maszynowego do przewidywania adopcyjności i czasu pobytu zwierzt, czyli psów i kotów, w schronisku typu *No-Kill* na podstawie danych dostpnych wycznie w momencie ich przyjcia. Wyniki eksperymentów, oparte na analizie ponad 160 tysicy epizodów z Austin Animal Center, wskazuj na wysok skuteczno analityczn zastosowanych algorytmów z rodziny drzew decyzyjnych, w szczególności modeli *Gradient Boosting*. Zbudowane modele pozwalaj identyfikowa wzorce zwizane z póniejszym losem zwierzcia.

8.1 Odpowiedzi na pytania badawcze i weryfikacja hipotez

W toku prowadzonych eksperymentów zweryfikowano trzy kluczowe pytania badawcze (RQ), które ukierunkoway niniejsz prac:

RQ1: Jakie cechy zwierzcia s najwaniejszymi predyktorami adopcyjności?


Analiza wanoci cech, wsparta wyjanieniami SHAP, wskazaa spójnie, e najwaniejszymi predyktorami pozytywnej adopcyjności i krótkiego czasu pobytu s imi zwierzcia (zmienna `has_name`) oraz jego wiek. Modsze zwierzta posiadajce nadane imi w momencie przyjcia maj znacznie wiksze szanse na pozytywne zakoczenie epizodu schroniskowego. Tradycyjne cechy fizyczne, takie jak kategoria rasy czy umaszczenie (kolor), odgrywaj w ogólnym rozrachunku rol drugorzdn.

RQ2: Czy zaawansowane modele (Gradient Boosting) przewyższają linie bazowe?

Eksperymenty pokazały jednoznacznie przewagę zaawansowanych algorytmów drzewiastych nad metodami bazowymi. W klasyfikacji adopcji najlepszy okazał się model *HistGradientBoosting*, uzyskując PR-AUC równe 0,884 oraz ROC-AUC na poziomie 0,840, wyraźnie przewyższając regresję logistyczną [11]. W zadaniu regresyjnym najniższy błąd osiągnęła *CatBoost* (MAE = 18,55 dnia). Potwierdza to, że drzewa decyzyjne z boostingiem gradientowym skutecznie wychwytywać nieliniowe zależności pomiędzy atrybutami schroniskowymi.

RQ3: Jak zjawiska makrostrukturalne oraz różnice gatunkowe wpływają na wzorce?

Zidentyfikowano wyraźne różnice w zdolności predykcyjnej dla poszczególnych gatunków: skuteczność modeli była wyższa dla kotów (PR-AUC na poziomie 0,899) niż dla psów (PR-AUC 0,857), co sugeruje, że psy bywają oceniane przez pryzmat bardziej zoonych preferencji i cech niewidocznych w systemie (np. behawioralnych). Dodatkowo wykazano, że okres pandemii COVID-19 w istotny sposób zmodyfikował przepływ zwierząt w schronisku, wydłużając czas ich pobytu i modyfikując dynamikę rotacji jako bardzo silna zmienna zakłócająca (confounder).



Rysunek 8.1: Globalny wykres wartości SHAP dla modelu klasyfikacyjnego, potwierdzający dominującą rolę zmiennej `has_name`, wieku oraz typu przyjęcia w kształtowaniu prawdopodobieństwa adopcji.

8.2 Ograniczenia badawcze i metodologiczne

Ocena modeli predykcyjnych wymaga wskazania ich ogranicze.

1. **Cenzorowanie prawostronne (*Right-Censoring*).** Do trenowania klasycznych algorytmów predykcyjnych, w szczególności regresji dugoci pobytu, konieczne byo pominiecie epizodów, które nie posiaday wpisanego wyniku zakoczenia w momencie zrzutu bazy danych. Zjawisko to jest ograniczeniem wynikajcym z odstpienia od technik analizy przeycia (*Survival Analysis*).
2. **Specyfika schronisk typu *No-Kill* i generalizowalno (*Single-Shelter Generalizability*).** Zidentyfikowane wzorce odnosz si do placówki dziaającej w rodowisku o wysokiej wiadomoci spoecznej (Austin, Teksas). Przeniesienie modelu do schroniska o innej polityce demograficznej i mniejszych zasobach finansowych mogoby prowadzi do spadku skuteczności z powodu odmiennych wzorców.
3. **Brak zmiennych behawioralnych.** Zgodnie z zaoeniem predykcji tu po przyjciu (*intake-only*), w wektorze wejciowym nie zawarto oceny behawioralnej zwierzcia, co w pewnych przypadkach ogranicza sprawno modeli.
4. **Implikacje etyczne (*Ethical Implications*).** Uywanie modeli ML do wskazywania profili wysokiego ryzyka niesie potencjalne niebezpieczestwo stygmatyzacji. Bdnie przewidziane wysokie ryzyko dugiego pobytu mogoby zniechci personel do inwestowania czasu w dane zwierz, tworzc samospeniajc si przepowiedni.
5. **Upředzenia w etykietowaniu ras (*Breed Labeling Bias*).** Identyfikacja ras w schroniskach odbywa si czsto w sposób subiektywny na podstawie wygldu (*visual breed identification*). Moe to prowadzi do zaburzenia percepcji ras wprowadzanych do wektorów wejciowych modelu.
6. **Luki w kalibracji w zalenoci od grupy (*Calibration Gaps by Cohort*).** Cho ogólna skuteczno modelu jest wysoka, wystpuj różnice w kalibracji dla mniejszych, specyficznych grup (np. wybrane grupy psów), co po wdroeniu operacyjnym moe zmniejszy pewno modeli w pojedynczych kohortach.
7. **Pandemia jako czynnik zakócajcy (*COVID Confounders*).** Pandemia COVID-19 drastycznie zmienia zachowania adoptujcych oraz polityk przyj. Brak uwzględnienia odpowiednio skompensowanych wskaników tej makro-zmiennej moe powodowa problemy w analizie po pandemii.

8.3 Kierunki dalszych bada i rekomendacje praktyczne

Rezultaty uzyskane w niniejszej pracy wskazuj na moliwo dalszego rozwijania projektu w kierunku naukowym i wdroeniowym:


- **Uczenie transferowe (*Transfer Learning*).** Próba przeniesienia modeli wytrenowanych na bazie z Austin do innej, mniejszej placówki pozwoliaby na ocen podatnoci zbudowanych architektur na wiedz dziedzinow schronisk na szersz skal.
- **Integracja z danymi w czasie rzeczywistym (*Real-Time Data Integration*).** Stworzenie asynchronicznego API poczonego z klasycznym oprogramowaniem ewidencyjnym schroniska, by asystent predykcyjny klasyfikowa przypadki ju minut po dokonaniu rejestracji.
- **Wykorzystanie widzenia komputerowego (*Computer Vision*).** Ocena potencjau zdj zwierz przy pomocy sieci wizyjnych do przechwytywania walorów estetycznych z fotografii, które silnie wpywaj na wizerunek rynkowy i skonnoci adoptujcych.
- **Integracja z mediami spoecznociowymi (*Social Media Integration*).** Podczenie oprogramowania flagujcego do automatycznych akcji promocyjnych online w celu aktywnego dystrybuowania materiaów o trudnych zwierzach na zewntrnych platformach.
- **Ewaluacja wariantu wdroeniowego (Testy A/B).** Rzeczywiste eksperymenty losowe (A/B testing) z modelem w schronisku na oddzielonej grupie kontrolnej moglyby definitywnie potwierdzi zdolno systemu do przyspieszenia procesu operacyjnego, izolujc narzdzie od efektów psychologicznych.

8.3.1 Rekomendacje dla personelu schronisk

Obok perspektyw teoretycznych sformuowano wytyczne, z których personel placówek zyska korzyści poprzez korekt biecych dziaa na poziomie zarzdczym:

- **Flagowanie przypadków specyficznych pod ktem interwencji publicznych.** Psy w typie rasy *Pit Bull* oraz zwierzta przejte z drastycznych okolicznoci (*Public Assist*) powinny by objte wysokim priorytetem oceny behawioralnej tu po przyjciu, gdy ta grupa notuje jedne z najniszych wskaników adopcyjnoci.

- **Priorytetyzacja profesjonalnych zdj u starszych roczników (*Senior*).** Przejście z grupy Baby/Young do Adult/Senior koreluje z radykalnym spadkiem tempa adopcji. Skupienie wysiłku wolontariuszy i dobrych kamer w pierwszej kolejności na starszych zwierztach pozwoli zniwelować barierę wieku.
- **Obowiązkowe procedury namingowe.** Brak posiadanego przez zwierza imienia wpływa wysoce niekorzystnie na współczynnik trafie predykcyjnych na adopcję. Jak najszybsze nadawanie i rejestrowanie przynajmniej roboczych imion w systemie pozwala szybciej „zhumanizować” los zwierztcia w percepcji adoptujących.




Rysunek 8.2: Panel wspomagający uruchamianie ukierunkowanych kampanii adopcyjnych dla grup zwierzt o największym ryzyku długoterminowego pobytu.

Wdrożenie systemów uczenia maszynowego w sektorze ratownictwa zwierzt nie zastąpi specjalistycznej wiedzy ludzkiego personelu. Moe jednak stanowi narzędzie wspierające zarządzanie ryzykiem i dystrybucję ograniczonych zasobów. Skierowanie większej uwagi behawioralnej i promocyjnej na zwierzt zidentyfikowane przez model jako szczególnie narażone na długi pobyt moe być praktycznym krokiem w stronę usprawnienia systemu współczesnej opieki nad bezdomnymi zwierztami.

8.4 Podsumowanie kocowe i reprodukowalno

Przeprowadzona w niniejszej pracy analiza ponad 162 tysicy epizodów schroniskowych wskazuje, e algorytmy uczenia maszynowego, w szczególności modele z rodziny *Gradient Boosting*, mog skutecznie modelowa losy zwierz wycznie na podstawie pocztkowego profilu wejciowego. W klasyfikacji adopcji najwysz skuteczno osign model *HistGradientBoosting* z miar PR-AUC wynoszc 0,884 oraz ROC-AUC = 0,840. W zadaniu regresyjnym model *CatBoost* zredukowa redni bd bezwzglndny (MAE) do 18,55 dnia (RMSE = 38,36 dnia). Zidentyfikowano kluczowe determinanty ryzyka, wykazujc jednoznacznie wiksze znaczenie wczesnych okolicznoci przyjcia (np. charakteru zrzeczenia si zwierzcia) oraz wieku nad tradycyjnymi, wrodzonymi cechami fizycznymi.



Rysunek 8.3: Syntetyczny obraz profili zwierz szczególnie naraonych na dugoterminowy pobyt w schronisku, wyznaczonych przez model predykcyjny. Grupy te stanowi priorytet dla interwencji opisanych w rekomendacjach praktycznych.

Warto poznawcza pracy polega zatem nie tylko na osigniciu satysfakcjonujcych miar predykcyjnych, lecz take na uporzdkowaniu procesu analitycznego w sposób moliwy do interpretacji przez odbiorców nietechnicznych. Zastosowanie wyjanie SHAP pozwolio przej od samego wyniku klasyfikacji do wskazania czynników, które najbardziej zwikszy lub zmniejszay prawdopodobieństwo adopcji oraz ryzyko duszego pobytu. Dzięki temu model moe by rozumiany jako narzdzie wspomagajce decyzje, a nie jako zamknita, nieprzejrzysta procedura automatycznego rozstrzygania.

Z perspektywy praktycznej najwłaściwszym wnioskiem jest możliwe wcześniejsze wykrywanie przypadków wymagających dodatkowej uwagi organizacyjnej. Jeśli już w momencie przyjęcia można wskazać zwierzęta potencjalnie narażone na długi pobyt, schronisko może szybciej zaplanować działania promocyjne, konsultacje behawioralne lub wsparcie wolontariuszy. Taki sposób wykorzystania predykcji zachowuje nadrzędny rolę personelu i nie zastępuje indywidualnej oceny zwierzęcia, lecz dostarcza dodatkowego sygnału wspierającego priorytetyzację ograniczonych zasobów.

Technicznym elementem wzmacniającym wiarygodność tych ustaleń było obudowanie ich architekturą *MLOps*, opartą na konteneryzacji Docker i automatycznych audytach wycieku danych (Pytest). Zastosowanie środowiska Jupyter do R&D oraz wyizolowanych potoków uruchomieniowych *pipeline-full* zapewniło wysoką odtwarzalność procesu badawczego. Zbudowanie interfejsu Streamlit pokazało natomiast, w jaki sposób metody sztucznej inteligencji mogą zostać wprowadzone do codziennej pracy personelu niefachowego poprzez interaktywne raportowanie wartości SHAP.

Zgodnie z dobrymi praktykami oprogramowania naukowego cały kod źródłowy projektu, wraz z konfiguracją Docker Compose oraz testami jednostkowymi, został przygotowany w sposób umożliwiający audyt, weryfikację i replikację badań w przyszłości.

Niniejsza praca dowodzi, że dane administracyjne schroniska — dostępne powszechnie, lecz rzadko systematycznie analizowane — kryją w sobie wystarczający sygnał predykcyjny, aby już w momencie przyjęcia zwierzęcia wskazać przypadki wymagające szczególnej uwagi. Zbudowany system nie zastępuje oceny personelu, lecz uzupełnia ją o ilościowy kontekst wyprowadzony z historii ponad 162 tysięcy epizodów schroniskowych. Jego interpretowalna warstwa SHAP oraz certyfikowane przez testy środowisko *MLOps* czyni z niego narzędzie gotowe do dalszego badania w warunkach rzeczywistego schroniska. W szerszym kontekście wyniki wpisują się w rosnący nurt zastosowania uczenia maszynowego w ochronie dobrostanu zwierząt, wskazując jednocześnie na potrzeb dalszych badań nad sprawiedliwością algorytmiczną i generalizowalnością modeli schroniskowych [4].

Bibliografia

- [1] Shelter Animals Count. Intake and outcome data analysis: Annual report 2024. Online, <https://www.shelteranimalscount.org/explore-the-data/statistics-2024>, 2025. dostp 08.02.2026.
- [2] ASPCA. U.s. animal shelter statistics, 2024.
- [3] Austin Animal Center. No-kill implementation plan. Online, <https://www.austintexas.gov/page/no-kill-plan>, 2010. dostp 08.02.2026.
- [4] Janae Bradley and Suchithra Rajendran. Increasing adoption rates at animal shelters: a two-phase approach to predict length of stay and optimal shelter allocation. *BMC Veterinary Research*, 17(1):70, 2021.
- [5] Cem Sazara and Xin Gao. Predicting animal shelter pet adoption times and feature importance analysis using catboost. In *2022 IEEE 11th International Conference on Intelligent Systems (IS)*, pages 1–4, 2022.
- [6] H. J. Svoboda and C. L. Hoffman. Investigating the role of coat colour, age, sex, and breed on outcomes for dogs at two animal shelters in the united states. *Animal Welfare*, 24(4):497–506, November 2015.
- [7] FOUR PAWS. Stray animals: Pets without a home. Online, <https://www.fourpawsusa.org/campaigns-topics/topics/help-for-strays/stray-animals-pets-without-a-home>, 2023. dostp 08.02.2026.
- [8] L. M. Gunter, R. T. Barber, and C. D. L. Wynne. What’s in a name? effect of breed perceptions & labeling on attractiveness, adoptions & length of stay for pit-bull-type dogs. *PLOS ONE*, 11(3):e0146857, 2016.
- [9] J. Cain et al. Modeling shelter animal adoptions: A data-driven approach. *Animal Welfare*, 29(2):1–15, 2020.

- [10] A. Protopopova and C. D. L. Wynne. Adopter-dog interactions at the shelter: behavioral and contextual predictors of adoption. *Applied Animal Behaviour Science*, 140(3-4):211–221, 2012.
- [11] Léo Grinsztajn, Edouard Oyallon, and Gaël Varoquaux. Why do tree-based models still outperform deep learning on typical tabular data? In *Advances in Neural Information Processing Systems*, volume 35, 2022.
- [12] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [13] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [14] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [15] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Liu Tie-Yan. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [16] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [17] Haibo He and Edwardo A. Garcia. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9):1263–1284, 2009.
- [18] Tom Fawcett. An introduction to roc analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.
- [19] Glenn W. Brier. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3, 1950.
- [20] Edward L. Kaplan and Paul Meier. Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association*, 53(282):457–481, 1958.
- [21] David R. Cox. Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2):187–202, 1972.

- [22] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [23] S. M. Hawes et al. Predicting length of stay in animal shelters using machine learning. *Frontiers in Veterinary Science*, 9, 2022.
- [24] D. Sculley, Gary Holt, Daniel Golovin, Eugene Davydov, et al. Hidden technical debt in machine learning systems. In *Advances in Neural Information Processing Systems*, volume 28, 2015.
- [25] Dirk Merkel. Docker: Lightweight linux containers for consistent development and deployment. *Linux Journal*, 2014(239), 2014.
- [26] Ruslan Kuprieiev et al. Data version control (dvc): Documentation. Online, <https://dvc.org/doc>, 2024. dostp 08.02.2026.
- [27] Streamlit Inc. Streamlit documentation. Online, <https://docs.streamlit.io>, 2023. dostp 08.02.2026.
- [28] Jesse Davis and Mark Goadrich. The relationship between precision-recall and ROC curves. In *Proceedings of the 23rd International Conference on Machine Learning*, pages 233–240, 2006.
- [29] Alexandru Niculescu-Mizil and Rich Caruana. Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning*, pages 625–632, 2005.
- [30] Lisa M. Gunter, Rebecca T. Barber, and Clive D. L. Wynne. Outcomes for shelter animals during the COVID-19 pandemic: a case study of Arizona shelters. *Animals*, 12(3):272, 2022.
- [31] Scott M. Lundberg, Gabriel Erion, Hugh Chen, Alex DeGrave, Jordan M. Prutkin, Bala Nair, Ronit Katz, Jonathan Himmelfarb, Nisha Bansal, and Su-In Lee. From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1):56–67, 2020.
- [32] The Turing Way Community. The turing way: A handbook for reproducible, ethical and collaborative research. Zenodo, <https://doi.org/10.5281/zenodo.3233853>, 2025. dostp 12.06.2026.

- [33] Dominik Kreuzberger, Niklas Kühl, and Sebastian Hirschl. Machine learning operations (MLOps): Overview, definition, and architecture. *IEEE Access*, 11:31866–31879, 2023.
- [34] Amina Adadi and Mohammed Berrada. Peeking inside the black-box: A survey on explainable artificial intelligence (XAI). *IEEE Access*, 6:52138–52160, 2018.
- [35] Eduardo Mosqueira-Rey, Elena Hernández-Pereira, David Alonso-Ríos, José Bobes-Bascarán, and Ángel Fernández-Leal. Human-in-the-loop machine learning: A state of the art. *Artificial Intelligence Review*, 56(4):3005–3054, 2023.

Spis rysunków

Rysunek 1.1	Liczba przyj zwierzt do schroniska Austin Animal Center w kolejnych latach (2013–2025). Wyranie widoczny jest spadek wolumenu przyj w latach 2020–2021 zwizany z ograniczeniami pandemii COVID-19, a nastpnie stopniowy powrót do wartoci sprzed pandemii.	2
Rysunek 1.2	Liczba adopcji zarejestrowanych w AAC w kolejnych latach (2013–2025). Zestawienie z Rysunkiem 3.2 ilustruje zmienn relacj midzy wolumenem przyj a skutecznoaci adopcji w poszczególnych latach.	3
Rysunek 1.3	Schemat blokowy metodyki badawczej i przeplywu pracy (pipeline MLOps).	6
Rysunek 2.1	Krzywe Kaplana-Meiera szacujce prawdopodobieństwo pozostania w schronisku bez adopcji, w podziale na gatunek zwierzcia (dane Austin Animal Center, 2013–2025). Spadek krzywej odpowiada momentom adopcji; krzywe ucinane s przez obserwacje ocenzone.	12
Rysunek 2.2	Podsumowanie wartoci SHAP dla modelu klasyfikacji adopcji (CatBoost). Kady punkt reprezentuje jedn obserwacj; kolor koduje warto cechy (czerwony – wysoka, niebieski – niska). Cechy posortowane malejco wedug redniej bezwzglidnej wartoci SHAP.	13
Rysunek 3.1	Porównanie strategii dopasowania rekordów przyjcia i wyniku. . .	17
Rysunek 3.2	Roczna liczba przyj zwierzt do Austin Animal Center w latach 2013–2025.	19
Rysunek 3.3	Roczna liczba adopcji w Austin Animal Center.	20
Rysunek 3.4	Skumulowane krzywe adopcji dla psów i kotów.	21
Rysunek 3.5	Krzywe Kaplana-Meiera prawdopodobieństwa adopcji w funkcji czasu pobytu, z podziaem na psy i koty.	21

Rysunek 3.6	Krzywe Kaplana-Meiera czasu do adopcji w podziale na grupy wiekowe zwierząt (wyczenie adoptowane). Zwierzęta z grupy baby opuszczają schronisko najszybciej; krzywa dla grupy senior opada wolniej i osiąga niższy poziom skumulowanej adopcji.	22
Rysunek 3.7	Krzywe Kaplana-Meiera czasu do adopcji według sposobu przyjęcia (wyczenie adoptowane). Zwierzęta przyjęte w ramach zręcznościowych (Owner Surrender) trafiają do nowych domów szybciej niż bezpaskie (Stray).	22
Rysunek 3.8	Porównanie wskaźników adopcji między typowymi profilami zwierząt.	23
Rysunek 4.1	Chronologiczny podział zbioru danych	27
Rysunek 4.2	Wykres SHAP Summary (beeswarm) dla klasyfikatora adopcji [22]. Każdy punkt odpowiada jednej obserwacji ze zbioru testowego. Kolor odzwierciedla wartość cechy (czerwony – wysoka, niebieski – niska), a pozycja pozioma – wartość SHAP. Szczegółowa interpretacja wyników w rozdziale 5.	32
Rysunek 4.3	Zagregowany wpływ Rodzin Cech na predykcje klasyfikatora (suma bezwzględnych wartości SHAP per Rodzina). Grupowanie cech pozwala ocenić relatywny wkład cech kategorii atrybutów.	33
Rysunek 5.1	Logika ewaluacji modeli klasyfikacyjnych i regresyjnych.	36
Rysunek 5.2	Zbiorcze porównanie zdolności dyskryminacyjnej badanych algorytmów na zbiorze czynym oraz podzbiorach gatunkowych.	37
Rysunek 5.3	Wartości rzeczywiste kontra przewidywane dla modelu regresyjnego (CatBoost). Widoczny jest systematyczny niedoszacunek dla długich pobyków (powyżej 60 dni).	38
Rysunek 5.4	Rozkład reszt modelu regresyjnego. Silna asymetria prawostronna potwierdza koncentrację błędów na rzadkich przypadkach bardzo długich pobyków – MAE wynosi 18,55 dnia, natomiast mediana błędów zaledwie 6,28 dnia.	39
Rysunek 5.5	Szczegółowy przebieg krzywej ROC dla zwyczajowego klasyfikatora (HistGradientBoosting). Widoczne wyraźne wysklepienie nad linią losową (AUC = 0.50).	39
Rysunek 5.6	Krzywa Precision-Recall dla najlepszego modelu klasyfikacyjnego. Pozwala lepiej ocenić jako predykcje, zwłaszcza w sytuacji niezbalansowania klas.	40

Rysunek 5.7	Macierz pomyłek dla modelu kocowego, pozwalająca szczegółowo przeleźć rozkład poprawnych i błędnych klasyfikacji.	41
Rysunek 5.8	Porównanie badanych algorytmów pod kątem średniego błęd bezwzględnego (MAE) na zbiorze czynnym oraz podzbiorach gatunkowych. .	41
Rysunek 5.9	Zestawienie błęd RMSE dla modeli regresyjnych. Wyższa waga większych odchyleń uwypukla przewagę CatBoosta nad innymi algorytmami.	42
Rysunek 5.10	Porównanie wagi rodzin cech dla wyniku klasyfikacji. Cechy okoliczności przyjęcia (Intake) dominują nad wyglądem.	43
Rysunek 5.11	Spadek prawdopodobieństwa adopcji postępujący wraz z wiekiem zwierzęcia (w latach).	43
Rysunek 5.12	Mediana liczby dni do adopcji w podziale na grupy wiekowe (w tym zwierzęta adoptowane). Niemowlęta opuszczają schronisko najszybciej.	44
Rysunek 5.13	Krzywe Kaplana-Meiera dla adopcji w podziale na grupy wiekowe [20]. Straszniejszy przebieg krzywej dla grupy baby potwierdza szybszy czas wyjścia ze schroniska.	44
Rysunek 5.14	Różnice we wskaźnikach adopcji przed, w trakcie oraz po pandemii COVID-19.	45
Rysunek 5.15	Wolumen przyjęć w zależności od okresu względem pandemii COVID-19.	46
Rysunek 5.16	Wskaźniki adopcji w rozbięciu na pory roku. Wiosna i lato wykazują wyższe wskaźniki niż jesień i zima.	46
Rysunek 5.17	Mediana czasu pobytu w zależności od sezonu.	47
Rysunek 5.18	Porównanie wskaźnika adopcji ze względu na umaszczenie zwierząt, wskazujące na lekkie odwrócenie trendu dla grupy o ciemnym umaszczeniu.	48
Rysunek 5.19	Różnice w medianie czasu pobytu dla zwierząt z jasnym i ciemnym umaszczeniem.	48
Rysunek 5.20	Zbiórny wykres SHAP (Summary Plot) dla zadania klasyfikacji, obrazujący wpływ poszczególnych wartości cech na przewidywane prawdopodobieństwo adopcji.	49
Rysunek 5.21	Zestawienie średnich wartości SHAP według rodzin cech dla klasyfikatora adopcji. Rodzina <code>name_identity</code> uzyskuje najwyższy sumaryczny wkład predykcyjny ($\approx 0,55$), wyprzedzając cechy wiekowe ($\approx 0,48$) oraz rasowo-wyglądowe ($\approx 0,26$).	50
Rysunek 5.22	Zbiórny wykres SHAP dla regresji czasu pobytu, pokazujący w jaki sposób dane parametry wydłużają lub skracają prognozowany wynik. . . .	50

Rysunek 5.23 Krzywa kalibracyjna (Calibration Curve) pokazująca, w jakim stopniu przewidywane przez model prawdopodobieństwo adopcji odpowiada rzeczywistej częstotliwości (Perfectly calibrated).	51
Rysunek 5.24 Wizualizacja przekrojów bdu dla modelu klasyfikacyjnego. Ukazuje wycinki zbioru, w których skuteczność modelu jest najniższa.	52
Rysunek 5.25 Analiza segmentacyjna bdów regresji. Rozbicie przypadków według wielkości MAE dla różnych profili zwierząt.	53
Rysunek 6.1 Architektura serwisów Docker Compose i udostępniane wolumeny pamięci	56
Rysunek 6.2 Porównanie strategii ewaluacji chronologicznej zastosowanej w potoku eksperymentalnym. Dane z lat 2013–2021 posłużyły do uczenia modeli, lata 2022–2023 do walidacji i doboru progu decyzyjnego, a lata 2024–2025 stanowi jednorazowy zbiór testowy. Podejście to odwzorowuje warunki rzeczywistego wdrożenia, w którym model musi generalizować na dane z przyszłości.	59
Rysunek 6.3 Strona główna aplikacji demonstracyjnej (Streamlit) działającej w kontenerze dashboard po pomyślnym zakończeniu potoku pipeline-full. Widoczne zakładki odpowiadają modułom funkcjonalnym opisanym w rozdziale 7.	61
Rysunek 7.1 Widok startowy aplikacji demonstracyjnej (<i>Executive Overview</i>) z widocznym selektorem języka interfejsu (Polish/English) w panelu bocznym oraz zestawieniem wyników selekcji modelu. Aplikacja dostępna jest lokalnie pod adresem localhost:8501 po uruchomieniu docker-compose up dashboard.	64
Rysunek 7.2 Główny interfejs aplikacji demonstracyjnej (Single Animal Predictor) wspomagający ocenę nowo przyjmowanego zwierzęcia.	66
Rysunek 7.3 Przykładowy widok panelu objaśniającego (Interactive SHAP), umożliwiający zrozumienie, które cechy wpłynęły na prognozę algorytmu.	67
Rysunek 7.4 Zakładka <i>Hypothesis Lab</i> umożliwiająca przeglądanie wyników weryfikacji hipotez badawczych H1–H5 w formie interaktywnych kart analitycznych.	68
Rysunek 7.5 Panel analityczny udostępniający przegląd historycznych grup zwierząt i pozwalający na przeprowadzanie analiz warunkowych przez kierownictwo schroniska.	68

Rysunek 7.6 Schemat procesu selekcji priorytetowej (triaging) w schronisku z wykorzystaniem systemu predykcyjnego.	69
Rysunek 8.1 Globalny wykres wartoci SHAP dla modelu klasyfikacyjnego, potwierdzajcy dominujc rol zmiennej <code>has_name</code> , wieku oraz typu przyjcia w ksztatowaniu prawdopodobiestwa adopcji.	72
Rysunek 8.2 Panel wspomagajcy uruchamianie ukierunkowanych kampanii adopcyjnych dla grup zwierz o największym ryzyku dugoterminowego pobytu.	75
Rysunek 8.3 Syntetyczny obraz profili zwierz szczególnie naraonych na dugoterminowy pobyt w schronisku, wyznaczonych przez model predykcyjny. Grupy te stanowi priorytet dla interwencji opisanych w rekomendacjach praktycznych.	76