



POLSKO-JAPOŃSKA AKADEMIA
TECHNIK KOMPUTEROWYCH

Wydział Informatyki

Katedra Systemów Inteligentnych i Data Science
Data Science

Magdalena Sokolowska
S32924

**Dane, które ratują życie: Analiza i wizualizacja
czynników wpływających na adopcję psów i
kotów w Austin Animal Center z wykorzystaniem
metod uczenia maszynowego**

Praca dyplomowa magisterska

Promotor: prof. dr hab. Grzegorz Wójcik

Warszawa, styczeń 2026 r.

Streszczenie

Praca przedstawia reprodukowalny system uczenia maszynowego wspierający analizę adopcji zwierząt w Austin Animal Center. Zintegrowano rejestry przyjęć i wyników z lat 2013–2025, uzyskując 162 355 chronologicznie dopasowanych epizodów. Zdefiniowano dwa odrębne zadania: klasyfikację adopcji względem innych wyników oraz regresję liczby dni do dowolnego dopasowanego wyniku. Ewaluację przeprowadzono chronologicznie: trening na latach 2013–2021, kalibracja i wybór modeli na latach 2022–2023 oraz jednorazowy test na latach 2024–2025.

Na podstawie wyników walidacyjnych wybrano CatBoost dla klasyfikacji oraz Random Forest dla regresji. Na zbiorze testowym model klasyfikacyjny osiągnął ROC-AUC 0,841, PR-AUC 0,885 i F1 0,817. Wybrany model regresyjny uzyskał MAE 20,07 dnia, RMSE 35,82 dnia i medianę błędu bezwzględnego 10,82 dnia. Interpretację predykcji oparto na wartościach SHAP, z zachowaniem rozróżnienia między zależnością predykcyjną a przyczynowością. Projekt obejmuje 20-krokowy potok, pokwitowania uruchomień, 48 wymaganych artefaktów, dashboard Streamlit i środowisko Docker Compose. Końcowa weryfikacja objęła 269 zaliczonych testów oraz 3 oczekiwane pominięcia.

Słowa kluczowe: adopcja zwierząt, uczenie maszynowe, Austin Animal Center, CatBoost, Random Forest, SHAP, MLOps

Abstract

This thesis presents a reproducible machine-learning system supporting animal-adoption analysis at Austin Animal Center. Intake and outcome records from 2013–2025 were integrated into 162,355 chronologically matched episodes. Two distinct tasks were defined: classification of adoption versus other outcomes and regression of days to any matched outcome. Evaluation followed a chronological design: training on 2013–2021, calibration and model selection on 2022–2023, and one-time final testing on 2024–2025.

Validation evidence selected CatBoost for classification and Random Forest for regression. On the test set, the classification model achieved ROC-AUC 0.841, PR-AUC 0.885, and F1 0.817. The selected regression model achieved MAE 20.07 days, RMSE 35.82 days, and median absolute error 10.82 days. Predictions were interpreted with SHAP while explicitly separating predictive association from causality. The project includes a 20-step

pipeline, run receipts, 48 required artifacts, a Streamlit dashboard, and a Docker Compose environment. Final verification recorded 269 passing tests and 3 expected skips.

Keywords: animal adoption, machine learning, Austin Animal Center, CatBoost, Random Forest, SHAP, MLOps

Spis treści

1	Wstęp	2
1.1	Kontekst problemu i znaczenie badań	2
1.2	Cel, hipotezy i pytania badawcze	4
1.3	Zakres i struktura pracy	6
2	Podstawy teoretyczne i przegląd literatury	9
2.1	Problem bezdomności zwierząt i filozofia No-Kill	9
2.2	Predykcyjne modelowanie adopcji	10
2.3	Reprodukowalność i inżynieria danych (MLOps)	12
3	Dane i przygotowanie zbioru badawczego	14
3.1	Źródło danych i zakres analizy	14
3.2	Charakterystyka zbiorów wejściowych	14
3.3	Standaryzacja i czyszczenie danych	15
3.4	Konstrukcja epizodów i dopasowanie rekordów	15
3.5	Zmienne docelowe	16
3.6	Konstrukcja cech wejściowych	16
3.7	Charakterystyka opisowa zbioru	17
3.8	Ograniczenia danych	19
3.9	Podsumowanie przygotowania danych	22
4	Metodyka modelowania i oceny modeli	23
4.1	Cel modelowania	23
4.2	Formalne sformułowanie problemu	24
4.3	Przygotowanie danych i podział chronologiczny	24
4.4	Algorytmy predykcyjne	25
4.5	Metryki oceny	26
4.6	Interpretowalność (SHAP)	28
4.7	Protokół eksperymentu	29
4.8	Ograniczenia	30
5	Wyniki badań i interpretacja modeli	32
5.1	Ramy interpretacyjne rozdziału	32
5.2	Porównanie jakości modeli	32
5.2.1	Porównanie modeli regresyjnych	37
5.3	Weryfikacja hipotez badawczych	39

5.4	Interpretacja i wiarygodność modelu	46
5.4.1	Analiza błędów i wiarygodność modelu	47
6	Architektura systemu i reprodukowalność eksperymentów	50
6.1	Środowisko wdrożeniowe i konteneryzacja (Docker)	50
6.1.1	Uzasadnienie złożoności systemu (Dlaczego MLOps?)	50
6.1.2	Architektura serwisów (Docker Compose)	51
6.2	Architektura <i>Artifact-First</i> i separacja warstw	52
6.3	Organizacja kodu i modułowość	52
6.4	Automatyzacja potoku (Pipeline) a notatniki Jupyter	53
6.4.1	Fazy zautomatyzowanego potoku i Data Provenance	53
6.5	Rygor testowy i audyty danych	55
7	Aplikacja demonstracyjna i sposób prezentacji wyników	57
7.1	Cel i środowisko aplikacji	57
7.2	Główne moduły funkcjonalne (widoki)	58
7.2.1	Symulator pojedynczego przyjęcia (Model Sensitivity Demo)	58
7.2.2	Wyjaśnialność decyzji (Interactive SHAP)	59
7.2.3	Laboratorium hipotez (Hypothesis Lab)	60
7.2.4	Przegląd historycznych grup zwierząt i analiza warunkowa	61
7.3	Scenariusze użycia w pracy schroniska (triaging)	61
7.4	Ograniczenia aplikacji i kierunki dalszego rozwoju	63
8	Podsumowanie i wnioski końcowe	64
8.1	Odpowiedzi na pytania badawcze i weryfikacja hipotez	64
8.2	Ograniczenia badawcze i metodologiczne	65
8.3	Kierunki dalszych badań i rekomendacje praktyczne	66
8.3.1	Rekomendacje dla personelu schronisk	67
8.4	Podsumowanie końcowe i reprodukowalność	67
	Bibliografia	69
	Lista figur	76

1. Wstęp


1.1 Kontekst problemu i znaczenie badań

Każdego roku do schronisk dla zwierząt na całym świecie trafiają miliony bezdomnych psów i kotów, co stanowi ogromne wyzwanie organizacyjne i logistyczne. W samych Stanach Zjednoczonych szacuje się, że rocznie do schronisk trafia około 6 milionów psów i kotów [1, 2]. Efektywne zarządzanie taką liczbą podopiecznych wymaga zapewnienia odpowiedniej opieki, zasobów i przestrzeni każdemu zwierzęciu, przy jednoczesnym dążeniu do jak najszybszego znalezienia mu nowego domu. Jednym z kluczowych wskaźników skuteczności pracy schroniska jest czas pobytu zwierzęcia pod jego opieką (ang. *Length of Stay*, LOS). Im krótszy jest LOS, tym mniejsze obciążenie dla zwierzęcia (ograniczenie stresu, ryzyka chorób i zgonu) oraz dla placówki (niższe koszty utrzymania i więcej wolnego miejsca dla kolejnych potrzebujących).


Coraz więcej schronisk przyjmuje filozofię „*No-Kill*”, która zakłada unikanie eutanazji zdrowych zwierząt poprzez osiągnięcie bardzo wysokiego odsetka adopcji i uratowań. Przykładem spektakularnego sukcesu podejścia *No-Kill* jest *Austin Animal Center* (AAC) w Teksasie. Od 2011 roku miasto Austin może poszczycić się mianem największego miasta w USA o statusie *No-Kill*, utrzymując współczynnik uratowań (ang. *live-release rate*) powyżej 90% [3]. Schronisko AAC przyjmuje ponad 18 tysięcy zwierząt rocznie [3], co czyni je jedną z największych tego typu placówek komunalnych w kraju i jednocześnie stawia przed nim ogromne wymagania w zakresie efektywnego wykorzystania danych i zasobów. Dążenie do utrzymania wysokiego odsetka adopcji przy tak dużej skali działalności wymaga ciągłego usprawniania procesów i podejmowania trafnych decyzji operacyjnych.

W ostatnich latach zauważalny jest istotny zwrot od podejmowania decyzji w oparciu o doświadczenie i intuicję personelu ku podejściu opartemu na danych (*data-driven*). Większość dużych schronisk gromadzi szczegółowe informacje o każdym przyjęciu i opuszczeniu zwierzęcia (intake & outcome), jednak w wielu przypadkach dane te nie są w żadnym stopniu wykorzystywane do wyciągania praktycznych wniosków. Zastosowanie nowoczesnych metod analizy danych i uczenia maszynowego otwiera możliwość lepszego zrozumienia, jakie czynniki sprzyjają szybkim adopcjom, a jakie wiążą się z dłuższym pobytem zwierząt w schronisku lub – w skrajnych przypadkach – ich uśpieniem. Modele predykcyjne mogą pomóc przewidywać prawdopodobieństwo adopcji konkretnego zwierzęcia oraz zidentyfikować obszary wymagające interwencji (np. grupy zwierząt o podwyższonym ryzyku długotrwałego pobytu). Tym samym, badania łączące dane schronisk z metodami *machine learning* mają istotne znaczenie praktyczne: mogą przyczynić się do optymalizacji pracy schronisk, lepszego alokowania zasobów oraz, co najważniejsze, ratowania większej liczby zwierząt poprzez skracanie czasu oczekiwania na nowy dom i uniknięcie śmierci.

Analizowany w niniejszej pracy zbiór danych obejmuje 162 390 dopasowanych epizodów pobytu (przyjęcie–wynik) zarejestrowanych w systemie AAC w latach 2013–2025, w tym 93 805 epizodów dotyczących psów oraz 68 585 dotyczących kotów.



Rysunek 1.1: Liczba przyjęć zwierząt do schroniska Austin Animal Center w kolejnych latach (2013–2025). Wyraźnie widoczny jest spadek wolumenu przyjęć w latach 2020–2021 związany z ograniczeniami pandemii COVID-19, a następnie stopniowy powrót do wartości sprzed pandemii.



Rysunek 1.2: Liczba adopcji zarejestrowanych w AAC w kolejnych latach (2013–2025). Zestawienie z Rysunkiem 1.1 ilustruje zmienną relację między wolumenem przyjęć a skutecznością adopcji w poszczególnych latach.

Dotychczasowe badania wykazały obiecujące rezultaty w zakresie predykcji adopcji z wykorzystaniem uczenia maszynowego. Bradley i Rajendran [4] zaproponowali dwufazowy model predykcji czasu pobytu w schronisku, natomiast Sazara i Gao [5] zastosowali algorytm CatBoost do przewidywania czasu adopcji, uzyskując wysoką trafność i identyfikując wiek oraz rasę jako najważniejsze cechy. Niniejsza praca rozszerza te podejścia o chronologiczny

podział danych, analizę interpretowalności SHAP oraz wdrożenie interaktywnego systemu decyzyjnego.

Warto też wspomnieć o wymiarze etycznym. Dane wykorzystywane w niniejszej pracy pochodzą z publicznie dostępnych rejestrów Austin Animal Center i nie zawierają danych osobowych adopterów. Jednakże zastosowanie modeli predykcyjnych w kontekście schroniskowym wiąże się z ryzykiem utrwalenia istniejących uprzedzeń (np. dyskryminacji rasowej zwierząt). Dlatego model zaprojektowano jako narzędzie wspierające, a nie zastępujące, decyzje personelu schroniska.

1.2 Cel, hipotezy i pytania badawcze

Celem niniejszej pracy jest opracowanie kompleksowego, zaawansowanego systemu analitycznego wykorzystującego metody uczenia maszynowego do prognozowania adopcji zwierząt na podstawie danych historycznych ze schroniska oraz identyfikacji najważniejszych czynników wpływających na przebieg tych adopcji. W szczególności praca skupia się na oszacowaniu prawdopodobieństwa adopcji oraz czasu oczekiwania na adopcję dla psów i kotów przyjętych do *Austin Animal Center* w latach 2013–2025. Osiągnięcie celu naukowego wymaga zbudowania dokładnego modelu predykcyjnego, ale wyzwaniem może być również zadbanie o jego interpretowalność oraz użyteczność praktyczną dla nietechnicznych użytkowników. Dlatego też celem wdrożeniowym jest implementacja systemu, który integruje powstały model w formie interaktywnej aplikacji (*dashboard*) przeznaczanej dla personelu i wolontariuszy schroniska. System ten ma umożliwiać eksplorację wyników predykcji (np. przewidywanego czasu adopcji danego zwierzęcia) oraz przeprowadzanie analiz typu „co-jeśli” w celu wsparcia decyzji dotyczących działań ukierunkowanych na zwierzęta o obniżonych szansach adopcyjnych.

Równolegle, celem analitycznym niniejszej pracy jest pogłębiona identyfikacja tych cech zwierząt oraz czynników zewnętrznych, które istotnie wpływają na zmniejszenie prawdopodobieństwa adopcji, co może stanowić podstawę do dalszych interwencji, zmian w działaniach operacyjnych lub kampanii adopcyjnych ukierunkowanych na najbardziej narażone grupy.

Aby zrealizować powyższe cele, sformułowano następujące kluczowe pytania badawcze:

1. **Które zmienne opisujące zwierzę oraz okoliczności jego przyjęcia do schroniska najsilniej wpływają na prawdopodobieństwo szybkiej adopcji?** Jakie cechy (np. wiek, rasa, umaszczenie, płeć, stan zdrowia, typ przyjęcia) wykazują największą moc predykcyjną w kontekście skrócenia lub wydłużenia czasu pobytu zwierzęcia w schronisku?

2. **Jak złożone modele uczenia maszynowego wypadają na tle prostszych metod w zadaniu przewidywania adopcji zwierząt?** Innymi słowy, czy zastosowanie algorytmów klasy *ensemble* (np. gradient boosting w modelach XGBoost/CatBoost) zapewnia wyraźnie lepszą trafność prognoz niż podstawowe podejścia bazowe (takie jak proste modele regresyjne lub losowe strategie decyzji)?
3. **Czy istnieją istotne różnice w wzorcach adopcji między psami a kotami oraz jak te wzorce zmieniały się w czasie?** Pytanie to dotyczy zarówno ewentualnych odmiennych czynników wpływających na adopcje w zależności od gatunku, jak i trendów czasowych (np. czy w kolejnych latach obserwuje się poprawę skuteczności adopcji, zmiany sezonowe itp.).

Mając na uwadze powyższe pytania oraz przegląd literatury przedmiotu, przyjęto również kilka hipotez badawczych, które zostaną zweryfikowane w toku analizy:

- H1:** Sposób, w jaki zwierzę trafia do schroniska (np. jako bezdomna znajduje przywieziona przez służby miejskie, czy jako zwierzę oddane bezpośrednio przez właściciela), ma istotniejszy wpływ na prawdopodobieństwo i tempo jego adopcji niż cechy wyglądu. Innymi słowy, zakłada się, że typ przyjęcia (ang. *intake type*) stanowi silniejszy prognostyk sukcesu adopcyjnego niż przynależność do konkretnej rasy.
- H2:** Występuje wyraźny efekt sezonowości w przebiegu adopcji. Pewne okresy w roku (np. miesiące letnie lub okolice przerw świątecznych) sprzyjają szybszym adopcjom, skracając średni czas pobytu zwierząt w schronisku, podczas gdy w innych okresach tempo adopcji spada. Hipoteza ta opiera się na założeniu, że czynniki zewnętrzne (takie jak wakacje, kampanie społeczne czy warunki pogodowe) wpływają na popyt na adopcje.
- H3:** Wiek zwierzęcia ma istotny wpływ na jego szanse adopcyjne – młodsze zwierzęta są adoptowane szybciej niż starsze. Zgodnie z obserwacjami z praktyki schroniskowej, szczenięta i kocięta cieszą się większym zainteresowaniem niż osobniki dorosłe lub starsze.
- H4:** Umaszczenie zwierzęcia wpływa na prawdopodobieństwo adopcji – zwierzęta o ciemnym umaszczeniu (np. czarne psy i koty) są adoptowane rzadziej. Zjawisko to, znane jako *black dog syndrome*, jest często przytaczane w mediach, choć literatura naukowa nie jest w tej kwestii jednogłębna [6]. W ramach pracy zweryfikowane zostanie, czy w danych z AAC zjawisko to jest rzeczywiście obserwowalne.
- H5:** Pandemia COVID-19 (2020–2021) spowodowała istotne zmiany w dynamice adopcji zwierząt: w roku 2020 odnotowano wzrost wskaźnika adopcji i skrócenie mediany czasu pobytu (tzw. *pandemic adoption surge*), natomiast rok 2021 przyniósł częściowe

odwrócenie tego trendu wraz ze stopniowym powrotem do normalnej działalności schroniska.

Powyższe hipotezy zostaną poddane weryfikacji w dalszych rozdziałach pracy. Analiza ich trafności pozwoli nie tylko odpowiedzieć na postawione pytania badawcze, lecz także lepiej zrozumieć dynamikę procesów adopcyjnych. Praca obejmuje pełny cykl projektowy: od analizy danych i budowy modeli predykcyjnych po wdrożenie działającego systemu wspierającego decyzje w schronisku.


Tabela 1.1: Zestawienie głównych hipotez badawczych weryfikowanych w pracy.

Identyfikator	Treść hipotezy
H1	Typ przyjęcia do schroniska ma istotniejszy wpływ na prawdopodobieństwo i tempo adopcji niż cechy wyglądu (np. rasa).
H2	Występuje wyraźna sezonowość w adopcjach, wpływająca na czas pobytu zwierząt w schronisku w zależności od pory roku.
H3	Młodsze zwierzęta (szczenięta, kocięta) mają wyższe szanse na szybką adopcję w porównaniu do starszych osobników.
H4	Zjawisko „black dog syndrome” (rzadsze adopcje zwierząt o ciemnym umaszczeniu) jest zauważalne w analizowanym zbiorze danych.
H5	Pandemia COVID-19 (2020–2021) wpłynęła na dynamikę adopcji oraz zmiany w średnim czasie pobytu zwierząt.

1.3 Zakres i struktura pracy

Zakres analizy obejmuje dane historyczne pochodzące z *Austin Animal Center* z lat 2013–2025, które zawierają informacje zarówno o przyjęciach zwierząt do schroniska (*intake*), jak i o ich dalszych losach (*outcome*, w szczególności adopcjach). Dane te pozwalają prześledzić pełny cykl pobytu zwierzęcia w schronisku – od momentu znalezienia lub oddania, aż do chwili adopcji bądź innego zakończenia opieki. W pracy skoncentrowano się na dwóch dominujących w schronisku gatunkach, tj. psach i kotach, z pominięciem mniej licznych gatunków egzotycznych. Analizy zostały przeprowadzone oddzielnie dla psów i kotów wszędzie tam, gdzie było to zasadne, aby uchwycić ewentualne różnice między tymi grupami. Pod względem merytorycznym praca łączy zagadnienia z obszaru nauk o danych (*data science*), uczenia maszynowego oraz inżynierii oprogramowania, co znajduje odzwierciedlenie w strukturze pracy.

Rozdziały niniejszej pracy zostały ułożone w taki sposób, aby stopniowo wprowadzać czytelnika w temat i następnie przejść do szczegółów implementacyjnych rozwiązania. Rozdział 2 przedstawia przegląd literatury oraz teoretyczne podstawy związane z problematyką bezdomności zwierząt i adopcji w kontekście zarządzania schroniskami. Omówiono



Rysunek 1.3: Schemat blokowy metodyki badawczej i przepływu pracy (pipeline MLOps).

w nim kluczowe pojęcia (takie jak zasada *No-Kill* czy metryki w pracy schronisk), a także metody analizy danych i algorytmy uczenia maszynowego wykorzystywane dotychczas do rozwiązywania podobnych problemów. Rozdział 3 zawiera opis danych wykorzystanych w badaniu – źródła i charakterystykę zbioru danych z AAC, sposób ich wstępnego przetworzenia oraz analizę eksploracyjną (EDA). Celem tej części jest zrozumienie struktury danych, wstępna identyfikacja trendów i potencjalnych zależności (np. typowe przedziały wiekowe zwierząt, sezonowość przyjęć i adopcji, itp.) oraz przygotowanie odpowiedniego zestawu cech do modelowania.

W Rozdziale 4 przedstawiono metodologię budowy modeli predykcyjnych. Opisano proces doboru cech (*feature engineering*) istotnych z punktu widzenia przewidywania adopcji, a także wybrane algorytmy uczenia maszynowego. Szczególną uwagę poświęcono modelom typu *gradient boosting*, takim jak XGBoost i CatBoost, ze względu na ich wysoką skuteczność w zadaniach z danymi tabelarycznymi. Omówiono też konfigurację tych modeli, strategię walidacji krzyżowej oraz metryki oceny, które posłużą do porównania ich z prostszymi modelami bazowymi. Rozdział 5 prezentuje uzyskane wyniki eksperymentów. Przedstawiono w nim porównanie jakości predykcji różnych modeli (m.in. porównanie modeli gradient boosting z modelami liniowymi) oraz analizę interpretowalności najlepszego modelu. Wykorzystano do tego techniki objaśniania decyzji czarnej skrzynki, w szczególności wartości SHAP (*Shapley Additive Explanations*), które pozwalają określić wpływ poszczególnych cech (np. wieku, rasy, typu intaku) na przewidywane prawdopodobieństwo adopcji. Taka analiza dostarcza cennych informacji, czy model podejmuje decyzje w sposób zgodny z intuicją i wiedzą dziedzinową (np. czy potwierdza, że młode zwierzęta adoptowane są szybciej), a także może ujawnić nieoczywiste zależności w danych.

Rozdział 6 koncentruje się na aspekcie inżynierskim rozwiązania, opisując zastosowane podejście *MLOps* do zapewnienia powtarzalności i niezawodności procesu analitycznego. Omówiono w nim wersjonowanie kodu w systemie Git, powiązanie artefaktów z wersją kodu za pomocą pokwitowań uruchomień (*run receipts*), konteneryzację środowiska za pomocą Docker Compose oraz automatyzację trenowania i weryfikacji modeli w ramach potoku przetwarzania. Rozdział 7 przedstawia zaprojektowaną aplikację internetową (dashboard) służącą jako interfejs użytkownika dla opracowanego modelu. Opisano funkcjonalności prototypowej aplikacji stworzonej w technologii *Streamlit* – m.in. możliwość sprawdzania prognoz dla wybranego zwierzęcia, symulacji scenariuszy (np. jak zmiana pewnych cech wpływa na przewidywane szanse adopcji), czy przegląd globalnych statystyk i trendów. Rozdział ten ukazuje, jak wyniki zaawansowanej analizy danych mogą zostać opakowane w przystępne narzędzie wspierające codzienną pracę schroniska. Wreszcie, Rozdział 8 to podsumowanie uzyskanych wyników oraz wnioski. Zawarto w nim omówienie stopnia realizacji celu pracy, weryfikację hipotez w świetle przeprowadzonych analiz oraz rekomendacje dotyczące wdrożenia wypracowanych rozwiązań w praktyce. Przedstawiono także propozycje dalszych kierunków rozwoju – zarówno jeśli chodzi o ulepszenia modelu (np. uwzględnienie dodatkowych danych lub zastosowanie alternatywnych technik uczenia), jak i rozszerzenie funkcjonalności systemu dla schroniska.

Niniejsza praca stanowi zatem połączenie badań nad danymi schroniska z praktycznym wdrożeniem rozwiązania informatycznego. Wkład własny autora przejawia się zarówno w warstwie analitycznej, jak i inżynierskiej. Od strony analitycznej obejmuje on przygotowanie i oczyszczenie zbioru danych, przeprowadzenie eksploracji w celu sformułowania hipotez, a następnie zaprojektowanie i wytrenowanie modeli predykcyjnych dostosowanych do specyfiki danych AAC. Od strony inżynierskiej, istotnym elementem pracy jest zaprojektowanie i zaimplementowanie kompletnego procesu *MLOps*. Obejmuje to m.in.: zautomatyzowanie procesu trenowania modelu i aktualizacji prognoz, wprowadzenie kontroli wersji dla danych i modeli (co zapewnia odtwarzalność wyników), konteneryzację aplikacji dla ułatwienia jej uruchomienia na dowolnej platformie, oraz integrację tych komponentów w ramach deterministycznego potoku z weryfikacją opartą na testach i pokwitowaniach uruchomień. Dodatkowo, autor stworzył aplikację webową, która udostępnia wyniki modeli szerszemu gronu odbiorców w intuicyjnej formie. Dzięki temu podejściu, praca nie tylko odpowiada na postawione pytania badawcze, ale również dostarcza narzędzia mogącego znaleźć praktyczne zastosowanie w poprawie efektywności działania schronisk dla zwierząt.

2. Podstawy teoretyczne i przegląd literatury

2.1 Problem bezdomności zwierząt i filozofia No-Kill

Zjawisko bezdomności zwierząt to poważny problem społeczny i ekologiczny na całym świecie. Szacuje się, że globalna populacja bezdomnych psów i kotów liczona jest w setkach milionów [7]. Szczególnie dotkliwie problem ten występuje w Stanach Zjednoczonych, gdzie każdego roku do schronisk trafia ponad 6 milionów porzuconych lub bezdomnych zwierząt domowych. Historycznie wysoki odsetek z nich był poddawany eutanazji z braku miejsc i możliwości adopcji – jeszcze kilkanaście lat temu uśmiercano miliony psów i kotów rocznie, co stanowiło znaczną część wszystkich przyjmowanych zwierząt [4].

W ostatnich latach, dzięki upowszechnieniu sterylizacji, licznym kampaniom adopcyjnym oraz zmianie podejścia do zarządzania schroniskami, sytuacja zaczęła się stopniowo poprawiać. Obecnie do amerykańskich schronisk wchodzi rocznie ok. 6,3 mln zwierząt, a liczba eutanazji znacząco spadła w porównaniu do dekady ubiegłej [1]. Trend ten odzwierciedla globalny zwrot w kierunku bardziej humanitarnego traktowania bezdomnych zwierząt, którego centralnym elementem jest filozofia *No-Kill*.

Filozofia *No-Kill* zakłada rezygnację z rutynowej eutanazji zwierząt w schronisku *wyłącznie z powodu braku miejsc* – wszystkie zdrowe lub rokujące na wyleczenie zwierzęta powinny pozostać przy życiu i oczekiwać na adopcję tak długo, jak będzie to konieczne. W praktyce za schronisko *no-kill* uznaje się placówkę osiągającą co najmniej 90% tzw. współczynnika ocalenia (ang. *save rate*), czyli odsetka zwierząt opuszczających schronisko żywych [3]. Takie podejście wymaga wdrożenia szeregu strategii zwiększających liczbę udanych adopcji oraz zmniejszających napływ nowych zwierząt do systemu (m.in. programy sterylizacji, rozbudowa wolontariatu).

Przykładem skutecznej realizacji idei *No-Kill* jest miasto Austin w Teksasie. W 2010 r. władze Austin przyjęły kompleksowy plan działań, którego celem było osiągnięcie statusu *no-kill*, a już w kolejnym roku miejskie schronisko Austin Animal Center przekroczyło próg 90% uratowanych zwierząt [3]. Od tego czasu Austin utrzymuje reputację największego miasta *No-Kill* w USA. Sukces ten zainspirował wiele innych społeczności – w ostatnich latach odsetek amerykańskich schronisk deklarujących status *no-kill* znacząco wzrósł [1]. Należy jednak podkreślić, że status ten nie oznacza całkowitego wyeliminowania eutanazji: nadal uśmiercane są zwierzęta poważnie chore lub niebezpieczne, lecz nie dopuszcza się uśpienia zdrowego zwierzęcia z powodów ekonomicznych.

Dane gromadzone w schroniskach stanowią cenne źródło informacji do oceny efektywności adopcji. Większość schronisk prowadzi szczegółową ewidencję przyjęć (ang. *intake*) i opuszczeń (ang. *outcome*) zwierząt, co pozwala śledzić m.in. czas pobytu (*length of stay*), stan zdrowia, rasę czy wiek. Analiza takich danych umożliwia wyliczenie kluczowych

mierników operacyjnych i zastosowanie zaawansowanych metod analitycznych w celu **predykcji** wyników adopcji. Przykładowo, badania wskazują, że cechy takie jak wiek czy wielkość zwierzęcia istotnie wpływają na tempo jego adopcji – szczenięta znajdujące domy szybciej niż psy starsze, a zwierzęta o umaszczeniu odbiegającym od preferowanego mogą oczekiwać na adopcję dłużej [4]. Zjawisko to, często określane mianem *Black Dog Syndrome* (syndrom czarnego psa), sugeruje, że psy o ciemnym umaszczeniu są rzadziej wybierane przez adoptujących [8, 9, 6]. Ponadto istotne znaczenie w procesie adopcji odgrywają interakcje między zwierzęciem a potencjalnym opiekunem w schronisku [10].

2.2 Predykcyjne modelowanie adopcji

Wyzwania związane z poprawą wskaźników adopcji przyczyniły się do rosnącego zainteresowania metodami predykcyjnymi. Modelowanie to polega na wykorzystaniu metod statystycznych oraz algorytmów uczenia maszynowego do przewidywania, czy i kiedy dane zwierzę zostanie adoptowane. Modele uczą się na danych historycznych w celu uchwycenia zależności między cechami zwierzęcia a wynikiem adopcyjnym [5].

Do najprostszych metod predykcji należą modele statystyczne, w tym regresja logistyczna. W modelu tym prawdopodobieństwo adopcji $P(y = 1|X)$ dla wektora cech X modelowane jest za pomocą funkcji logistycznej:

$$P(y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}} \quad (2.1)$$

gdzie β_0 to wyraz wolny, $\beta_1, \dots, \beta_n$ to współczynniki regresji odpowiadające poszczególnym cechom, zaś $x_1, \dots, x_n$ to wartości cech opisujących dane zwierzę.

Choć regresja cechuje się wysoką interpretowalnością, ma ograniczoną zdolność chwytania nieliniowych zależności. Dlatego coraz częściej sięga się po metody o większej mocy predykcyjnej, takie jak zespoły drzew decyzyjnych, które w przeciwieństwie do modeli głębokiego uczenia (ang. *Deep Learning*) wykazują wyższą skuteczność na typowych danych tabelarycznych [11].


Lasy losowe (*Random Forests*), zaproponowane przez Breimana [12], łączą przewidywania wielu niezależnie trenowanych drzew decyzyjnych, co zmniejsza wariancję modelu i zapobiega przeuczeniu. Alternatywnym, potężnym podejściem są algorytmy z rodziny *gradient boosting* [13], które iteracyjnie budują drzewa, gdzie każde kolejne drzewo stara się zminimalizować funkcję straty $\mathcal{L}$ z poprzednich iteracji. W przypadku binarnej klasyfikacji często stosowaną funkcją straty jest *log-loss*:

$$\mathcal{L}(y, \hat{p}) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)] \quad (2.2)$$

gdzie N to liczba próbek treningowych, $y_i \in \{0, 1\}$ to rzeczywista etykieta klasy (1 – adoptowane), a $\hat{p}_i$ to prognozowane prawdopodobieństwo adopcji dla i -tej próbki.

Najbardziej rozpowszechnionymi algorytmami tego typu są XGBoost [14] oraz LightGBM [15]. W ostatnich latach popularność zyskał również CatBoost – biblioteka zoptymalizowana do przetwarzania cech kategorycznych bez konieczności obszernego kodowania zmiennych (ang. *categorical encoding*), np. *one-hot encodingu* [16]. W kontekście danych schroniskowych, które obfitują w atrybuty kategoryczne (rasa, umaszczenie, typ przyjęcia), optymalne metody kodowania zmiennych oraz radzenie sobie z często występującym problemem niezbilansowanych klas (ang. *class imbalance*) [17] odgrywają kluczową rolę w trenowaniu modeli. Badania z wykorzystaniem danych schroniskowych, m.in. praca Sazary i in. (2022), wykazały, że zaawansowane modele klasyfikacyjne potrafią z dużą dokładnością przewidywać szybkość adopcji, identyfikując wiek i rasę jako kluczowe predyktory sukcesu [5].

Ocenę jakości modeli klasyfikacyjnych przeprowadza się z użyciem krzywej ROC (ang. *Receiver Operating Characteristic*), która dla różnych progów decyzyjnych modelu ilustruje zależność między czułością (ang. *True Positive Rate*, TPR) a odsetkiem fałszywych alarmów (ang. *False Positive Rate*, FPR = 1 – swoistość). Pole pod tą krzywą, czyli metryka AUC (ang. *Area Under the Curve*), pozwala ocenić zdolność modelu do rozróżniania klas [18]. Do weryfikacji trafności probabilistycznych predykcji stosuje się także wskaźnik Briera (ang. *Brier Score*) [19]. Do modelowania czasu do zdarzenia (np. długości pobytu w schronisku) stosuje się analizę przeżycia, wykorzystując takie narzędzia jak estymator Kaplana-Meiera [20] i model proporcjonalnego hazardu Coxa [21].




Rysunek 2.1: Krzywe Kaplana-Meiera szacujące prawdopodobieństwo pozostania w schronisku bez adopcji, w podziale na gatunek zwierzęcia (dane Austin Animal Center, 2013–2025). Spadek krzywej odpowiada momentom adopcji; krzywe ucinane są przez obserwacje ocenzone.

Istotnym elementem projektowania modeli jest także ocena **istotności cech** oraz interpretowalność. Złożone modele zespołowe działają często jak „czarne skrzynki”. Metoda SHAP (*Shapley Additive Explanations*) [22] pozwala na alokację kontrybucji każdej cechy do ostatecznej predykcji modelu, w oparciu o wartości Shapleya z teorii gier:

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} (v(S \cup \{i\}) - v(S)) \quad (2.3)$$

gdzie ϕ_i to wartość Shapleya dla cechy i , N to zbiór wszystkich cech, a $v(S)$ to przewidywanie modelu dla podzbioru cech S . Metoda ta pozwala określić, w jaki sposób konkretna cecha (np. czarne umaszczenie) wpływa na obniżenie lub podwyższenie prawdopodobieństwa adopcji dla danego zwierzęcia.



Rysunek 2.2: Podsumowanie wartości SHAP dla modelu klasyfikacji adopcji (CatBoost). Każdy punkt reprezentuje jedną obserwację; kolor koduje wartość cechy (czerwony – wysoka, niebieski – niska). Cechy posortowane malejąco według średniej bezwzględnej wartości SHAP.

Przegląd najistotniejszych prac badawczych wykorzystujących uczenie maszynowe do analizy danych schroniskowych zestawiono w Tabeli 2.1.

2.3 Reprodukowalność i inżynieria danych (MLOps)

Wraz z rozwojem projektów z zakresu sztucznej inteligencji pojawiła się potrzeba wypracowania praktyk zapewniających reprodukowalność badań. Odpowiedzią na te wyzwania jest podejście MLOps (*Machine Learning Operations*), które integruje proces projektowania modeli z ich wdrażaniem, testowaniem i utrzymaniem [24]. W kontekście badań opartych na

Tabela 2.1: Zestawienie wybranych prac dotyczących modelowania adopcji zwierząt

Publikacja	Zastosowane algorytmy	Kluczowe wnioski
Bradley i Rajendran (2021) [4]	Regresja logistyczna, Analiza przeżycia	Wiek i wielkość psa silnie wpływają na czas do adopcji. Optymalna alokacja zasobów schroniska.
Sazara i Gao (2022) [5]	CatBoost, XGBoost	Drzewa wzmacniane gradientowo osiągają wysoką precyzję, użyto SHAP do interpretacji.
Cain i in. (2020) [9]	Lasy losowe, SVM	Umaszczenie (np. Black Dog Syndrome) oraz rasa wpływają na preferencje adoptujących.
Hawes i in. (2022) [23]	LightGBM, Random Forest	Algorytmy ensemble są skuteczne w przewidywaniu ryzyka przedłużonego pobytu w schronisku.

uczeniu maszynowym, infrastruktura MLOps pozwala na standaryzację całego cyklu życia modelu.

Jednym z filarów MLOps jest zagwarantowanie spójnego środowiska uruchomieniowego. Służy do tego konteneryzacja, najczęściej realizowana z użyciem technologii Docker. Zapewnia ona, że kod trenujący model, wraz ze wszystkimi zależnościami, będzie działał identycznie niezależnie od środowiska (np. u lokalnego dewelopera czy na serwerze obliczeniowym), co jest kluczowe dla reprodukowalności badań naukowych [25].

Kolejnym ważnym elementem jest wersjonowanie danych i eksperymentów. W przeciwieństwie do kodu, który podlega kontroli wersji w systemie Git, duże zbiory danych i binarne pliki modeli wymagają dodatkowych mechanizmów proveniencji. W niniejszej pracy powiązanie wersji kodu z artefaktami zapewniają pokwitowania uruchomień (*run receipts*), zapisujące skrót SHA kodu, status kroków i sumy kontrolne wyników. Narzędzia takie jak DVC (*Data Version Control*) [26] lub systemy *experiment tracking*, np. MLflow i Weights & Biases, pozostają możliwym kierunkiem dalszego rozwoju.

Automatyzację projektu realizuje lokalny, deterministyczny potok uruchamiany bezpośrednio lub przez Docker Compose. Potok wykonuje przetwarzanie danych, trenowanie, ewaluację, generowanie artefaktów i testy akceptacyjne, a jego wynik jest audytowalny dzięki pokwitowaniom uruchomień. Ostatnim etapem jest prezentacja wyników, zrealizowana za pomocą biblioteki Streamlit, pozwalającej na tworzenie interaktywnych wizualizacji danych i udostępnianie wyników interesariuszom w postaci aplikacji webowej [27].

3. Dane i przygotowanie zbioru badawczego

W niniejszym rozdziale opisano proces przygotowania zbioru danych do analizy statystycznej. Jednostką obserwacji w badaniu jest epizod pobytu zwierzęcia w schronisku, rozumiany jako pojedyncze przyjęcie, przypisany do niego wynik kończący pobyt oraz zestaw cech znanych w momencie przyjęcia, czyli cech *intake-time-only*. W rozdziale przedstawiono kolejne etapy przekształcania danych surowych do postaci analitycznej.

3.1 Źródło danych i zakres analizy

Materiał empiryczny pochodzi ze schroniska Austin Animal Center (AAC) i został pobrany z bazy Austin Open Data. Baza obejmuje dwie tabele: rejestr przyjęć zwierząt (*intakes*) oraz rejestr wyników kończących pobyt (*outcomes*). Opcjonalnie dane wzbogacono o zmienne kontekstowe, takie jak pogoda.

Zakres czasowy badania obejmuje przyjęcia od 1 października 2013 roku do 4 maja 2025 roku. Analizę ograniczono do psów i kotów, ponieważ stanowią one zasadniczą część populacji schroniskowej. Uwzględnienie rzadziej występujących gatunków, na przykład dzikich zwierząt, mogłoby obniżyć stabilność estymacji.

Wykorzystane dane mają charakter obserwacyjny. Pochodzą z rutynowej dokumentacji schroniska, a nie z kontrolowanego eksperymentu. Z tego powodu analiza obejmuje wyłącznie relacje statystyczne między atrybutami zwierzęcia znanymi w momencie przyjęcia a wynikiem pobytu. Nie formułuje się na tej podstawie wniosków przyczynowo-skutkowych.

3.2 Charakterystyka zbiorów wejściowych

Zbiór analityczny łączy dane o przyjęciu z danymi o wyniku końcowym. Rozdzielenie tych warstw na etapie modelowania pozwala ograniczyć ryzyko wykorzystania informacji z przyszłości, czyli wycieku danych.

Tabela 3.1: Porównanie dwóch podstawowych zbiorów wejściowych

Warstwa danych	Przykładowe pola kluczowe	Rola w procesie
Rejestr przyjęć	animal_id, animal_type, intake_datetime, intake_type, intake_condition, sex_upon_intake, age_upon_intake, breed, color	Źródło atrybutów wejściowych (X)
Rejestr wyników	animal_id, animal_type, outcome_datetime, outcome_type, outcome_subtype, sex_upon_outcome	Źródło zmiennej docelowej (y)

Metadane generowane na końcu pobytu, takie jak `outcome_type` i `outcome_datetime`, wyodrębniono jako zmienne docelowe. Podział ten zapisano w oddzielnych plikach konfiguracyjnych JSON dla cech oraz targetów.

3.3 Standaryzacja i czyszczenie danych

Czyszczenie danych przeprowadzono ostrożnie, bez sztucznej imputacji braków. Nazwy zmiennych zapisano w formacie `snake_case`. Daty ujednolicono do lokalnej strefy czasowej schroniska, konwertując ciągi znaków do formatu `datetime64`.

Sprawdzono kompletność kluczowych atrybutów: `animal_id`, `animal_type`, `intake_datetime`, `outcome_datetime` oraz `outcome_type`. Obserwacje z brakami w tych polach usunięto. Dokładne duplikaty rekordów zostały odfiltrowane.

Tabela 3.2: Redukcja liczby rekordów w kolejnych etapach budowy zbioru modelowego


Zbiór danych na danym etapie	Liczba wierszy	Liczba usuniętych
Zbiór źródłowy wejść (<code>intakes.csv</code>)	173 812	—
Zbiór źródłowy wyjść (<code>outcomes.csv</code>)	173 775	—
Standaryzacja i filtracja wejść	163 901	9 911
Standaryzacja i filtracja wyjść	163 880	9 895
Dopasowane epizody z targetem	162 355	1 525
Finalny zbiór modelowy	162 355	0

Większość usuniętych rekordów dotyczyła zwierząt innych niż psy i koty. Usunięto również 1 511 przyjęć pozbawionych chronologicznie poprawnego wyniku końcowego. W modelowaniu nadzorowanym potraktowano je jako obserwacje bez dostępnej etykiety docelowej i wykluczono z finalnego zbioru; w ujęciu analizy przeżycia mogłyby być one rozważane jako obserwacje cenzorowane. Brakujące dane w atrybutach predykcyjnych występowały pojedynczo: odnotowano 9 braków wieku i 1 brak płci.

3.4 Konstrukcja epizodów i dopasowanie rekordów

Jednostką analizy jest epizod pobytu. Ponieważ to samo zwierzę (`animal_id`) może być kilkakrotnie rejestrowane w schronisku, każde przyjęcie połączono z najbliższym w czasie, niewykorzystanym wcześniej wynikiem. Zastosowano więc metodę najbliższego wolnego zdarzenia w czasie, aby odtworzyć możliwie spójną historię pobytu.

Taka procedura zapobiega powstawaniu ujemnych czasów pobytu oraz wielokrotnemu przypisaniu tego samego wyniku do różnych przyjęć. Audyt zbioru potwierdził poprawność łączenia — nie odnotowano epizodów nakładających się w czasie.



Rysunek 3.1: Porównanie strategii dopasowania rekordów przyjęcia i wyniku.

3.5 Zmienne docelowe

Zdefiniowano dwie główne zmienne docelowe przeznaczone do późniejszego modelowania:

Tabela 3.3: Formalne definicje zmiennych docelowych

Zmienna	Definicja	Interpretacja
classification_target	1 dla Adoption, 0 dla innych	Binarny wynik adopcji
regression_target_days	$(outcome_time - intake_time) \div 86400$	Długość pobytu do dowolnego wyniku (adopcja, transfer, eutanazja lub zgon)
days_to_adoption	Wartość regression_target_days dla adoptowanych	Stosowana wyłącznie w opisowej analizie czasu oczekiwania (nie jako cel modelowania regresji)

Adopcją zakończyło się 50,87% uwzględnionych epizodów, czyli 82 609 przypadków. Pozostałe 49,13% obejmuje powroty do właściciela, transfery, eutanazję oraz zgony. Czas do dowolnego zdarzenia potraktowano jako klasyczny problem regresji, ponieważ długość zajmowania boksu przekłada się bezpośrednio na koszty operacyjne placówki.

3.6 Konstrukcja cech wejściowych

Cechy wejściowe zbudowano wyłącznie na podstawie informacji dostępnych w chwili przyjęcia.

Tabela 3.4: Grupy cech wejściowych

Grupa	Zmienne
Cechy ogólne	animal_type, sex_upon_intake, intake_condition
Wiek	age_days, age_years, age_group (np. baby, senior)
Rasa	breed, primary_breed, simplified_breed_group
Umaszczenie	color, primary_color, simplified_color_group
Kontekst przyjęcia	intake_season, intake_type, covid_period
Cechy binarne	has_name, is_mixed_breed, is_black_or_dark
Cechy czasowe	intake_month, intake_year, intake_season

Aby ograniczyć liczbę kategorii, rasy i umaszczenia pogrupowano w szersze klasy, takie jak pit_bull_type, terrier_type czy domestic_cat. Oryginalna zmienna opisująca rasę zawierała 2 761 unikalnych wartości, z których większość występowała bardzo rzadko.

Na podstawie daty przyjęcia zdefiniowano okresy związane z pandemią: przed COVID-19, czyli do 1 marca 2020 r.; w trakcie pandemii, od marca 2020 do grudnia 2021; oraz po pandemii, od 1 stycznia 2022 r. Wiek przekształcono z wartości tekstowych, na przykład 2 years, do postaci w pełni numerycznej w dniach oraz do kategorii wiekowych.


Cechy wejściowe przebadano pod kątem multikolinearności za pomocą wskaźnika VIF (ang. *Variance Inflation Factor*). Za próg krytyczny przyjęto $VIF > 10$. Analiza wykazała krytyczną redundancję pomiędzy wariantami reprezentacji wieku: age_days uzyskał wartość $VIF = 2971$, a age_group_senior — $VIF = 4341$. Warianty liniowo zależne od siebie zredukowano do jednej numerycznej reprezentacji. Modele drzewiaste są odporne na multikolinearność, jednak ograniczenie redundancji zmniejsza przestrzeń cech i przyspiesza uczenie.

3.7 Charakterystyka opisowa zbioru


Zbiór obejmujący 162 355 pobytów pozwala przedstawić podstawowe statystyki opisowe. Najważniejsze wskaźniki zmieniały się w czasie:

- **Przed COVID-19 (108 785 epizodów):** wskaźnik adopcji wynosił 46,3%, a mediana całkowitej długości pobytu, liczona dla każdego wyniku, była równa 5,25 dnia.
- **COVID-19 (17 946 epizodów):** wskaźnik adopcji wzrósł do 57,2%, a mediana pobytu do 8,01 dnia.
- **Post COVID-19 (35 624 epizodów):** wskaźnik adopcji wyniósł 61,5%, a mediana pobytu 9,83 dnia.

Zmiany te zbiegają się ze zmianą struktury przyjmowanych zwierząt. Odsetek psów spadł z 60,45% w okresie przedpandemicznym do 50,65%. Jednocześnie odsetek młodych zwierząt (baby) wzrósł z 44,11% do 54,34%.




Rysunek 3.2: Roczna liczba przyjęć zwierząt do Austin Animal Center w latach 2013–2025.



Rysunek 3.3: Roczna liczba adopcji w Austin Animal Center.

Psy i koty różnią się pod względem dynamiki adopcji. Ogólny wskaźnik adopcji był zbliżony dla obu grup: 50,28% dla psów i 51,68% dla kotów. Wśród zwierząt adoptowanych do 30 dni schronisko opuszcza jednak 73,6% psów i 54,5% kotów.



Rysunek 3.4: Skumulowane krzywe adopcji dla psów i kotów.

Prawdopodobieństwo adopcji maleje wraz z wiekiem zwierzęcia. Grupa najmłodsza (baby) charakteryzuje się wskaźnikiem adopcji na poziomie 59,7%, młodzież (young) — 47,5%, zwierzęta dorosłe (adult) — 39,6%, a starsze (senior) — 31,0%.


Sposób przyjęcia również wiąże się ze znaczną zmiennością wyników. Wśród 116 393 zwierząt znalezionych na ulicy (Stray) adopcją zakończyło się 48,7% pobytów. Natomiast wśród 34 142 zrzeczeń właścicielskich (Owner Surrender) wskaźnik ten wyniósł 67,1%.

3.8 Ograniczenia danych


Wykorzystany zbiór danych ma kilka ograniczeń.

Po pierwsze, pochodzi z placówki no-kill, czyli schroniska utrzymującego wysoki współczynnik uratowań i niestosującego rutynowej eutanazji zdrowych zwierząt [3]. Wyniki mogą więc różnić się od wyników uzyskanych dla schronisk o innej specyfice działania.


Po drugie, wpisy dotyczące rasy i umaszczenia są deklaracją pracownika dokonaną przy przyjęciu, a nie wynikiem badań genetycznych. Etykiety takie jak `pit_bull_type` odzwierciedlają administracyjny sposób kategoryzacji psów oraz ludzką percepcję ich wyglądu.




Rysunek 3.5: Krzywe Kaplana-Meiera prawdopodobieństwa adopcji w funkcji czasu pobytu, z podziałem na psy i koty.



Rysunek 3.6: Krzywe Kaplana-Meiera czasu do adopcji w podziale na grupy wiekowe zwierzęcia (wyłącznie adoptowane). Zwierzęta z grupy baby opuszczają schronisko najszybciej; krzywa dla grupy senior opada wolniej i osiąga niższy poziom skumulowanej adopcji.



Rysunek 3.7: Krzywe Kaplana-Meiera czasu do adopcji według sposobu przyjęcia (wyłącznie adoptowane). Zwierzęta przyjęte w ramach zrzeczeń właścicielskich (Owner Surrender) trafiają do nowych domów szybciej niż bezpańskie (Stray).



Rysunek 3.8: Porównanie wskaźników adopcji między typowymi profilami zwierząt.

Ograniczeniem technicznym było wykluczenie pobytów bez jednoznacznie zakończonego wyniku, co wynika z wymogu posiadania etykiety docelowej w nadzorowanym uczeniu maszynowym.

3.9 Podsumowanie przygotowania danych

W wyniku opisanych przekształceń utworzono finalny zbiór modelowy obejmujący 162 355 epizodów pobytu psów i kotów w Austin Animal Center. Każdy rekord reprezentuje pojedyncze przyjęcie zwierzęcia, zestaw cech znanych w momencie tego przyjęcia oraz chronologicznie dopasowany wynik końcowy. Taka konstrukcja pozwala analizować proces pobytu z perspektywy informacji dostępnych przed rozstrzygnięciem sprawy zwierzęcia, a jednocześnie ogranicza ryzyko wycieku danych z przyszłości.

Najważniejszymi decyzjami przygotowawczymi były: ograniczenie populacji do psów i kotów, usunięcie rekordów bez podstawowych znaczników czasu i wyniku, dopasowanie przyjęć do najbliższych niewykorzystanych wyników oraz przekształcenie zmiennych opisowych do postaci możliwej do wykorzystania przez modele statystyczne. Szczególną uwagę zwrócono na zmienne, które mogą być dostępne dopiero po zakończeniu pobytu, ponieważ ich użycie prowadziłoby do sztucznego zawyżenia jakości predykcji.

Przygotowany zbiór stanowi podstawę dwóch zadań empirycznych rozwijanych w kolejnych rozdziałach: klasyfikacji prawdopodobieństwa adopcji oraz regresji długości pobytu do dowolnego dopasowanego wyniku. Rozdział następny opisuje metodykę modelowania, sposób podziału danych w czasie, dobór algorytmów oraz metryki użyte do oceny uzyskanych modeli.

4. Metodyka modelowania i oceny modeli

W rozdziale przedstawiono metodykę budowy i oceny modeli predykcyjnych. Problem badawczy sformułowano jako dwa odrębne zadania: klasyfikację binarną, czyli przewidywanie adopcji względem innych wyników, oraz regresję, czyli przewidywanie liczby dni do zakończenia pobytu. Zrezygnowano z analizy przeżycia (ang. *survival analysis*) na rzecz prognozowania całkowitej długości pobytu (ang. *length of stay*). W rozdziale opisano podział zbioru, dobór algorytmów uczących oraz zastosowane metryki oceny. Omówiono również interpretację wyników z wykorzystaniem wartości SHAP oraz protokół badawczy służący zapewnieniu odtwarzalności obliczeń.

Tabela 4.1: Etapy procesu modelowania i oceny

Etap badawczy	Działanie
1. Przygotowanie cech	Wykorzystanie zbioru zdefiniowanego w rozdziale 3. Wykluczenie atrybutów rejestrowanych po przyjęciu w celu uniknięcia wycieku informacji (ang. <i>data leakage</i>).
2. Podział danych	Podział chronologiczny: zbiór treningowy (2013–2021), walidacyjny (2022–2023) oraz testowy (2024–2025).
3. Uczenie modeli	Trenowanie modeli bazowych i zespołowych osobno dla klasyfikacji i regresji.
4. Ocena modeli	Ocena klasyfikacji za pomocą AUC-ROC, AUC-PR, F1-Score oraz regresji za pomocą MAE, RMSE i MedAE.
5. Interpretacja	Analiza wyjaśnień globalnych i lokalnych za pomocą SHAP oraz wpływ zdefiniowanych Rodzin Cech.
6. Reprodukowalność	Deterministyczna inicjalizacja algorytmów (<code>random_state=42</code>) oraz statyczny zapis wyników.

4.1 Cel modelowania

Celem modelowania predykcyjnego jest prognozowanie wyników wyłącznie na podstawie informacji dostępnych w momencie przyjęcia zwierzęcia do schroniska. Analiza koncentruje się na mocy predykcyjnej modeli, a nie na wnioskowaniu przyczynowo-skutkowym.

Modele mają określić, w jakim stopniu atrybuty takie jak gatunek, kategoria wiekowa czy okoliczności przyjęcia pozwalają przewidzieć dwie wartości: (1) prawdopodobieństwo adopcji zwierzęcia oraz (2) całkowity czas zajmowania miejsca w schronisku do momentu zakończenia pobytu, na przykład adopcji, transferu lub powrotu do właściciela. Takie podejście dostarcza prognoz, które mogą być przydatne w zarządzaniu placówką, ponieważ czas pobytu każdego zwierzęcia wiąże się z kosztami operacyjnymi.

4.2 Formalne sformułowanie problemu

Modele uczono dla dwóch zadań:

1. **Klasyfikacja binarna (classification_target):** zmienna objaśniana $Y^{(kl)} \in \{0, 1\}$, gdzie $Y^{(kl)} = 1$ oznacza adopcję, a $Y^{(kl)} = 0$ inny wynik końcowy. Szacowane jest prawdopodobieństwo adopcji $P(Y^{(kl)} = 1 | X)$.
2. **Regresja długości pobytu (regression_target_days):** zmienna ciągła wyrażona w dobach, reprezentująca czas do zdarzenia kończącego pobyt. Model estymuje wartość oczekiwaną długości trwania epizodu $E(T | X)$.

Nie zastosowano modeli analizy przeżycia, takich jak model proporcjonalnych hazardów Coxa czy Random Survival Forest. Wymagałoby to bardziej złożonej estymacji w obecności cenzurowania prawostronnego. Uczenie predykcyjne zdefiniowano jako klasyczną regresję na zamkniętych pobytach, dla których długość pobytu można zmierzyć bezpośrednio.


Zbiór predyktorów X nie zawiera cech będących składową wyniku końcowego.

4.3 Przygotowanie danych i podział chronologiczny

Dane mają charakter czasowy, dlatego zrezygnowano z klasycznej walidacji krzyżowej (ang. *k-fold cross-validation*) z tasowaniem próbek. Celem było uniknięcie wycieku informacji. Uczenie modelu na późniejszych rocznikach i testowanie go na wcześniejszych mogłoby zawyżyć ocenę skuteczności, ponieważ model korzystałby pośrednio z późniejszych wzorców.

Zbiór 162 355 epizodów podzielono chronologicznie na trzy części:

- **Zbiór treningowy:** lata 2013–2021. Pula obejmująca 126 759 rekordów psów i kotów.
- **Zbiór walidacyjny:** lata 2022–2023. Obejmuje 21 811 epizodów. Przeznaczony do doboru parametrów modeli i wskaźników odcięcia.
- **Zbiór testowy:** lata 2024–2025. Obejmuje 13 820 epizodów. Służy wyłącznie do ostatecznej oceny najlepszych algorytmów na najnowszych danych.



Rysunek 4.1: Chronologiczny podział zbioru danych

Taki podział pozwala ocenić odporność modelu na zmiany wzorców w czasie (ang. *concept drift*), zwłaszcza w okresie po pandemii COVID-19.

4.4 Algorytmy predykcyjne

W badaniu porównano proste modele odniesienia z bardziej zaawansowanymi algorytmami zespołowymi. Pozwala to ocenić, czy zastosowanie bardziej złożonych metod poprawia jakość predykcji.

Modele bazowe:

- **Modele odniesienia (Dummy):** przewidują klasę większościową w klasyfikacji lub medianę w regresji. Wyznaczają minimalny poziom odniesienia dla oceny błędu w ujęciu deterministycznym.
- **Modele liniowe:** regresja logistyczna dla binarnej zmiennej celu oraz regresja grzbietowa (Ridge) dla regresji długości pobytu. Zapewniają stabilność wyników i umożliwiają stosunkowo prostą analizę wag atrybutów. Prawdopodobieństwo w modelu regresji logistycznej wyraża się wzorem:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}} \quad (4.1)$$

Modele zaawansowane (drzewa decyzyjne):

- **Lasy Losowe (Random Forest, [12]):** model zespołowy łączący predykcje T drzew decyzyjnych, każde uczone na losowym podzbiorze obserwacji (ang. *bagging*) i losowym podzbiorze $\sqrt{p}$ spośród p cech. Agregacja przez uśrednianie (regresja) lub głosowanie większościowe (klasyfikacja) istotnie redukuje wariancję w porównaniu z pojedynczym drzewem. RF nie wymaga skalowania predyktorów, lecz wymaga jawnego kodowania zmiennych kategorycznych.
- **Histogram-based Gradient Boosting (HistGB, [15, 13]):** wariant sekwencyjnego uczenia na pseudoresztkach, gdzie każde kolejne drzewo koryguje błędy poprzedniego. Kluczową innowacją jest dyskretyzacja predyktorów numerycznych do histogramów (≤ 255 kubelków), co skraca złożoność uczenia. Algorytm obsługuje brakujące wartości natywnie i nie wymaga skalowania ani imputacji.
- **CatBoost [16]:** architektura z rodziny wzmacniania gradientowego (ang. *Gradient Boosting*). Zawiera mechanizmy przetwarzania zmiennych kategorycznych bez konieczności sztucznej wektoryzacji (*one-hot encoding*). Z tego powodu dobrze nadaje się do danych zawierających setki nominalnych wartości ras i umaszczeń zwierząt. Ogólna funkcja celu minimalizowana w kolejnych iteracjach algorytmów z tej rodziny ma postać:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (4.2)$$

gdzie l to różniczkowalna funkcja straty, $\hat{y}_i^{(t-1)}$ to predykcja z poprzedniej iteracji, f_t to nowo dodawane drzewo, a $\Omega(f_t)$ to człon regularyzacyjny [13].

Tabela 4.2: Porównanie wykorzystanych rodzin algorytmów predykcyjnych

Algorytm	Obsługa zm. kategorycznych	Nieliniowość	Główne zastosowanie
Dummy	Brak	Nie dotyczy	Punkt odniesienia (ang. <i>baseline</i>)
Logistic/Ridge Regression	Wymaga wektoryzacji	Nie	Stabilne modele liniowe
Random Forest	Wymaga wektoryzacji	Tak	Algorytm zespołowy redukujący wariancję
HistGradientBoosting	Natywna	Tak	Szybkie trenowanie dla dużych zbiorów
CatBoost	Natywna, zaawansowana	Tak	Główne modele, wysoka skuteczność dla cech nominalnych

Dla danych tabelarycznych z dużą liczbą zmiennych kategorycznych wybrano modele oparte na drzewach decyzyjnych (*gradient boosting*). Decyzja ta wynika z tego, że algorytmy te są często uznawane za jeden ze standardów dla tego typu danych (ang. *state-of-the-art*) [11]. W przeciwieństwie do modeli liniowych, dobrze wychwytyują nieliniowe interakcje między zmiennymi, na przykład specyficzny wpływ wieku tylko u konkretnej rasy psów, i nie wymagają rygorystycznego skalowania danych numerycznych.

Zrezygnowano z zastosowania głębokich sieci neuronowych (ang. *Deep Learning*). Literatura badawcza i praktyka inżynierska wskazują, że sieci neuronowe często nie poprawiają jakości estymacji na niejednorodnych zbiorach tabelarycznych w porównaniu z algorytmami z rodziny *gradient boosting*. Jednocześnie wymagają większych zasobów obliczeniowych i ograniczają łatwość interpretacji wyników, co określa się często jako problem czarnej skrzynki.

W procesie strojenia modeli, szczególnie CatBoost, przyjęto zachowawczą strategię doboru hiperparametrów, aby ograniczyć ryzyko przeuczenia (ang. *overfitting*). Zastosowano umiarkowaną głębokość drzew decyzyjnych ($\text{depth}=6$), co ogranicza zapamiętywanie szumu z danych treningowych, oraz niski współczynnik uczenia ($\text{learning_rate}=0.05$), pozwalający na stopniową i stabilną zbieżność algorytmu w trakcie 1000 iteracji. Dodatkowym mechanizmem kontrolnym było wczesne zatrzymywanie ($\text{early_stopping_rounds}=50$), które automatycznie przerywało proces uczenia, gdy metryka na zbiorze walidacyjnym przestawała się poprawiać.

4.5 Metryki oceny

Zastosowano następujące metryki oceny:

Zadanie klasyfikacji:

Tabela 4.3: Wybrane hiperparametry dla modeli wzmacniania gradientowego

Algorytm	Parametr	Wartość
CatBoost	depth	6
	learning_rate	0.05
	iterations	1000
	early_stopping_rounds	50
HistGradientBoosting	max_depth	None
	learning_rate	0.1

- **AUC-ROC (Area Under the Receiver Operating Characteristic Curve, [18]):** miara ogólnej zdolności modelu do rozróżniania klas. Wartość 1.0 oznacza idealne rozróżnianie, a 0.5 prognozę losową. Matematycznie można ją wyrazić jako prawdopodobieństwo, że model oceni wyżej losowo wybrany przypadek pozytywny niż negatywny:

$$\text{AUC-ROC} = P(\hat{p}_1 > \hat{p}_0) \quad (4.3)$$

- **AUC-PR (Area Under the Precision-Recall Curve):** metryka przydatna przy niewielkiej nierównowadze klas, opisująca skuteczność wykrywania kluczowej klasy [28]. Precyzja i czułość zdefiniowane są jako:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN} \quad (4.4)$$

AUC-PR stanowi pole pod krzywą Precision–Recall wyznaczoną dla wszystkich możliwych progów odcięcia. W przeciwieństwie do AUC-ROC, ignoruje przypadki prawdziwie negatywne, co czyni ją bardziej wrażliwą na jakość wykrywania klasy mniejszościowej [28].

- **F1-Score, precyzja (Precision) i czułość (Recall):** miary punktowe zależne od wyboru progu odcięcia (ang. *threshold*). Miara F1 jest średnią harmoniczną precyzji i czułości:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4.5)$$

W metodyce pracy zrezygnowano z naiwnego wyboru progu 0.5. Optymalny próg decyzyjny dla każdego algorytmu został dobrany na niezależnym zbiorze walidacyjnym pod kątem maksymalizacji wskaźnika F1, a następnie zastosowany na zbiorze testowym w celu ewaluacji.

- **Ocena kalibracji (Brier Score):** wysoki wynik AUC nie gwarantuje, że szacowane prawdopodobieństwa odpowiadają rzeczywistej częstości. Wynik Briera (ang. *Brier*

Score [19]) mierzy średni błąd kwadratowy:

$$BS = \frac{1}{n} \sum_{i=1}^n (p_i - o_i)^2 \quad (4.6)$$

gdzie $p_i \in [0, 1]$ to prognozowane prawdopodobieństwo adopcji, a $o_i \in \{0, 1\}$ to rzeczywisty wynik. Wartość $BS = 0$ odpowiada idealnej kalibracji [29]. W celu oceny kalibracji wygenerowano wykresy kalibracyjne. Jest to ważne z punktu widzenia budowy wiarygodnego narzędzia analitycznego dla personelu schroniska.

Zadanie regresji:

- **MAE (Mean Absolute Error):** średni błąd bezwzględny, mierzony w dniach. Jest to główna metryka oceniająca przeciętną pomyłkę modelu:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.7)$$

- **MedAE (Median Absolute Error):** mediana błędów bezwzględnych. Jest to metryka odporna na błędy skrajne, na przykład przypadki zwierząt pozostających w schronisku latami.
- **RMSE (Root Mean Square Error):** pierwiastek błędu średniokwadratowego. Metryka silniej penalizuje największe pomyłki modelu:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4.8)$$

4.6 Interpretowalność (SHAP)


Wyniki modeli predykcyjnych w kontekście schroniskowym i weterynaryjnym powinny być możliwie przejrzyste. Do analizy wpływu poszczególnych cech wykorzystano wartości SHAP (ang. *SHapley Additive exPlanations*) [22].

Metoda ta wywodzi się z kooperatywnej teorii gier i pozwala oszacować wkład poszczególnych atrybutów w końcową prognozę modelu, wykorzystując wartości Shapleya określone wzorem:

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_x(S \cup \{j\}) - f_x(S)] \quad (4.9)$$

gdzie F to zbiór wszystkich cech, S to podzbiór cech niezawierający cechy j , a $f_x(S)$ to prognoza dla podzbioru cech S .

1. **Wyjaśnienia globalne (SHAP Summary):** zestawienie pokazujące średni wpływ cech na decyzje modelu w całym zbiorze, na przykład związek młodego wieku z wyższym prawdopodobieństwem adopcji.
2. **Wyjaśnienia lokalne:** ocena znaczenia atrybutów w konkretnym pojedynczym epizodzie. Funkcja ta rozkłada prognozę na czynniki zwiększające lub zmniejszające końcowy wynik.
3. **Analiza Rodzin Cech:** atrybuty pogrupowano w „Rodziny Cech”, na przykład Wiek, Wygląd i Kontekst. Takie podejście umożliwia odrzucenie lub zachowanie wybranych grup zmiennych oraz sprawdzenie ogólnego spadku celności bez konieczności osobnego analizowania wpływu pojedynczych wektorów.




Rysunek 4.2: Wykres SHAP Summary (beeswarm) dla klasyfikatora adopcji [22]. Każdy punkt odpowiada jednej obserwacji ze zbioru testowego. Kolor odzwierciedla wartość cechy (czerwony – wysoka, niebieski – niska), a pozycja pozioma – wartość SHAP. Szczegółowa interpretacja wyników w rozdziale 5.

4.7 Protokół eksperymentu

W celu zapewnienia odtwarzalności eksperymentu zastosowano następujące zasady:

1. **Jednolite ziarno losowości:** ustalono deterministyczne ziarno liczb pseudolosowych (`random_state=42`) dla algorytmów.
2. **Rozdzielenie obliczeń i wizualizacji:** proces uczenia odbywa się poprzez dedykowany skrypt (`scripts/run_full_pipeline.py`).



Rysunek 4.3: Zagregowany wpływ Rodzin Cech na predykcje klasyfikatora (suma bezwzględnych wartości SHAP per Rodzina). Grupowanie cech pozwala ocenić relatywny wkład całych kategorii atrybutów.

3. **Zapis modeli:** wyniki modelowania i metadane ewaluacyjne zapisywane są bezpośrednio na dysk jako estymatory `.joblib` oraz tabele `.csv`. Interfejs analityczny jedynie odczytuje zapisane parametry, bez konieczności kosztownego ponownego uczenia modeli.

Algorytm 1 przedstawia uproszczony pseudokod procesu uczenia i oceny, realizowany w ramach protokołu badawczego.

4.8 Ograniczenia

Zastosowane modele mają kilka ograniczeń. Głównym ograniczeniem technicznym było wykluczenie pobytów nieukończonych w momencie pobrania bazy, czyli obserwacji objętych cenzorowaniem prawostronnym. Było to konieczne do przeprowadzenia wariantu regresji długości pobytu.

Ponadto modele odzwierciedlają statystyczne uwarunkowania lokalnego rynku w określonym przedziale czasu, szczególnie zasady działania AAC jako schroniska no-kill o wskaźniku przeżycia powyżej 90%. Prawidłowości przypisane na przykład do etykiet rasy mogą zależeć od lokalnej struktury społecznej i sposobu postrzegania zwierząt. Ich bezpośrednie przeniesienie do innych schronisk bez ponownego trenowania lub kalibracji mogłoby obniżyć skuteczność predykcyjną.

Algorytm 1: Protokół treningu i oceny modelu

Input: Zbiór danych D , konfiguracje hiperparametrów Θ

Output: Wytrenowane modele M , metryki oceny E

$D_{train} \leftarrow$ podzbiór D (lata 2013–2021);

$D_{val} \leftarrow$ podzbiór D (lata 2022–2023);

$D_{test} \leftarrow$ podzbiór D (lata 2024–2025);

foreach $zadanie \in \{klasyfikacja, regresja\}$ **do**

foreach $algorytm \in \{Dummy, Logistic/Ridge, RF, HistGB, CatBoost\}$ **do**

$M_{alg} \leftarrow$ Inicjuj($algorytm, \Theta_{alg}, random_state=42$);

 Trenuj M_{alg} na D_{train} używając `early_stopping` na D_{val} ;

if $zadanie == klasyfikacja$ **then**

 Optymalizuj próg odcięcia dla metryki F1 na D_{val} ;

$\hat{y} \leftarrow$ Prognozuj dla D_{test} z modelem M_{alg} ;

$E_{alg} \leftarrow$ Oblicz metryki ewaluacyjne($\hat{y}, D_{test}$);

 Zapisz M_{alg} (`.joblib`) oraz E_{alg} (`.csv`);

Wyprowadź globalne i lokalne wartości SHAP dla modeli CatBoost;

5. Wyniki badań i interpretacja modeli

5.1 Ramy interpretacyjne rozdziału

Ten rozdział zbiera wyniki po dwóch wcześniejszych etapach pracy: przygotowaniu danych i opisanu metod. Punktem wyjścia jest 162 355 dopasowanych epizodów pobytu (przyjęcie–wynik) psów i kotów. Modele oceniano w porządku chronologicznym, a nie po losowym przemieszaniu rekordów: lata 2013–2021 posłużyły do uczenia, lata 2022–2023 do walidacji i ustawiania progów decyzyjnych, natomiast lata 2024–2025 do jednego, końcowego testu. Takie ustawienie jest bardziej wymagające, ale lepiej przypomina sytuację, w której model ma pracować na danych z przyszłości.

Wyniki trzeba czytać z podziałem na dwa osobne zadania. Klasyfikacja odpowiada na pytanie o prawdopodobieństwo adopcji. Regresja szacuje liczbę dni do *dowolnego* dopasowanego wyniku pobytu, a więc nie jest prostą miarą „szybkości adopcji”. W tej zmiennej mieszczą się także inne zakończenia, między innymi eutanazja i powrót do właściciela. Dlatego atrybut `days_to_adoption` pełni tu tylko funkcję pomocniczą i opisową. Klasyfikatory oceniano za pomocą ROC-AUC, PR-AUC, Precision, Recall i F1-Score, a regresję przez MAE, RMSE i MedAE.


W dalszej części najpierw zestawiono jakość modeli, a następnie wrócono do hipotez badawczych. Osobne miejsce zajmuje interpretacja modeli, ponieważ same metryki nie wystarczają do oceny, czy wynik można rozsądnie wykorzystać w praktyce schroniskowej [22].

5.2 Porównanie jakości modeli

Najpierw warto uporządkować całą ścieżkę analizy. Schemat pokazuje, jak od zbioru modelowego przechodzono do porównania algorytmów, wyboru modelu końcowego i interpretacji jego zachowania.


Na podstawie wyników z okresu selekcyjnego 2023 wybrano dwa różne modele końcowe: CatBoost dla klasyfikacji adopcji oraz Random Forest dla regresji długości pobytu. Zbiór testowy z lat 2024–2025 wykorzystano wyłącznie do jednorazowej oceny ich zdolności generalizacji.

Różnica między zadaniami jest dobrze widoczna w metrykach. Wybrany klasyfikator osiągnął ROC-AUC około 0,841, natomiast wybrany model regresyjny uzyskał MAE 20,07 dnia. Warto też zwrócić uwagę na gatunek: wyniki dla kotów są lepsze niż dla psów. Może to oznaczać, że ścieżki pobytu kotów są w badanym materiale bardziej powtarzalne albo mniej zależne od nietypowych przypadków.



Rysunek 5.1: Logika ewaluacji modeli klasyfikacyjnych i regresyjnych.

Na wykresach łatwiej zobaczyć skalę tej przewagi niż w samej tabeli. Rysunek 5.2 pokazuje, że modele boostingowe wyraźnie odsuwają się od modelu bazowego, którym była Regresja Logistyczna.



Rysunek 5.2: Zbiorcze porównanie zdolności dyskryminacyjnej badanych algorytmów na zbiorze łącznym oraz podzbiorach gatunkowych.


Dokładne wartości metryk na odłożonym zbiorze testowym zebrano w tabeli 5.1.

Tabela 5.1: Wyniki modeli wybranych na walidacji, ocenionych na zbiorze testowym (2024–2025)


Zadanie	Podzbiór danych	Wybrany model	Główna miara (ROC-AUC / MAE)	PR-AUC	F1-Score	Precision	Recall	RMSE	MedAE
Klasyfikacja	Zbiór łączny	CatBoost	0,841 (ROC-AUC)	0,885	0,817	0,838	0,797	–	–
Klasyfikacja	Psy	CatBoost	0,810 (ROC-AUC)	0,858	0,798	0,820	0,777	–	–
Klasyfikacja	Koty	CatBoost	0,868 (ROC-AUC)	0,902	0,849	0,840	0,859	–	–
Regresja	Zbiór łączny	Random Forest	20,07 (MAE dni)	–	–	–	–	35,82	10,82
Regresja	Psy	Random Forest	22,22 (MAE dni)	–	–	–	–	41,95	9,84
Regresja	Koty	Random Forest	18,16 (MAE dni)	–	–	–	–	29,27	11,36

Te liczby potwierdzają, że modele bazowe spełniły swoją rolę kontrolną. Naiwne przewidywanie mediany lub dominanty pozwalało sprawdzić, czy dane niosą jakikolwiek sygnał predykcyjny. Najwięcej informacji analitycznej dały jednak modele boostingowe, zgodnie z szerszymi wynikami badań nad danymi tabelarycznymi [14, 16, 11]. Regresja logistyczna pozostaje użyteczna jako prostszy punkt odniesienia, ale to modele nieliniowe lepiej wykorzystały strukturę danych tabelarycznych.


Uzupełnieniem analizy skuteczności klasyfikatora jest krzywa Precision-Recall (PR) oraz macierz pomyłek, które dokładniej ilustrują rozkład błędów modelu, a w szczególności proporcje wyników fałszywie pozytywnych (FP) względem fałszywie negatywnych (FN). W kontekście schroniskowym minimalizowanie obu typów błędów ma inne konsekwencje praktyczne: błędne wskazanie na wysoką szansę adopcji (FP) może opóźnić konieczne



Rysunek 5.3: Wartości rzeczywiste kontra przewidywane dla wybranego modelu regresyjnego (Random Forest). Widoczny jest systematyczny niedoszacunek dla długich pobytów (powyżej 60 dni).




Rysunek 5.4: Rozkład reszt modelu regresyjnego. Silna asymetria prawostronna potwierdza koncentrację błędów na rzadkich przypadkach bardzo długich pobytów – MAE wynosi 20,07 dnia, natomiast mediana błędu bezwzględnego 10,82 dnia.



Rysunek 5.5: Szczegółowy przebieg krzywej ROC dla wybranego klasyfikatora (CatBoost). Widoczne wyraźne wysklepienie nad linią losową (AUC = 0.50).

interwencje wspomagające, a zbyt pesymistyczna prognoza (FN) prowadzi do marnowania zasobów na zwierzę, które poradziłoby sobie samo.




Rysunek 5.6: Krzywa Precision-Recall dla najlepszego modelu klasyfikacyjnego. Pozwala lepiej ocenić jakość predykcji, zwłaszcza w sytuacji niebalansowania klas.

Osobno sprawdzono cechy kontekstowe, takie jak pogoda i wcześniejszy wolumen przyjęć. Ich dodanie nie przyniosło dużej, jednolitej poprawy we wszystkich rodzinach modeli. W klasyfikacji pojawił się niewielki zysk dla CatBoosta w zbiorze łącznym, ale nie przełożył się on na wyraźną poprawę dla psów. W praktyce oznacza to, że zewnętrzny kontekst środowiskowy w momencie przyjęcia należy traktować ostrożnie, raczej jako uzupełnienie niż główne źródło informacji.


5.2.1 Porównanie modeli regresyjnych

W zadaniu regresji szacującym liczbę dni do wyjścia ze schroniska model Random Forest wybrano na podstawie najniższego błędu MAE w okresie selekcyjnym 2023. Do oceny tego zadania wykorzystano metryki opierające się na różnicy między predykcją a wartością rzeczywistą: średni błąd bezwzględny (MAE) oraz pierwiastek błędu średniokwadratowego (RMSE). Rysunki 5.8 i 5.9 pokazują graficzne zestawienie błędów dla poszczególnych algorytmów.


Modele nieliniowe poradziły sobie z tym wyzwaniem zauważalnie lepiej od średniej czy mediany bazowej. Algorytm ten jest w stanie optymalnie wyłapać nieliniowe relacje w strukturze danych wejściowych, co ma kluczowe znaczenie przy zjawiskach z dużą liczbą wartości odstających.



Rysunek 5.7: Macierz pomyłek dla modelu końcowego, pozwalająca szczegółowo prześledzić rozkład poprawnych i błędnych klasyfikacji.



Rysunek 5.8: Porównanie badanych algorytmów pod kątem średniego błędu bezwzględnego (MAE) na zbiorze łącznym oraz podzbiorach gatunkowych.



Rysunek 5.9: Zestawienie błędu RMSE dla modeli regresyjnych. Metryka silniej waży duże odchylenia i uzupełnia kryterium MAE użyte do wyboru modelu.

5.3 Weryfikacja hipotez badawczych

Każda z pięciu hipotez weryfikowana jest poniżej zarówno na podstawie analizy opisowej, jak i wyników predykcyjnych modeli.

Hipoteza H1 (Wpływ okoliczności przyjęcia w relacji do wyglądu)


Wyniki wspierają hipotezę, że okoliczności przyjęcia mają większe znaczenie niż same cechy wyglądu. W analizie opisowej najwyższe wskaźniki adopcji pojawiają się przy zrzeczeniu właścicielskim (Owner Surrender) oraz kategorii Abandoned. Podobny obraz widać w modelu: analizy SHAP i ablacja Rodzin Cech wskazują silniejszy sygnał po stronie zmiennych opisujących typ i okoliczności przyjęcia niż po stronie koloru czy innych cech wyglądu. Nie jest to dowód przyczynowy. To raczej spójna asocjacja, którą model wykorzystuje przy predykcji; podobną potrzebę ostrożności przy interpretowaniu cech schroniskowych podkreślają wcześniejsze badania nad adopcją i długością pobytu [4, 9].

Hipoteza H3 (Wpływ wieku zwierzęcia)


W przypadku wieku zależność jest czytelna i zgodna z intuicją oraz wcześniejszymi badaniami nad wynikami schroniskowymi [9, 4]. Najmłodsze zwierzęta najczęściej kończyły pobyt adopcją: grupa Baby osiąga wskaźnik 59,7%. Dla grupy Young jest to 47,5%, dla zwierząt dorosłych 39,6%, a dla seniorów 31,0%. Wiek pojawia się też wysoko w globalnych wyjaśnieniach modelu, więc nie jest to wyłącznie efekt prostego zestawienia opisowego.

Hipoteza H5 (Okres pandemii COVID-19)


Okres COVID-19 nie daje się sprowadzić do prostej historii o większym popycie na adopcje. W danych opisowych widać wzrost odsetka adopcji: z 46,3% przed pandemią do 61,5% po pandemii. Jednocześnie mediana liczby dni do opuszczenia schroniska rośnie z 5,25 do 9,83 dnia. Ten pozorny paradoks sugeruje zmianę struktury przyjmowanych zwierząt




Rysunek 5.10: Porównanie ważności rodzin cech dla wyniku klasyfikacji. Cechy okoliczności przyjęcia (Intake) dominują nad wyglądem.



Rysunek 5.11: Spadek prawdopodobieństwa adopcji postępujący wraz z wiekiem zwierzęcia (w latach).




Rysunek 5.12: Mediana liczby dni do adopcji w podziale na grupy wiekowe (wyłącznie zwierzęta adoptowane). Niemowlęta opuszczają schronisko najszybciej.



Rysunek 5.13: Krzywe Kaplana-Meiera dla adopcji w podziale na grupy wiekowe [20]. Stromszy przebieg krzywej dla grupy baby potwierdza szybszy czas wyjścia ze schroniska.

albo zmianę pojemności operacyjnej ośrodka, co jest spójne z obserwacjami o zmianach praktyk schroniskowych i przepływów zwierząt w pierwszym okresie pandemii [23, 30]. Zmniejszenie ogólnej liczby przyjęć w trakcie samej pandemii również jest czytelnym sygnałem zachodzących przemian. Sama informacja o pandemii pomaga więc opisać okres, ale nie powinna być czytana jako samodzielne wyjaśnienie mechanizmu.




Rysunek 5.14: Różnice we wskaźnikach adopcji przed, w trakcie oraz po pandemii COVID-19.

Hipoteza H2 (Wpływ sezonowości)


Sezonowość w danych wykazuje pewne różnice, jednak w ogólnym ujęciu ma ona charakter drugorzędny i pomocniczy. Zauważalne są wahania wskaźników w zależności od pór roku, co widoczne jest zarówno we wskaźnikach adopcji, jak i w medianie czasu pobytu. Efekt ten nie przeważa nad takimi zmiennymi jak okoliczności przyjęcia.

Hipoteza H4 (Ciemne umaszczenie i Black Dog Syndrome)


Hipoteza o ciemnym umaszczeniu, nawiązująca do tak zwanego *Black Dog Syndrome*, dotyczy przypuszczalnie niższych szans na adopcję dla zwierząt o ciemnym kolorze sierści. Historycznie, zwierzęta ujęte w kategorii `is_black_or_dark` faktycznie osiągały nieco niższe wskaźniki adopcji. Obecne zestawienia pokazują jednak ciekawe zjawisko polegające na nieznacznym odwróceniu tego efektu – można zaobserwować delikatne przełamanie *Black Dog Syndrome*, gdyż zwierzęta ciemne zaczynają lokalnie zyskiwać w statystykach adopcyjnych. Wciąż jednak taki wynik ilustruje jedynie asocjację w danych, a nie przyczyny decyzji ludzi; literatura opisująca zjawisko preferencji ze względu na wygląd ostrzega, że wpływ koloru i rasy bywa wysoce niejednoznaczny [6, 8, 9].




Rysunek 5.15: Wolumen przyjęć w zależności od okresu względem pandemii COVID-19.




Rysunek 5.16: Wskaźniki adopcji w rozbiciu na pory roku. Wiosna i lato wykazują wyższe wskaźniki niż jesień i zima.



Rysunek 5.17: Mediana czasu pobytu w zależności od sezonu.



Rysunek 5.18: Porównanie wskaźnika adopcji ze względu na umaszczenie zwierząt, wskazujące na lekkie odwrócenie trendu dla grupy o ciemnym umaszczeniu.




Rysunek 5.19: Różnice w medianie czasu pobytu dla zwierząt z jasnym i ciemnym umaszczeniem.

Tabela 5.2: Status hipotez badawczych w świetle wyników

Hipoteza	Zakres	Status	Najważniejsza obserwacja
H1	Okoliczności przyjęcia vs wygląd	Wsparta opisowo i predykcyjnie	Cechy intake-related wykazują wyższą doniosłość (SHAP importance) niż atrybuty umaszczenia.
H2	Sezonowość	Analiza opisowa	Różnice sezonowe istnieją, ale stanowią czynnik drugorzędny predykcyjnie.
H3	Wiek	Wsparta opisowo i predykcyjnie	Wskaźnik adopcji maleje z 59,7% (baby) do 31,0% (senior).
H4	Ciemne umaszczenie	Analiza opisowa	Historycznie niższa adopcyjność ulegająca lokalnemu odwróceniu (lekkie przełamanie efektu).
H5	Okres COVID-19	Wsparta opisowo	Wzrost adopcji (z 46% do 61%) przy jednoczesnym wzroście czasu pobytu (z 5 do 9 dni mediany).

5.4 Interpretacja i wiarygodność modelu

Interpretacja modelu nie jest tu dodatkiem estetycznym, lecz warunkiem sensownego użycia wyników. W środowisku weterynaryjnym i schroniskowym decyzje dotyczą konkretnych zwierząt, dlatego model typu „czarna skrzynka” (ang. *black-box*) łatwo może budzić nieufność personelu. Pracownik schroniska powinien wiedzieć, dlaczego szczeniak albo starszy pies został oznaczony jako przypadek podwyższonego ryzyka. Do tego wykorzystano metody *Explainable AI* (XAI), przede wszystkim wartości SHAP [22]. Globalne wykresy SHAP są zgodne z intuicją wynikającą z danych: starszy wiek obniża prawdopodobieństwo adopcji, a młody wiek działa w przeciwnym kierunku. Taka zgodność nie rozwiązuje wszystkich problemów interpretacyjnych, ale ułatwia rozmowę o modelu z osobami, które miałyby z niego korzystać.




Rysunek 5.20: Zbiorczy wykres SHAP (Summary Plot) dla zadania klasyfikacji, obrazujący wpływ poszczególnych wartości cech na przewidywane prawdopodobieństwo adopcji.

Wynik ten wymaga komentarza. Zmienna `has_name` (czy zwierzę miało imię w chwili przyjęcia) nie oznacza, że samo nadanie imienia zwiększa szansę adopcji – jest to asocjacja agregująca wiele kontekstów właścicielskich. Efekt predykcyjny jest jednak na tyle silny, że dominuje nad cechami wyglądu, wiekiem i rasą [31].

Trzeba przy tym uczciwie zaznaczyć jedną decyzję metodologiczną. Wybrany klasyfikatorem końcowym jest CatBoost, dla którego wygenerowano wykresy SHAP przy użyciu *TreeExplainer*. Interpretacje służą do pokazania kierunków zależności predykcyjnych i nie stanowią dowodu przyczynowości.

Drugim filarem użyteczności jest kalibracja. Samo wysokie ROC-AUC mówi, że model dobrze porządkuje przypadki, ale nie gwarantuje jeszcze, że podawane prawdopodobieństwa są dobrze wyskalowane [18, 19]. To szczególnie ważne na krańcach rozkładu



Rysunek 5.21: Zestawienie średnich wartości SHAP według rodzin cech dla klasyfikatora adopcji. Rodzina `name_identity` uzyskała najwyższy sumaryczny wkład predykcyjny ($\approx 0,55$), wyprzedzając cechy wiekowe ($\approx 0,48$) oraz rasowo-wyglądowe ($\approx 0,26$).


predykcji, gdzie błędna pewność modelu może być bardziej kłopotliwa niż pojedyncza pomyłka klasyfikacyjna.

Oszacowania sprawdzono więc pod kątem luki kalibracyjnej (Brier Score) oraz progów decyzyjnych (`threshold`). Progi dobrano na niezależnym zbiorze walidacyjnym z lat 2022–2023, a potem przeniesiono bez zmian na test z lat 2024–2025. Dla małych podgrup, poniżej 100 obserwacji w zbiorze testowym, wyniki należy czytać szczególnie ostrożnie.


5.4.1 Analiza błędów i wiarygodność modelu

Istotnym aspektem sprawdzania jakości prognozy na wdrożeniu jest identyfikacja tych segmentów, w których algorytmy radzą sobie wyraźnie gorzej. Wykonano tzw. *error analysis* przez wyizolowanie przekrojów (ang. *error slices*) najczęściej prowadzących do pomyłki modelu. Dla klasyfikatora pozwala to wskazać konkretne podgrupy zwierząt wywołujące największy odsetek nietrafionych prognoz, podczas gdy w regresji rzuca światło na przypadki z nadzwyczaj wysokim błędem MAE.


Najostrożniej trzeba interpretować regresję czasu pobytu. Proces opuszczania schroniska jest częściowo losowy i zależy od czynników, których nie ma w tabeli danych. Model nie jest więc „wyrocznią” wskazującą dokładny dzień wyjścia psa czy kota ze schroniska. Lepiej traktować go jako filtr ryzyka i narzędzie do porządkowania uwagi personelu. Z takiego założenia wynika późniejsza architektura Dashboardu oraz środowiska MLOps opisana w kolejnym rozdziale.



Rysunek 5.22: Krzywa kalibracyjna (Calibration Curve) pokazująca, w jakim stopniu przewidywane przez model prawdopodobieństwo adopcji odpowiada rzeczywistej częstotliwości (Perfectly calibrated).



Rysunek 5.23: Wizualizacja przekrojów błędów dla modelu klasyfikacyjnego. Ukazuje wycinki zbioru, w których skuteczność modelu jest najniższa.



Rysunek 5.24: Analiza segmentacyjna błędów regresji. Rozbicie przypadków według wielkości MAE dla różnych profili zwierząt.

6. Architektura systemu i reprodukowalność eksperymentów

W niniejszym rozdziale przedstawiono warstwę inżynierską i techniczną projektu. Badania oparte na uczeniu maszynowym wymagają nie tylko oceny skuteczności predykcyjnej, opisanej w rozdziale 5, lecz także zapewnienia odtwarzalności (ang. *reproducibility*). Zgodnie z dobrymi praktykami oprogramowania naukowego, na przykład postulatami *The Turing Way* [32], rzetelne badanie powinno być możliwe do niezależnego odtworzenia na podstawie dostarczonego kodu i danych. W tym celu wdrożono uporządkowaną architekturę systemu, skonteneryzowane środowisko Docker, zautomatyzowane skrypty wykonawcze oraz zestaw testów.

6.1 Środowisko wdrożeniowe i konteneryzacja (Docker)

Podstawą reprodukowalności wdrożonego rozwiązania jest skonteneryzowanie go przy użyciu technologii Docker [25]. Zamiast opierać się na lokalnych środowiskach programistycznych, które mogą różnić się konfiguracją i zależnościami, cały system analityczny i aplikacyjny został umieszczony w izolowanym obrazie.

6.1.1 Uzasadnienie złożoności systemu (Dlaczego MLOps?)

Na pierwszy rzut oka do wytrenowania modelu uczenia maszynowego mógłby wystarczyć pojedynczy skrypt w Pythonie. Potrzeba zastosowania bardziej rozbudowanej architektury Docker, izolowanych potoków i środowisk testowych wynika jednak bezpośrednio z charakteru problemu badawczego.

Praca na 160 tysiącach epizodów zwierząt obejmujących 10 lat działalności schroniska wiąże się z istotnym ryzykiem wycieku danych (ang. *data leakage*). W nieustrukturyzowanym kodzie łatwo o sytuację, w której podczas transformacji danych przypadkowo uwzględniona zostanie informacja z przyszłości, na przykład powód eutanazji jako predyktor, mimo że model ma działać już na etapie przyjęcia zwierzęcia. Dodatkowym problemem jest zjawisko „cichej degradacji” (ang. *silent failure*). W przypadku błędnie podanych danych model nie musi wygenerować technicznego błędu, takiego jak *Exception*, lecz może bez widocznego ostrzeżenia zwrócić nieprawidłową predykcję ryzyka. Z tego powodu uporządkowana infrastruktura MLOps była ważna dla zapewnienia bezstronności, audytowalności i kontroli jakości wygenerowanych rezultatów, a nie tylko dla uzyskania wysokich metryk.


6.1.2 Architektura serwisów (Docker Compose)

Zastosowano narzędzie Docker Compose (`docker-compose.yml`), które definiuje architekturę systemu jako zbiór odseparowanych kontenerów, czyli serwisów, korzystających ze wspólnych zasobów. Taka struktura pozwala uruchomić wybraną warstwę systemu za pomocą jednej komendy. W ramach architektury zdefiniowano następujące serwisy operacyjne:

```
services:
  dashboard:
    build: .
    ports: ["8501:8501"]
    volumes: [./models:/app/models]
  pipeline-full:
    build: .
    command: python scripts/run_full_pipeline.py
    volumes: [./data:/app/data, ./reports:/app/reports]
  test:
    build: .
    command: python -m pytest tests/ -v
```

Listing 6.1: Kluczowe definicje serwisów wyizolowane w architekturze `docker-compose.yml`

Wszystkie te serwisy współdzielą na poziomie kontenerów zmapowane wolumeny pamięci, czyli katalogi `data/`, `models/`, `reports/` i `logs/`. Umożliwia to przepływ wytworzonych artefaktów między poszczególnymi warstwami bez powielania danych. Istotne jest także odseparowanie zapisu od konsumpcji: `pipeline-full` zapisuje artefakty do katalogu `reports/`, natomiast `dashboard` korzysta z modeli zapisanych w katalogu `models/`. Relacje między głównymi serwisami a udostępnianymi katalogami zilustrowano na rysunku 6.1.



Rysunek 6.1: Architektura serwisów Docker Compose i udostępniane wolumeny pamięci

6.2 Architektura *Artifact-First* i separacja warstw

Dzięki skonteneryzowaniu różnych ról systemu możliwe było zastosowanie podejścia *Artifact-First*. Oznacza ono ścisłe rozdzielenie zasobochłonnego procesu uczenia modeli od lekkiej warstwy prezentacyjnej, czyli aplikacji dla użytkownika końcowego.

Decyzja ta wynika z praktycznych ograniczeń środowiska docelowego. Typowe placówki ratownictwa zwierząt nie dysponują infrastrukturą serwerową wyposażoną w akceleratorry graficzne (GPU), które mogą być potrzebne do efektywnego trenowania wybranych modeli. Dodatkowo interaktywne retrenowanie modelu po wprowadzeniu każdego nowego zwierzęcia, czyli tzw. uczenie online, wiązałoby się z ryzykiem operacyjnym. Błędnie wprowadzony rekord mógłby szybko pogorszyć jakość działania całego systemu.

- **Warstwa eksperymentalna (Jupyter):** przeznaczona dla *data scientistów* do testowania hipotez.
- **Warstwa treningowa (Pipeline):** z uwagi na duży wolumen danych, obejmujący ponad 160 tys. epizodów, operacje te zajmują znaczny czas. Wyniki uruchomienia kontenera `pipeline-full` są „zamrażane” w formie statycznych artefaktów: wyuczonych modeli w formacie `.joblib`, tabel wyników w formacie `.csv` oraz wygenerowanych wykresów `.png`.
- **Warstwa konsumpcyjna (Dashboard):** aplikacja demonstracyjna, opisana w rozdziale 7, nie posiada uprawnień do modyfikacji algorytmów. Jej rola ogranicza się do ładowania do pamięci RAM gotowych modeli zapisanych na dysku.

Takie podejście obniża wymagania sprzętowe po stronie serwera aplikacji i wspiera niezmiennosć decyzji algorytmicznych. Pracownik schroniska otrzymuje predykcję z modelu wcześniej przetestowanego, a nie z modelu zmienionego najnowszymi danymi.

6.3 Organizacja kodu i modułowość

Projekt ustrukturyzowano jako standardowy pakiet języka Python zarządzany przez `pyproject.toml`. Struktura repozytorium (listing 6.2) odpowiada podziałowi kompetencji:

```
austin-analysis/  
|-- docker-compose.yml  
|-- pyproject.toml  
|-- src/  
|   |-- aac_adoption/  
|       |-- data/  
|       |-- features/  
|       |-- models/  
|       |-- reporting/  
|-- scripts/  
|   |-- run_full_pipeline.py  
|-- tests/
```

```
|-- notebooks/  
|-- models/  
|-- reports/
```

Listing 6.2: Drzewo katalogów głównego projektu

1. `src/aac_adoption/` – główny kod źródłowy biblioteki, podzielony na domeny: `data` (przetwarzanie epizodów), `features` (rejestr cech), `models` (uczenie i ewaluacja) oraz `reporting` (agregacja wyników).
2. `scripts/` – narzędzia wykonawcze (CLI), np. skrypt `run_full_pipeline.py`.
3. `tests/` – zestaw zautomatyzowanych testów jednostkowych i integracyjnych uruchamianych z kontenera testowego.
4. `notebooks/` – notatniki Jupyter służące analizie odkrywczej.

6.4 Automatyzacja potoku (Pipeline) a notatniki Jupyter

W uczeniu maszynowym częstym problemem jest „ukryty dług techniczny” (ang. *hidden technical debt*) [24]. Modele budowane wyłącznie przez sekwencyjne uruchamianie komórek w notatnikach Jupyter mogą stać się trudne do odtworzenia.

Dlatego w niniejszej architekturze Jupyter (`notebooks/`) służy wyłącznie do badania i rozwoju (R&D). Gdy dana logika okazuje się skuteczna, jest przenoszona do produkcyjnego kodu źródłowego w `src/`. Ostateczne trenowanie modeli realizowane jest przez w pełni skryptowy, centralny potok wywoływany w kontenerze `pipeline-full`:

```
docker-compose up pipeline-full
```

Listing 6.3: Uruchomienie pełnego potoku eksperymentalnego

6.4.1 Fazy zautomatyzowanego potoku i Data Provenance

Komenda ta zamyka proces badawczy w deterministycznych ramach, uruchamiając sekwencyjnie 18 zdefiniowanych kroków widocznych w skrypcie `run_full_pipeline.py`. Proces ten można podzielić na następujące makrofazy:

1. **Zarządzanie danymi:** automatyczne pobranie surowych danych, jeśli ich brakuje, czyszczenie oraz budowa ujednoliconego zbioru (`build_dataset`).
2. **Modelowanie:** trening modeli bazowych, strojenie hiperparametrów algorytmów drzewiastych oraz kalibracja klasyfikatorów.
3. **Diagnostyka i wyjaśnialność:** generowanie wykresów diagnostycznych i przeliczanie wartości SHAP dla całego zbioru.

4. **Raportowanie:** automatyczne zapisywanie artefaktów, czyli tabel i wykresów, bezpośrednio do katalogu reports/.



Rysunek 6.2: Porównanie strategii ewaluacji chronologicznej zastosowanej w potoku eksperymentalnym. Dane z lat 2013–2021 posłużyły do uczenia modeli, lata 2022–2023 do walidacji i doboru progu decyzyjnego, a lata 2024–2025 stanowią jednorazowy zbiór testowy. Podejście to odwzorowuje warunki rzeczywistego wdrożenia, w którym model musi generalizować na dane z przyszłości.

Szczególną uwagę w potoku poświęcono koncepcji **Data Provenance**, czyli proveniencji danych, oraz precyzyjnemu wersjonowaniu eksperymentów. Wersjonowanie kodu zapewnia system Git, a powiązanie konkretnej wersji kodu z odpowiednimi artefaktami realizowane jest przez autorski mechanizm pokwitowań uruchomień (ang. *run receipts*). Każdy krok potoku wywołuje funkcję `write_producer_receipt()`, zapisującą do katalogu `reports/run_receipts/` osobny plik JSON dokumentujący identyfikator uruchomienia, skrót SHA komitu Git, listę artefaktów wejściowych i wyjściowych, czas wykonania oraz status zakończenia. Integracja z narzędziem DVC (Data Version Control) [26] stanowi planowany kierunek dalszego rozwoju systemu [33].

Po poprawnym zakończeniu 18 kroków modelowania potok generuje plik `run_receipt.json`. Pełni on funkcję kompleksowego zapisu technicznego z przebiegu eksperymentu, dokumentując:

- dokładny znacznik czasu (timestamp) rozpoczęcia i zakończenia procedur,
- skrót SHA komitu Git, precyzyjnie identyfikujący wersję kodu źródłowego,

- pełną listę wszystkich wykonanych z powodzeniem faz (od czyszczenia danych, przez inżynierię cech, strojenie hiperparametrów, aż po ocenę końcową),
- podsumowanie ewentualnych ostrzeżeń lub pominiętych kroków kalibracji.

Dzięki temu plikowi można bezbłędnie zidentyfikować, w jakich warunkach oraz na jakich danych trenujących powstały wyeksportowane modele.

6.5 Rygor testowy i audyty danych

Złożoność przetwarzania danych weryfikowano na każdym etapie za pomocą zautomatyzowanych zestawów testów, uruchamianych w ramach komendy `docker-compose up test`. Środowisko testowe pokrywa szereg krytycznych aspektów niezawodności, przede wszystkim: obronę przed wyciekami danych informujących o przyszłości (ang. *data leakage*), integralność strukturalną tabel bazowych (*data integrity*) oraz spójność przejścia surowych danych przez cały zintegrowany potok (*pipeline tests*). System zwraca jednoznaczne logi dokumentujące poprawność architektury:

```
===== test session starts ↗
  ↳ =====
collected 34 items

tests/test_leakage_audit.py::test_audit_leakage_columns_risk_levels ↗
  ↳ PASSED
tests/test_leakage_audit.py::test_no_leakage_columns_in_dataset ↗
  ↳ PASSED
tests/test_leakage_audit.py::test_no_future_columns_in_dataset ↗
  ↳ PASSED
tests/test_leakage_audit.py::test_all_prohibited_columns_rejected ↗
  ↳ PASSED
tests/test_split.py::test_chronological_split_dates ↗
  ↳ PASSED
tests/test_calibration_chronology.py::test_calibration_uses_val_data ↗
  ↳ PASSED
...
===== 34 passed in 18.2s ↗
  ↳ =====
```

Listing 6.4: Fragment wydruku środowiska testowego dokumentujący pomyślne zakończenie audytu wycieku danych (leakage audit)


Wszystkim niedeterministycznym operacjom algorytmicznym w kodzie przypisano stałe ziarno losowości (`RANDOM_STATE = 42`). Nie zastępuje ono chronologicznego podziału danych opisanego w sekcji 4.3, lecz stabilizuje elementy losowe obecne w procedurach uczenia i oceny modeli:

```
RANDOM_STATE = 42

classifier = HistGradientBoostingClassifier(random_state=RANDOM_STATE)
regressor = CatBoostRegressor(random_seed=RANDOM_STATE, verbose=False)
```

Listing 6.5: Przykład utrzymania stałego ziarna losowości w modelowaniu

Poprawne uruchomienie całego środowiska Docker — od potoku treningowego po warstwę prezentacyjną — potwierdzono praktycznie. Rysunek 6.3 przedstawia stronę startową aplikacji demonstracyjnej uruchomionej w kontenerze dashboard.




Rysunek 6.3: Strona główna aplikacji demonstracyjnej (Streamlit) działającej w kontenerze dashboard po pomyślnym zakończeniu potoku `pipeline-full`. Widoczne zakładki odpowiadają modułom funkcjonalnym opisanym w rozdziale 7.

W połączeniu z powtarzalną architekturą Docker wspiera to odtwarzalność potoku analitycznego na innej maszynie serwerowej. Celem takiej organizacji jest uzyskanie tych samych tabel wyników oraz wykresów przy ponownym uruchomieniu eksperymentu, z zastrzeżeniem możliwych minimalnych różnic numerycznych wynikających z wersji bibliotek, architektury sprzętowej lub ustawień wielowątkowości. Tak rozumiana reprodukowalność odpowiada kryteriom audytowalności prac naukowych.

7. Aplikacja demonstracyjna i sposób prezentacji wyników

Zbudowanie skutecznego algorytmu analitycznego działającego w środowisku konsolowym, opisanym w poprzednich rozdziałach, rozwiązuje problem z perspektywy *data science*, ale nie tworzy jeszcze narzędzia wygodnego dla pracowników schroniska. Aby ograniczyć barierę wejścia i pokazać praktyczną użyteczność opracowanych modeli, stworzono interaktywną aplikację demonstracyjną (dashboard).

W niniejszym rozdziale przedstawiono cele, architekturę oraz przykładowe scenariusze użycia tego narzędzia wizualnego, które stanowi końcowy element praktycznej części pracy.



Rysunek 7.1: Widok startowy aplikacji demonstracyjnej (*Executive Overview*) z widocznym selektorem języka interfejsu (Polish / English) w panelu bocznym oraz zestawieniem wyników selekcji modelu. Aplikacja dostępna jest lokalnie pod adresem `localhost:8501` po uruchomieniu `docker-compose up dashboard`.

7.1 Cel i środowisko aplikacji

Głównym celem aplikacji jest umożliwienie personelowi Austin Animal Center (AAC) korzystania z wyników modelu predykcyjnego bez konieczności posiadania wiedzy programistycznej lub analitycznej.

Kluczowym założeniem projektowym, zgodnym z opisaną w rozdziale 6 architekturą *Artifact-First*, jest pasywność aplikacji w kontekście uczenia maszynowego. Wybór biblioteki Streamlit [27] podyktowany był natywnym wsparciem dla języka Python, możliwością błyskawicznego prototypowania (ang. *rapid prototyping*) oraz czytelnym interfejsem

użytkownika (UI). Streamlit pozwala na bezproblemową integrację wizualizacji danych. Aplikacja wspiera dwujęzyczność — użytkownik może przełączać interfejs między językiem polskim a angielskim za pomocą selektora widocznego w panelu bocznym, co czyni ją dostępną zarówno dla krajowego personelu, jak i anglojęzycznych wolontariuszy. Dodatkowo aplikacja została zaprojektowana z uwzględnieniem obsługi przypadków brzegowych – w sytuacji brakujących danych wprowadzanych przez użytkownika lub pojawienia się bardzo rzadkich ras, system stosuje bezpieczne wartości domyślne, co zapobiega awarii podczas generowania predykcji. Aplikacja nie trenuje modeli interaktywnie. Zamiast tego pobiera wcześniej zatwierdzone i zamrożone po weryfikacji testowej artefakty ze współdzielonego wolumenu Dockera dostępnego dla kontenera jako katalog `models/`.

Poniższy fragment kodu pokazuje lekkość warstwy konsumpcyjnej. Interfejs wczytuje wcześniej wytrenowany model i przechodzi w stan gotowości operacyjnej:

```
import streamlit as st
import joblib

@st.cache_resource
def load_model():
    # Model ładuje się tylko raz po starcie kontenera "dashboard"
    return joblib.load('models/adoption_model.joblib')

model = load_model()
```

Listing 7.1: Mechanizm buforowania wczytywania modelu zapobiegający degradacji wydajności

Dzięki temu system, działający jako izolowany kontener dashboard, ogranicza ryzyko uszkodzeń wynikających z wprowadzania błędnych danych przez operatora. Czas oczekiwania na prognozę pozostaje krótki, ponieważ aplikacja korzysta z gotowego modelu, a nie uruchamia procesu trenowania.

7.2 Główne moduły funkcjonalne (widoki)

Interfejs użytkownika podzielono na logiczne sekcje odpowiadające najczęstszym operacjom w schronisku.

7.2.1 Symulator pojedynczego przyjęcia (Model Sensitivity Demo)

Jest to główny moduł operacyjny przeznaczony dla personelu pracującego przy tak zwanej „bramie” (*intake*), czyli na etapie przyjęcia zwierzęcia do ośrodka. Umożliwia on manualne wprowadzenie cech zwierzęcia znanych w momencie przyjęcia.

Użytkownik definiuje z rozwijanych list między innymi:

- gatunek, płeć oraz wiek w miesiącach lub latach,

- typ i okoliczności przyjęcia, na przykład zrzeczenie właścicielskie, znalezienie na ulicy lub uratowanie z wypadku,
- cechy wyglądu, w tym rasę dominującą oraz umaszczenie.

Po zatwierdzeniu formularza wbudowany w aplikację skrypt mapuje wartości z interfejsu na odpowiedni, stabelaryzowany wektor wejściowy i przekazuje go do wiodącego modelu klasyfikacyjnego. Pracownik otrzymuje następnie czytelny wynik:

1. **Ocena ryzyka długiego pobytu** – aplikacja klasyfikuje przypadek, używając wcześniej ustalonego progu decyzyjnego.
2. **Kwantyfikacja** – prezentowane jest bazowe prawdopodobieństwo adopcji w procentach.

Language / Język
Polski

Resynchronizuj Bufory Pamięci
Stanu (Refresh)

Wizualizacja wyników pracy magisterskiej: analiza predykcyjna adopcji w AAC

Interaktywny system wizualizacji modeli klasyfikacyjnych, weryfikacji hipotez oraz analizy wrażliwości.

< 12 (XAI) Moduł ewaluacji ryzyka Weryfikacja hipotez badawczych Identyfikacja celów interwencji promocyjnych **Moduł empirycznej ewaluacji podatności na wejście (Sensitivity Analysis)**

Methodological note: Changing fields in this form shows how the trained model reacts to different input records. It does not prove that changing a real animal's characteristic would change its adoption outcome.

Rutyna wymusza pobranie zasobów z potoku wytworzonego predyktora (skonsolidowany algorytm klasyfikujący-regresyjny). Narzędzie to stanowi symulację estymacyjną oraz weryfikację na żądanie i w żadnym ze swoich obiektywnych wskaźników nie uprawnia do stanowienia niezależnej i odciętej reguły przyzwolenia na określoną decyzję fizyczną względem zjawiska.

Gatunek
Dog

Zmienia ciągła wieku (lata)
2.00

Klasyfikacja formalna trybu przyjęcia
Obiekt porzucony/bezpański (Stray)

Taksonomia rasy
Labrador Retriever Mix

Stan kondycyjno-zdrowotny przy inkorporacji
Normalny (Normalny)

Klasyfikacja fenotypowa umaszczenia
Black/White

Status reprodukcyjny zwierzęcia w chwili inkorporacji
Samiec niezdezintegrowany reprodukcyjnie

Temporalny znacznik przyjęcia
2024/06/01

☒ Identyfikator nadany (imię)

Zainicjuj predykcję heurystyczną

Rysunek 7.2: Główny interfejs aplikacji demonstracyjnej (Model Sensitivity Demo) wspomagający ocenę nowo przyjmowanego zwierzęcia, pełniący rolę symulatora manualnego wprowadzania parametrów.

7.2.2 Wyjaśnialność decyzji (Interactive SHAP)

Wartość prawdopodobieństwa jest użyteczną informacją, jednak personel weterynaryjny potrzebuje również zrozumienia powodów stojących za oceną algorytmu, czyli tak zwanej *explainability*. Dlatego dla predykcji pojedynczego zwierzęcia aplikacja może prezentować lokalne wyjaśnienie SHAP, na przykład w postaci wykresu typu *force plot* lub *waterfall plot*.

W perspektywie globalnej, czyli dla całego zbioru, wartości te układają się w interpretowalne wzorce, co prezentuje poniższy wykres.



Rysunek 7.3: Globalna analiza struktury ważności cech na podstawie rozkładu wartości Shapley’a (SHAP), pozwalająca na ocenę relacyjnej istotności predyktorów bez domniemania związków przyczynowo-skutkowych.

Pracownik na ekranie aplikacji widzi analogiczny wykres, ale ograniczony do jednego zwierzęcia. Może sprawdzić, które konkretne atrybuty, na przykład podeszły wiek psa, ciemne umaszczenie czy trudna sytuacja znalezienia, obniżyły wynik, a które, na przykład przynależność do bardziej pożądanego typu rasy, działały na jego korzyść. Jest to istotny element budowania zaufania między człowiekiem a algorytmem i ograniczania ryzyka odrzucenia systemu z powodu postrzegania go jako „czarnej skrzynki” (*black-box*) [34].

7.2.3 Laboratorium hipotez (Hypothesis Lab)

Zakładka *Hypothesis Lab* stanowi bezpośrednie przedłużenie analitycznej części pracy w przestrzeni interfejsu użytkownika. Prezentuje ona wyniki weryfikacji hipotez H1–H5 w formie skondensowanych kart wizualnych z kluczowymi statystykami i wykresami. Dzięki temu kierownik schroniska, bez konieczności sięgania po pełny raport analityczny, może zweryfikować na przykład, czy sezonowy wzorzec adopccyjności (H2) jest zgodny z bieżącymi obserwacjami operacyjnymi.



Rysunek 7.4: Widok panelu *Hypothesis Lab* umożliwiający eksplorację wyników weryfikacji hipotez badawczych H1–H5 w ujęciu syntetycznych kart analitycznych.

7.2.4 Przegląd historycznych grup zwierząt i analiza warunkowa

Dla stanowisk kierowniczych aplikacja udostępnia widok umożliwiający przeglądanie historycznych grup zwierząt z populacji AAC oraz dokonywanie analizy warunkowej (ang. *what-if analysis*). Pozwala to na nakładanie filtrów i obserwację zmian krzywych adopcyjności oraz median długości pobytu w czasie, z podziałem na kluczowe archetypy, takie jak szczenięta, dorosłe psy określonych ras czy koty. Aplikacja może wskazać obszary wymagające uwagi, na przykład nagromadzenie starszych kotów w określonym kwartale roku, bez konieczności generowania zapytań SQL przez analityka.

Dzięki wizualizacji profilowych kontrastów adopcyjności (np. porównaniu młodych psów ras małych ze starszymi psami ras dużych), personel schroniska może błyskawicznie ocenić, jak zmiana wybranych parametrów wpływa na przewidywany czas pobytu. Pozwala to na trafniejsze identyfikowanie grup najwyższego ryzyka, co w ujęciu syntetycznym prezentuje poniższy wykres.


7.3 Scenariusze użycia w pracy schroniska (triaging)

Największą wartością dodaną aplikacji z punktu widzenia operacyjnego nie jest precyzyjna predykcja konkretnej daty, lecz możliwość zastosowania selekcji priorytetowej, czyli tak zwanego *triagingu*.

W tradycyjnym środowisku każdy przyjmowany pies otrzymuje standardową opiekę. Czasem dopiero po kilku miesiącach personel zauważa, że dane zwierzę źle znosi pobyt




Rysunek 7.5: Karty analizy ścieżki pobytu (Animal Stories) wizualizujące historyczne archetypy zwierząt oraz ich kontrasty profilowe.



Rysunek 7.6: Moduł *Campaign Candidate Finder* udostępniający zaawansowane możliwości filtrowania i przeprowadzania analiz warunkowych przez kierownictwo schroniska.

w schronisku i zaczyna funkcjonować jak długoterminowy „rezydent”. W scenariuszu wspartym aplikacją:

1. zwierzę jest wprowadzane do bazy,
2. aplikacja flaguje je jako przypadek wysokiego ryzyka długiego pobytu, na przykład ze względu na bardzo niskie prawdopodobieństwo adopcji lub długi estymowany czas pobytu,
3. pracownik już pierwszego dnia widzi ten alert i może uruchomić procedury zaradcze, na przykład przekazanie zwierzęcia do tymczasowego domu zastępczego (*foster*), rozpoczęcie intensywniejszej promocji w lokalnych mediach społecznościowych lub szybką interwencję behawiorysty.



Rysunek 7.7: Schemat procesu selekcji priorytetowej (triaging) w schronisku z wykorzystaniem systemu predykcyjnego.

7.4 Ograniczenia aplikacji i kierunki dalszego rozwoju

Ograniczenia aplikacji wynikają bezpośrednio z ograniczeń modelu predykcyjnego opisanych w rozdziale 5. Należy wskazać następujące zastrzeżenia:

- **Brak uogólnienia poza populację AAC.** Predykcje dla zwierząt spoza zakresu danych treningowych należy traktować jako ekstrapolowane, a nie interpolowane.
- **Pasywność wobec danych rzeczywistych.** Aplikacja nie pobiera danych operacyjnych w czasie rzeczywistym. Wyświetlane statystyki odzwierciedlają stan artefaktów z ostatniego uruchomienia potoku pipeline-full.
- **Brak formalnej ewaluacji użyteczności.** Niniejsza wersja stanowi demonstrację koncepcyjną i nie była poddana testom użytkowników zgodnym z metodyką HCI [35].

8. Podsumowanie i wnioski końcowe

Ostatni rozdział pracy stanowi syntezę przeprowadzonych badań, ocenę stopnia realizacji założonych celów oraz wskazanie obszarów wymagających dalszej eksploracji w przyszłości.

Głównym celem niniejszej pracy było zbadanie możliwości wykorzystania technik uczenia maszynowego do przewidywania adopcyjności i czasu pobytu zwierząt, czyli psów i kotów, w schronisku typu *No-Kill* na podstawie danych dostępnych wyłącznie w momencie ich przyjęcia. Wyniki eksperymentów, oparte na analizie ponad 160 tysięcy epizodów z Austin Animal Center, wskazują na wysoką skuteczność analityczną zastosowanych algorytmów z rodziny drzew decyzyjnych, w szczególności modeli *Gradient Boosting*. Zbudowane modele pozwalają identyfikować wzorce związane z późniejszym losem zwierzęcia.

8.1 Odpowiedzi na pytania badawcze i weryfikacja hipotez

W toku prowadzonych eksperymentów zweryfikowano trzy kluczowe pytania badawcze (RQ), które ukierunkowały niniejszą pracę:

RQ1: Jakie cechy zwierzęcia są najważniejszymi predyktorami adopcyjności?

Analiza ważności cech, wsparta wyjaśnieniami SHAP, wskazała spójnie, że najważniejszymi predyktorami pozytywnej adopcyjności i krótkiego czasu pobytu są imię zwierzęcia (zmienna *has_name*) oraz jego wiek. Młodsze zwierzęta posiadające nadane imię w momencie przyjęcia mają znacznie większe szanse na pozytywne zakończenie epizodu schroniskowego. Tradycyjne cechy fizyczne, takie jak kategoria rasy czy umaszczenie (kolor), odgrywają w ogólnym rozrachunku rolę drugorzędną.


RQ2: Czy zaawansowane modele (Gradient Boosting) przewyższają linie bazowe?

Eksperymenty pokazały jednoznaczną przewagę zaawansowanych algorytmów drzewiastych nad metodami bazowymi. Na podstawie okresu selekcyjnego 2023 dla klasyfikacji wybrano *CatBoost*; na teście model uzyskał PR-AUC 0,885 oraz ROC-AUC 0,841. Dla regresji wybrano *Random Forest*, który na teście osiągnął MAE 20,07 dnia. Potwierdza to, że drzewa decyzyjne z boostingiem gradientowym skutecznie wychwytyują nieliniowe zależności pomiędzy atrybutami schroniskowymi.

RQ3: Jak zjawiska makrostrukturalne oraz różnice gatunkowe wpływają na wzorce?

Zidentyfikowano wyraźne różnice w zdolności predykcyjnej dla poszczególnych gatunków: skuteczność modeli była wyższa dla kotów (PR-AUC na poziomie 0,899) niż dla psów (PR-AUC 0,857), co sugeruje, że psy bywają oceniane przez pryzmat

bardziej złożonych preferencji i cech niewidocznych w systemie (np. behawioralnych). Dodatkowo wykazano, że okres pandemii COVID-19 w istotny sposób zmodyfikował przepływ zwierząt w schronisku, wydłużając czas ich pobytu i modyfikując dynamikę rotacji jako bardzo silna zmienna zakłócająca (confounder).



Rysunek 8.1: Globalny wykres wartości SHAP dla modelu klasyfikacyjnego, potwierdzający dominującą rolę zmiennej `has_name`, wieku oraz typu przyjęcia w kształtowaniu prawdopodobieństwa adopcji.

8.2 Ograniczenia badawcze i metodologiczne

Ocena modeli predykcyjnych wymaga wskazania ich ograniczeń.

1. **Cenzorowanie prawostronne (*Right-Censoring*).** Do trenowania klasycznych algorytmów predykcyjnych, w szczególności regresji długości pobytu, konieczne było pominięcie epizodów, które nie posiadały wpisanego wyniku zakończenia w momencie zrzutu bazy danych. Zjawisko to jest ograniczeniem wynikającym z odstępiania od technik analizy przeżycia (*Survival Analysis*).
2. **Specyfika schronisk typu *No-Kill* i generalizowalność (*Single-Shelter Generalizability*).** Zidentyfikowane wzorce odnoszą się do placówki działającej w środowisku o wysokiej świadomości społecznej (Austin, Teksas). Przeniesienie modelu do schroniska o innej polityce demograficznej i mniejszych zasobach finansowych mogłoby prowadzić do spadku skuteczności z powodu odmiennych wzorców.
3. **Brak zmiennych behawioralnych.** Zgodnie z założeniem predykcji tuż po przyjęciu (*intake-only*), w wektorze wejściowym nie zawarto oceny behawioralnej zwierzęcia, co w pewnych przypadkach ogranicza sprawność modeli.

4. **Implikacje etyczne (*Ethical Implications*)**. Używanie modeli ML do wskazywania profili wysokiego ryzyka niesie potencjalne niebezpieczeństwo stygmatyzacji. Błędnie przewidziane wysokie ryzyko długiego pobytu mogłoby zniechęcić personel do inwestowania czasu w dane zwierzę, tworząc samospełniającą się przepowiednię.
5. **Uprzedzenia w etykietowaniu ras (*Breed Labeling Bias*)**. Identyfikacja ras w schroniskach odbywa się często w sposób subiektywny na podstawie wyglądu (*visual breed identification*). Może to prowadzić do zaburzenia percepcji ras wprowadzanych do wektorów wejściowych modelu.
6. **Luki w kalibracji w zależności od grupy (*Calibration Gaps by Cohort*)**. Choć ogólna skuteczność modelu jest wysoka, występują różnice w kalibracji dla mniejszych, specyficznych grup (np. wybrane grupy psów), co po wdrożeniu operacyjnym może zmniejszyć pewność modeli w pojedynczych kohortach.
7. **Pandemia jako czynnik zakłócający (*COVID Confounders*)**. Pandemia COVID-19 drastycznie zmieniła zachowania adoptujących oraz politykę przyjęć. Brak uwzględnienia odpowiednio skompensowanych wskaźników tej makro-zmiennej może powodować problemy w analizie po pandemii.

8.3 Kierunki dalszych badań i rekomendacje praktyczne

Rezultaty uzyskane w niniejszej pracy wskazują na możliwość dalszego rozwijania projektu w kierunku naukowym i wdrożeniowym:

- **Uczenie transferowe (*Transfer Learning*)**. Próba przeniesienia modeli wytrenowanych na bazie z Austin do innej, mniejszej placówki pozwoliłaby na ocenę podatności zbudowanych architektur na wiedzę dziedziczną schronisk na szerszą skalę.
- **Integracja z danymi w czasie rzeczywistym (*Real-Time Data Integration*)**. Stworzenie asynchronicznego API połączonego z klasycznym oprogramowaniem ewidencyjnym schroniska, by asystent predykcyjny klasyfikował przypadki już minutę po dokonaniu rejestracji.
- **Wykorzystanie widzenia komputerowego (*Computer Vision*)**. Ocena potencjału zdjęć zwierząt przy pomocy sieci wizyjnych do przechwytywania walorów estetycznych z fotografii, które silnie wpływają na wizerunek rynkowy i skłonności adoptujących.
- **Integracja z mediami społecznościowymi (*Social Media Integration*)**. Podłączenie oprogramowania flagującego do automatycznych akcji promocyjnych online w celu

aktywnego dystrybuowania materiałów o trudnych zwierzętach na zewnętrznych platformach.

- **Ewaluacja wariantu wdrożeniowego (Testy A/B).** Rzeczywiste eksperymenty losowe (A/B testing) z modelem w schronisku na oddzielonej grupie kontrolnej mogłyby definitywnie potwierdzić zdolność systemu do przyspieszenia procesu operacyjnego, izolując narzędzie od efektów psychologicznych.

8.3.1 Rekomendacje dla personelu schronisk

Obok perspektyw teoretycznych sformułowano wytyczne, z których personel placówek zyska korzyści poprzez korektę bieżących działań na poziomie zarządczym:

- **Flagowanie przypadków specyficznych pod kątem interwencji publicznych.** Psy w typie rasy *Pit Bull* oraz zwierzęta przejęte z drastycznych okoliczności (*Public Assist*) powinny być objęte wysokim priorytetem oceny behawioralnej tuż po przyjęciu, gdyż ta grupa notuje jedne z najniższych wskaźników adopcyjności.
- **Priorytetyzacja profesjonalnych zdjęć u starszych roczników (*Senior*).** Przejście z grupy Baby/Young do Adult/Senior koreluje z radykalnym spadkiem tempa adopcji. Skupienie wysiłku wolontariuszy i dobrych kamer w pierwszej kolejności na starszych zwierzętach pozwoli zniwelować barierę wieku.
- **Obowiązkowe procedury namingowe.** Brak posiadanego przez zwierzę imienia wpływa wysoce niekorzystnie na współczynnik trafień predykcyjnych na adopcję. Jak najszybsze nadawanie i rejestrowanie przynajmniej roboczych imion w systemie pozwala szybciej „zhumanizować” los zwierzęcia w percepcji adoptujących.

Wdrożenie systemów uczenia maszynowego w sektorze ratownictwa zwierząt nie zastąpi specjalistycznej wiedzy ludzkiego personelu. Może jednak stanowić narzędzie wspierające zarządzanie ryzykiem i dystrybucję ograniczonych zasobów. Skierowanie większej uwagi behawioralnej i promocyjnej na zwierzęta zidentyfikowane przez model jako szczególnie narażone na długi pobyt może być praktycznym krokiem w stronę usprawnienia systemu współczesnej opieki nad bezdomnymi zwierzętami.

8.4 Podsumowanie końcowe i reprodukowalność

Przeprowadzona w niniejszej pracy analiza 162 355 epizodów schroniskowych wskazuje, że algorytmy uczenia maszynowego, w szczególności modele z rodziny *Gradient Boosting*, mogą skutecznie modelować losy zwierząt wyłącznie na podstawie początkowego profilu wejściowego. W klasyfikacji adopcji wybrany model *CatBoost* osiągnął na



Rysunek 8.2: Panel wspomagający uruchamianie ukierunkowanych kampanii adopcyjnych dla grup zwierząt o największym ryzyku długoterminowego pobytu.

teście PR-AUC 0,885 oraz ROC-AUC = 0,841. W zadaniu regresyjnym wybrany model *Random Forest* uzyskał MAE 20,07 dnia i RMSE 35,82 dnia. Zidentyfikowano kluczowe determinanty ryzyka, wykazując jednoznacznie większe znaczenie wczesnych okoliczności przyjęcia (np. charakteru zrzeczenia się zwierzęcia) oraz jego wieku nad tradycyjnymi, wrodzonymi cechami fizycznymi.

Wartość poznawcza pracy polega zatem nie tylko na osiągnięciu satysfakcjonujących miar predykcyjnych, lecz także na uporządkowaniu procesu analitycznego w sposób możliwy do interpretacji przez odbiorców nietechnicznych. Zastosowanie wyjaśnień SHAP pozwoliło przejść od samego wyniku klasyfikacji do wskazania czynników, które najbardziej zwiększały lub zmniejszały prawdopodobieństwo adopcji oraz ryzyko dłuższego pobytu. Dzięki temu model może być rozumiany jako narzędzie wspomagające decyzje, a nie jako zamknięta, nieprzejrzysta procedura automatycznego rozstrzygania.

Z perspektywy praktycznej najważniejszym wnioskiem jest możliwość wcześniejszego wykrywania przypadków wymagających dodatkowej uwagi organizacyjnej. Jeżeli już w momencie przyjęcia można wskazać zwierzęta potencjalnie narażone na dłuższy pobyt, schronisko może szybciej zaplanować działania promocyjne, konsultacje behawioralne lub wsparcie wolontariuszy. Taki sposób wykorzystania predykcji zachowuje nadrzędną rolę personelu i nie zastępuje indywidualnej oceny zwierzęcia, lecz dostarcza dodatkowego sygnału wspierającego priorytetyzację ograniczonych zasobów.

Technicznym elementem wzmacniającym wiarygodność tych ustaleń było obudowanie ich architekturą *MLOps*, opartą na konteneryzacji Docker i automatycznych audytach wycieku danych (Pytest). Zastosowanie środowisk Jupyter do R&D oraz wyizolowanych



Rysunek 8.3: Widok panelu *Thesis Conclusions* z aplikacji demonstracyjnej. Zwięzłe podsumowanie kluczowych artefaktów wygenerowanych przez ostateczny potok uczenia maszynowego.

potoków uruchomieniowych pipeline-full zapewniło wysoką odtwarzalność procesu badawczego. Zbudowanie interfejsu Streamlit pokazało natomiast, w jaki sposób metody sztucznej inteligencji mogą zostać wprowadzone do codziennej pracy personelu nietechnicznego poprzez interaktywne raportowanie wartości SHAP.

Zgodnie z dobrymi praktykami oprogramowania naukowego cały kod źródłowy projektu, wraz z konfiguracją Docker Compose oraz testami jednostkowymi, został przygotowany w sposób umożliwiający audyt, weryfikację i replikację badań w przyszłości.

Niniejsza praca dowodzi, że dane administracyjne schroniska — dostępne powszechnie, lecz rzadko systematycznie analizowane — kryją w sobie wystarczający sygnał predykcyjny, aby już w momencie przyjęcia zwierzęcia wskazać przypadki wymagające szczególnej uwagi. Zbudowany system nie zastępuje oceny personelu, lecz uzupełnia ją o ilościowy kontekst wyprowadzony z historii ponad 162 tysięcy epizodów schroniskowych. Jego interpretowalna warstwa SHAP oraz certyfikowane przez testy środowisko MLOps czynią z niego narzędzie gotowe do dalszego badania w warunkach rzeczywistego schroniska. W szerszym kontekście wyniki wpisują się w rosnący nurt zastosowań uczenia maszynowego w ochronie dobrostanu zwierząt, wskazując jednocześnie na potrzebę dalszych badań nad sprawiedliwością algorytmiczną i generalizowalnością modeli schroniskowych [4].

Bibliografia

- [1] Shelter Animals Count. Intake and outcome data analysis: Annual report 2024. Online, <https://www.shelteranimalscount.org/explore-the-data/statistics-2024>, 2025. dostęp 08.02.2026.
- [2] ASPCA. U.s. animal shelter statistics, 2024.
- [3] Austin Animal Center. No-kill implementation plan. Online, <https://www.austintexas.gov/page/no-kill-plan>, 2010. dostęp 08.02.2026.
- [4] Janae Bradley and Suchithra Rajendran. Increasing adoption rates at animal shelters: a two-phase approach to predict length of stay and optimal shelter allocation. *BMC Veterinary Research*, 17(1):70, 2021.
- [5] Cem Sazara and Xin Gao. Predicting animal shelter pet adoption times and feature importance analysis using catboost. In *2022 IEEE 11th International Conference on Intelligent Systems (IS)*, pages 1–4, 2022.
- [6] H. J. Svoboda and C. L. Hoffman. Investigating the role of coat colour, age, sex, and breed on outcomes for dogs at two animal shelters in the united states. *Animal Welfare*, 24(4):497–506, November 2015.
- [7] FOUR PAWS. Stray animals: Pets without a home. Online, <https://www.fourpawsusa.org/campaigns-topics/topics/help-for-strays/stray-animals-pets-without-a-home>, 2023. dostęp 08.02.2026.
- [8] L. M. Gunter, R. T. Barber, and C. D. L. Wynne. What’s in a name? effect of breed perceptions & labeling on attractiveness, adoptions & length of stay for pit-bull-type dogs. *PLOS ONE*, 11(3):e0146857, 2016.
- [9] J. Cain et al. Modeling shelter animal adoptions: A data-driven approach. *Animal Welfare*, 29(2):1–15, 2020.
- [10] A. Protopopova and C. D. L. Wynne. Adopter-dog interactions at the shelter: behavioral and contextual predictors of adoption. *Applied Animal Behaviour Science*, 140(3-4):211–221, 2012.
- [11] Léo Grinsztajn, Edouard Oyallon, and Gaël Varoquaux. Why do tree-based models still outperform deep learning on typical tabular data? In *Advances in Neural Information Processing Systems*, volume 35, 2022.
- [12] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

- [13] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [14] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [15] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Liu Tie-Yan. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [16] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [17] Haibo He and Edward A. Garcia. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9):1263–1284, 2009.
- [18] Tom Fawcett. An introduction to roc analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.
- [19] Glenn W. Brier. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3, 1950.
- [20] Edward L. Kaplan and Paul Meier. Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association*, 53(282):457–481, 1958.
- [21] David R. Cox. Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2):187–202, 1972.
- [22] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [23] S. M. Hawes et al. Predicting length of stay in animal shelters using machine learning. *Frontiers in Veterinary Science*, 9, 2022.
- [24] D. Sculley, Gary Holt, Daniel Golovin, Eugene Davydov, et al. Hidden technical debt in machine learning systems. In *Advances in Neural Information Processing Systems*, volume 28, 2015.
- [25] Dirk Merkel. Docker: Lightweight linux containers for consistent development and deployment. *Linux Journal*, 2014(239), 2014.
- [26] Ruslan Kuprieiev et al. Data version control (dvc): Documentation. Online, <https://dvc.org/doc>, 2024. dostęp 08.02.2026.

- [27] Streamlit Inc. Streamlit documentation. Online, <https://docs.streamlit.io>, 2023. dostę 08.02.2026.
- [28] Jesse Davis and Mark Goadrich. The relationship between precision-recall and ROC curves. In *Proceedings of the 23rd International Conference on Machine Learning*, pages 233–240, 2006.
- [29] Alexandru Niculescu-Mizil and Rich Caruana. Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning*, pages 625–632, 2005.
- [30] Lisa M. Gunter, Rebecca T. Barber, and Clive D. L. Wynne. Outcomes for shelter animals during the COVID-19 pandemic: a case study of Arizona shelters. *Animals*, 12(3):272, 2022.
- [31] Scott M. Lundberg, Gabriel Erion, Hugh Chen, Alex DeGrave, Jordan M. Prutkin, Bala Nair, Ronit Katz, Jonathan Himmelfarb, Nisha Bansal, and Su-In Lee. From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1):56–67, 2020.
- [32] The Turing Way Community. The turing way: A handbook for reproducible, ethical and collaborative research. Zenodo, <https://doi.org/10.5281/zenodo.3233853>, 2025. dostę 12.06.2026.
- [33] Dominik Kreuzberger, Niklas Kühl, and Sebastian Hirschl. Machine learning operations (MLOps): Overview, definition, and architecture. *IEEE Access*, 11:31866–31879, 2023.
- [34] Amina Adadi and Mohammed Berrada. Peeking inside the black-box: A survey on explainable artificial intelligence (XAI). *IEEE Access*, 6:52138–52160, 2018.
- [35] Eduardo Mosqueira-Rey, Elena Hernández-Pereira, David Alonso-Ríos, José Bobes-Bascarán, and Ángel Fernández-Leal. Human-in-the-loop machine learning: A state of the art. *Artificial Intelligence Review*, 56(4):3005–3054, 2023.

Spis rysunków

Rysunek 1.1	Liczba przyjęć zwierząt do schroniska Austin Animal Center w kolejnych latach (2013–2025). Wyraźnie widoczny jest spadek wolumenu przyjęć w latach 2020–2021 związany z ograniczeniami pandemii COVID-19, a następnie stopniowy powrót do wartości sprzed pandemii. . . .	3
Rysunek 1.2	Liczba adopcji zarejestrowanych w AAC w kolejnych latach (2013–2025). Zestawienie z Rysunkiem 1.1 ilustruje zmienną relację między wolumenem przyjęć a skutecznością adopcji w poszczególnych latach. . . .	3
Rysunek 1.3	Schemat blokowy metodyki badawczej i przepływu pracy (pipeline MLOps).	7
Rysunek 2.1	Krzywe Kaplana-Meiera szacujące prawdopodobieństwo pozostania w schronisku bez adopcji, w podziale na gatunek zwierzęcia (dane Austin Animal Center, 2013–2025). Spadek krzywej odpowiada momentom adopcji; krzywe ucinane są przez obserwacje ocenzurowane.	11
Rysunek 2.2	Podsumowanie wartości SHAP dla modelu klasyfikacji adopcji (CatBoost). Każdy punkt reprezentuje jedną obserwację; kolor koduje wartość cechy (czerwony – wysoka, niebieski – niska). Cechy posortowane malejąco według średniej bezwzględnej wartości SHAP.	12
Rysunek 3.1	Porównanie strategii dopasowania rekordów przyjęcia i wyniku. . .	16
Rysunek 3.2	Roczna liczba przyjęć zwierząt do Austin Animal Center w latach 2013–2025.	18
Rysunek 3.3	Roczna liczba adopcji w Austin Animal Center.	18
Rysunek 3.4	Skumulowane krzywe adopcji dla psów i kotów.	19
Rysunek 3.5	Krzywe Kaplana-Meiera prawdopodobieństwa adopcji w funkcji czasu pobytu, z podziałem na psy i koty.	20
Rysunek 3.6	Krzywe Kaplana-Meiera czasu do adopcji w podziale na grupy wiekowe zwierzęcia (wyłącznie adoptowane). Zwierzęta z grupy baby opuszczają schronisko najszybciej; krzywa dla grupy senior opada wolniej i osiąga niższy poziom skumulowanej adopcji.	20
Rysunek 3.7	Krzywe Kaplana-Meiera czasu do adopcji według sposobu przyjęcia (wyłącznie adoptowane). Zwierzęta przyjęte w ramach rzeczeń właścicielskich (Owner Surrender) trafiają do nowych domów szybciej niż bezpańskie (Stray).	21
Rysunek 3.8	Porównanie wskaźników adopcji między typowymi profilami zwierząt.	21

Rysunek 4.1	Chronologiczny podział zbioru danych	24
Rysunek 4.2	Wykres SHAP Summary (beeswarm) dla klasyfikatora adopcji [22]. Każdy punkt odpowiada jednej obserwacji ze zbioru testowego. Kolor odzwierciedla wartość cechy (czerwony – wysoka, niebieski – niska), a pozycja pozioma – wartość SHAP. Szczegółowa interpretacja wyników w rozdziale 5.	29
Rysunek 4.3	Zagregowany wpływ Rodzin Cech na predykcje klasyfikatora (suma bezwzględnych wartości SHAP per Rodzina). Grupowanie cech pozwala ocenić relatywny wkład całych kategorii atrybutów.	30
Rysunek 5.1	Logika ewaluacji modeli klasyfikacyjnych i regresyjnych.	33
Rysunek 5.2	Zbiorcze porównanie zdolności dyskryminacyjnej badanych algo- rytmów na zbiorze łącznym oraz podzbiorach gatunkowych.	34
Rysunek 5.3	Wartości rzeczywiste kontra przewidywane dla wybranego modelu regresyjnego (Random Forest). Widoczny jest systematyczny niedoszacunek dla długich pobyków (powyżej 60 dni).	35
Rysunek 5.4	Rozkład reszt modelu regresyjnego. Silna asymetria prawostronna potwierdza koncentrację błędów na rzadkich przypadkach bardzo długich po- byków – MAE wynosi 20,07 dnia, natomiast mediana błędu bezwzględnego 10,82 dnia.	36
Rysunek 5.5	Szczegółowy przebieg krzywej ROC dla wybranego klasyfikatora (CatBoost). Widoczne wyraźne wysklepienie nad linią losową ($AUC = 0.50$).	36
Rysunek 5.6	Krzywa Precision-Recall dla najlepszego modelu klasyfikacyjnego. Pozwala lepiej ocenić jakość predykcji, zwłaszcza w sytuacji niebalansowa- nia klas.	37
Rysunek 5.7	Macierz pomyłek dla modelu końcowego, pozwalająca szczegó- łowo prześledzić rozkład poprawnych i błędnych klasyfikacji.	38
Rysunek 5.8	Porównanie badanych algorytmów pod kątem średniego błędu bezwzględnego (MAE) na zbiorze łącznym oraz podzbiorach gatunkowych.	38
Rysunek 5.9	Zestawienie błędu RMSE dla modeli regresyjnych. Metryka silniej wagi duże odchylenia i uzupełnia kryterium MAE użyte do wyboru modelu.	39
Rysunek 5.10	Porównanie ważności rodzin cech dla wyniku klasyfikacji. Cechy okoliczności przyjęcia (Intake) dominują nad wyglądem.	40
Rysunek 5.11	Spadek prawdopodobieństwa adopcji postępujący wraz z wiekiem zwierzęcia (w latach).	40
Rysunek 5.12	Mediana liczby dni do adopcji w podziale na grupy wiekowe (wyłącznie zwierzęta adoptowane). Niemowlęta opuszczają schronisko naj- szybciej.	41

Rysunek 5.13 Krzywe Kaplana-Meiera dla adopcji w podziale na grupy wiekowe [20]. Stromszy przebieg krzywej dla grupy baby potwierdza szybszy czas wyjścia ze schroniska.	41
Rysunek 5.14 Różnice we wskaźnikach adopcji przed, w trakcie oraz po pandemii COVID-19.	42
Rysunek 5.15 Wolumen przyjęć w zależności od okresu względem pandemii COVID-19.	43
Rysunek 5.16 Wskaźniki adopcji w rozbiciu na pory roku. Wiosna i lato wykazują wyższe wskaźniki niż jesień i zima.	43
Rysunek 5.17 Mediana czasu pobytu w zależności od sezonu.	44
Rysunek 5.18 Porównanie wskaźnika adopcji ze względu na umaszczenie zwierząt, wskazujące na lekkie odwrócenie trendu dla grupy o ciemnym umaszczeniu.	44
Rysunek 5.19 Różnice w medianie czasu pobytu dla zwierząt z jasnym i ciemnym umaszczeniem.	45
Rysunek 5.20 Zbiorczy wykres SHAP (Summary Plot) dla zadania klasyfikacji, obrazujący wpływ poszczególnych wartości cech na przewidywane prawdopodobieństwo adopcji.	46
Rysunek 5.21 Zestawienie średnich wartości SHAP według rodzin cech dla klasyfikatora adopcji. Rodzina <code>name_identity</code> uzyskała najwyższy sumaryczny wkład predykcyjny ($\approx 0,55$), wyprzedzając cechy wiekowe ($\approx 0,48$) oraz rasowo-wyglądowe ($\approx 0,26$).	47
Rysunek 5.22 Krzywa kalibracyjna (Calibration Curve) pokazująca, w jakim stopniu przewidywane przez model prawdopodobieństwo adopcji odpowiada rzeczywistej częstotliwości (Perfectly calibrated).	48
Rysunek 5.23 Wizualizacja przekrojów błędów dla modelu klasyfikacyjnego. Ukazuje wycinki zbioru, w których skuteczność modelu jest najniższa.	48
Rysunek 5.24 Analiza segmentacyjna błędów regresji. Rozbicie przypadków według wielkości MAE dla różnych profili zwierząt.	49
Rysunek 6.1 Architektura serwisów Docker Compose i udostępniane wolumeny pamięci	51
Rysunek 6.2 Porównanie strategii ewaluacji chronologicznej zastosowanej w potoku eksperymentalnym. Dane z lat 2013–2021 posłużyły do uczenia modeli, lata 2022–2023 do walidacji i doboru progu decyzyjnego, a lata 2024–2025 stanowią jednorazowy zbiór testowy. Podejście to odwzorowuje warunki rzeczywistego wdrożenia, w którym model musi generalizować na dane z przyszłości.	54

Rysunek 6.3	Strona główna aplikacji demonstracyjnej (Streamlit) działającej w kontenerze dashboard po pomyślnym zakończeniu potoku pipeline-full. Widoczne zakładki odpowiadają modułom funkcjonalnym opisanym w rozdziale 7.	56
Rysunek 7.1	Widok startowy aplikacji demonstracyjnej (<i>Executive Overview</i>) z widocznym selektorem języka interfejsu (Polish/English) w panelu bocznym oraz zestawieniem wyników selekcji modelu. Aplikacja dostępna jest lokalnie pod adresem localhost:8501 po uruchomieniu docker-compose up dashboard.	57
Rysunek 7.2	Główny interfejs aplikacji demonstracyjnej (Model Sensitivity Demo) wspomagający ocenę nowo przyjmowanego zwierzęcia, pełniący rolę symulatora manualnego wprowadzania parametrów.	59
Rysunek 7.3	Globalna analiza struktury ważności cech na podstawie rozkładu wartości Shapley’a (SHAP), pozwalająca na ocenę relacyjnej istotności predyktorów bez domniemania związków przyczynowo-skutkowych.	60
Rysunek 7.4	Widok panelu <i>Hypothesis Lab</i> umożliwiający eksplorację wyników weryfikacji hipotez badawczych H1–H5 w ujęciu syntetycznych kart analitycznych.	61
Rysunek 7.5	Karty analizy ścieżki pobytu (Animal Stories) wizualizujące historyczne archetypy zwierząt oraz ich kontrasty profilowe.	62
Rysunek 7.6	Moduł <i>Campaign Candidate Finder</i> udostępniający zaawansowane możliwości filtrowania i przeprowadzania analiz warunkowych przez kierownictwo schroniska.	62
Rysunek 7.7	Schemat procesu selekcji priorytetowej (triaging) w schronisku z wykorzystaniem systemu predykcyjnego.	63
Rysunek 8.1	Globalny wykres wartości SHAP dla modelu klasyfikacyjnego, potwierdzający dominującą rolę zmiennej has_name, wieku oraz typu przyjęcia w kształtowaniu prawdopodobieństwa adopcji.	65
Rysunek 8.2	Panel wspomagający uruchamianie ukierunkowanych kampanii adopcyjnych dla grup zwierząt o największym ryzyku długoterminowego pobytu.	68
Rysunek 8.3	Widok panelu <i>Thesis Conclusions</i> z aplikacji demonstracyjnej. Zwięzłe podsumowanie kluczowych artefaktów wygenerowanych przez ostateczny potok uczenia maszynowego.	69